وزارت علوم، تحقیقات و فناوری
دانشگاه تحصیلات تکمیلی علوم پایه
گاوازنگ - زنجان

دانشکده علوم رایانه و فناوری اطلاعات

مهندسی کامپیوتر - هوش مصنوعی و رباتیکز

کشف پیمانه‌های عملکردی در شبکه‌های تعاملات پروتئین – پروتئین با رویکرد شبکه‌های عصبی گرافی

پایان‌نامه‌ی کارشناسی ارشد

سمانه طجرلو

استاد راهنما: **دکتر زهرا نریمانی**

۶ مرداد ۱۴۰۵


بسم الله الرحمن الرحیم

تقدیم به

یگانه دلبندم، سارینا

که بهانه‌ی آغاز و انگیزه‌ی استمرارم در این مسیر بود.
این تلاش تقدیم به تو باد، به امید آنکه بدانی در کتاب زندگی، ایستایی
معنایی ندارد و هیچ‌گاه برای آموختن، رشد کردن و دویدن به سوی
فرداها دیر نیست.

تشکر و قدردانی

سپاس خدایی را که توان پیمودن این مسیر پررهرو را به من بخشید. نخست از استاد راهنمای ارجمندم، سرکار خانم دکتر زهرا نریمانی، که با دانش و صبوری، راهنمای من در این پژوهش بودند، قدردانی می‌کنم. نهایت تشکر خود را تقدیم پدر و مادر عزیزم می‌کنم که با حضور پرمهر خود، همواره تکیه‌گاه استوار من در زندگی بوده‌اند. از دختر نازنینم، سارینا، که با حضور و پویایی خود، انگیزه‌ای ماندگار برای ادامه دادن در من ایجاد کرد، سپاسگزارم. در نهایت، از همسرم قدردانی می‌کنم که نه تنها مشوق و همراهم، بلکه پناهگاه آرامش من در تلاطم‌های این مسیر بود. سپاس که با وجودت، جهان برای من آرام‌تر شد.

چکیده

بیشتر فعالیت‌های زیستی سلول‌ها توسط پروتئین‌ها انجام می‌شود. پروتئین‌ها معمولاً به‌صورت منفرد عمل نکرده و با تشکیل مجموعه‌های پروتئینی، وظایف خود را انجام می‌دهند. شناسایی این مجموعه‌ها برای درک سازوکارهای زیستی بسیار اهمیت دارد. در مقایسه با روش‌های آزمایشگاهی، استفاده از روش‌های محاسباتی کم‌هزینه‌تر است. از همین روی، تاکنون مطالعات زیادی سعی بر استفاده از شبکه تعامل پروتئین_پروتئین برای شناسایی پیمانه‌های عملکردی به کمک روش‌های محاسباتی داشته‌اند. در این بین مطالعات محدودی بر بهره‌گیری از روش‌های یادگیری عمیق مبتنی بر شبکه‌های عصبی گرافی و استفاده موثر از داده‌های زیستی تمرکز کرده‌اند، که هیچ یک روشی یکپارچه جهت شناسایی پیمانه‌های عملکردی بر پایه شبکه‌های عصبی گرافی ارائه نکرده‌اند. در این پژوهش، روشی یکپارچه برای خوشه‌بندی گراف و کشف مجموعه‌های پروتئینی هم‌پوشان مبتنی بر شبکه‌های عصبی گرافی ارائه می‌شود که از ویژگی‌های زیستی پایگاه داده هستی‌شناسی ژن به‌طور مؤثر بهره می‌گیرد. نتایج نشان می‌دهد روش پیشنهادی در مقایسه با سایر روش‌های موجود و بهترین روش فعلی یعنی AdaPPI، در تمامی مجموعه‌داده‌های معیار عملکرد بهتری دارد.

واژه‌های کلیدی: *شبکه‌های عصبی گرافی، تعامل پروتئین_ پروتئین، شناسایی پیمانه‌های عملکردی، خوشه‌بندی گراف‌های دارای ویژگی*

فهرست مطالب

چکیده . . . . . پنج

۱ معرفی پژوهش ۱

۱.۱ مقدمه ۱

۲.۱ بیان مسئله ۲

۳.۱ اهمیت و ضرورت انجام پژوهش ۵

۴.۱ پرسش‌های پژوهش ۶

۵.۱ نوآوری‌های پژوهش ۶

۶.۱ جمع‌بندی ۷

۲ مفاهیم بنیادی ۹

۱.۲ مقدمه ۹

۲.۲ مفاهیم زیستی ۱۰

۱.۲.۲ پروتئین ۱۰

۲.۲.۲ پیمانه‌های عملکردی ۱۰

۳.۲.۲ بیان ژن ۱۲

۴.۲.۲ پایگاه داده هستی‌شناسی ژن ۱۳

۵.۲.۲ شبکه‌های PPI و ویژگی‌های آنها ۱۵
۳.۲ مفاهیم محاسباتی ۱۶
۱.۳.۲ یادگیری ماشین ۱۶
۲.۳.۲ یادگیری عمیق ۱۷
۳.۳.۲ یادگیری نظارت‌شده ۱۷
۴.۳.۲ یادگیری بدون نظارت ۱۸
۵.۳.۲ گراف ۱۸
۶.۳.۲ شبکه‌های عصبی گرافی ۱۹
۷.۳.۲ شبکه‌های عصبی گرافی پیچشی ۲۱
۸.۳.۲ شبکه‌های عصبی گرافی توجه محور ۲۲
۹.۳.۲ شبکه‌های عصبی گرافی با پرش دانش بین لایه‌ها ۲۵
۱۰.۳.۲ تعبیه گره‌ها با روش Node2Vec ۲۷
۱۱.۳.۲ خوشه‌بندی گراف با گره‌های ویژگی‌دار ۲۸
۱۲.۳.۲ دسته‌بندی و روش‌های کلی خوشه‌بندی گراف ۲۹
۴.۲ معیارهای ارزیابی ۳۰
۱.۴.۲ شباهت همسایگی ۳۰
۲.۴.۲ دقت ۳۱
۳.۴.۲ بازیابی ۳۲
۴.۴.۲ امتیاز F ۳۲
۵.۴.۲ صحت ۳۲
۵.۲ جمع‌بندی ۳۳

۳ بررسی منابع ۳۴

۱.۳ خوشه‌بندی گراف با گره‌های ویژگی‌دار ۳۴
۲.۳ پیش‌بینی مجموعه‌های پروتئینی ۴۱
۱.۲.۳ روش‌های بر پایه شبکه ۴۱
۲.۲.۳ روش‌های مبتنی بر آگاهی از زمینه‌های زیستی ۴۲
۳.۲.۳ روش‌های مبتنی بر شبکه‌های عصبی گرافی ۴۴

۴ روش شناسی پژوهش ۴۷
۱.۴ مقدمه ۴۷
۲.۴ مجموعه‌داده ۴۸
۱.۲.۴ مجموعه‌داده شبکه‌های PPI ۵۰
۲.۲.۴ استخراج ویژگی‌ها از پایگاه هستی‌شناسی ژن ۵۱
۳.۲.۴ مجموعه‌های پروتئینی مرجع و پروتکل ارزیابی ۵۵
۳.۴ روش پیشنهادی ۵۶
۱.۳.۴ چارچوب کلی روش پیشنهادی ۵۶
۲.۳.۴ تابع هزینه ۵۸
۳.۳.۴ شبکه‌های عصبی گرافی ۶۱
۴.۳.۴ توابع فعال‌سازی ۶۴
۵.۳.۴ استخراج مجموعه‌های پروتئینی و تعیین آستانه ۶۵
۴.۴ جمع‌بندی ۶۶

۵ نتایج ۶۸
۱.۵ مقدمه ۶۸
۲.۵ محیط پیاده‌سازی ۶۹
۳.۵ نتایج مربوط به عملکرد شبکه‌های عصبی گرافی و تابع هزینه ۷۰

۴.۵ بررسی عملکرد توابع فعالسازی ۷۴
۵.۵ بررسی عملکرد روش پرش دانش ۷۶
۶.۵ مقایسه عملکرد شبکه GAT استاندارد در مقایسه با دو نسخه بهبود یافته آن . . . ۷۸
۷.۵ نتایج تعیین آستانه تجمیعی و تاثیر انتخاب ویژگی ۷۹
۸.۵ مقایسه با پژوهش‌های پیشین ۸۰
۱.۸.۵ بررسی پیمانه‌های پیش‌بینی شده ۸۴

۶ نتیجه‌گیری و پیشنهادها **۸۹**
۱.۶ مقدمه ۸۹
۲.۶ جمع‌بندی و نتیجه‌گیری ۸۹
۳.۶ پیشنهادها ۹۰

آ نتایج تکمیلی روش محاسباتی **۹۲**
آ.۱ نتایج آستانه‌های متفاوت ۹۲
آ.۲ نتایج ویژگی‌های تصادفی ۹۸
واژه‌نامه انگلیسی به فارسی ۱۱۱

فهرست تصاویر

۱.۲ پیمانه‌های عملکردی موجود در یک شبکه تعامل پروتئین_پروتئین، این تصویر انتزاعی هفت پیمانه هم‌پوشان را نمایش می‌دهد. ۱۱

۲.۲ ویژگی‌های عبارت GO:0016597 [۱] ۱۳

۳.۲ ساختار هستی‌شناسی ژن [۱] ۱۴

۴.۲ شماتیک سازوکار انتقال پیام در شبکه‌های عصبی گرافی [۲] ۱۹

۵.۲ سازوکار توجه در شبکه‌های عصبی گرافی [۳] ۲۴

۶.۲ شماتیک پرش دانش در شبکه‌های عصبی گرافی [۴] ۲۶

۱.۴ نمونه‌ای از فایل مجموعه‌داده شبکه PPI ۵۱

۲.۴ نمونه‌ای از مجموعه‌های پروتئینی در فایل مجموعه مرجع ۵۶

۳.۴ نمایی از چارچوب کلی روش پیشنهادی ۵۷

۴.۴ نمونه‌ای از هم‌پوشانی‌های مجموعه‌های پروتئینی در مجموعه مرجع ۶۷

۱.۵ نمودار مقایسه روش پیشنهادی با پژوهش‌های پیشین ۸۴

۲.۵ توزیع اندازه پیمانه‌های مرجع و پیمانه‌های پیش‌بینی‌شده ۸۶

۳.۵ مقایسه پیمانه‌های تودرتو پیش‌بینی شده و مرجع در مجموعه‌داده Biogrid . . . ۸۷

فهرست جداول

۱.۴ تفاوت نسخه‌های هستی شناسی ژن ۵۲

۲.۴ اطلاعات مجموعه داده‌های PPI ۵۵

۱.۵ مشخصات کتابخانه‌های مورد استفاده در این پژوهش به همراه نسخه مربوطه . . ۶۹

۲.۵ نتایج عملکرد شبکه عصبی و تابع هزینه برای مجموعه داده Collins ۷۱

۳.۵ نتایج عملکرد شبکه عصبی و تابع هزینه برای مجموعه داده Krogan-Core . . . ۷۲

۴.۵ نتایج عملکرد شبکه عصبی و تابع هزینه برای مجموعه داده DIP ۷۲

۵.۵ نتایج عملکرد توابع فعال‌سازی با ویژگی‌های دودویی ۷۵

۶.۵ نتایج عملکرد توابع فعال‌سازی با ویژگی‌های تعبیه ۷۶

۷.۵ نتایج عملکرد روش JKNet با ویژگی‌های دودویی ۷۷

۸.۵ بررسی عملکرد شبکه‌های GATv2 و SuperGAT با ویژگی‌های دودویی ۷۸

۹.۵ عملکرد تعیین آستانه تجمیعی و نوع ویژگی‌ها - نتایج مربوط به سایر آستانه‌ها در پیوست موجود است. ۷۹

۱۰.۵ مقایسه عملکرد روش پیشنهادی با پژوهش‌های پیشین در مجموعه‌داده‌های متفاوت - نتایج گزارش شده در پژوهش AdaPPI ۸۱

۱۱.۵ بررسی آماری پیمانه‌های مرجع و پیمانه‌های پیش‌بینی شده از نظر اندازه و هم‌پوشانی ۸۵

۱۲.۵ مقایسه درصد بازیابی جفت‌های پیمانه‌های تودرتو با استفاده از دو روش تعیین آستانه ۸۷

آ.۱ نتایج عملکرد شبکه عصبی در آستانه‌های ثابت مختلف با انواع ویژگی‌ها برای مجموعه داده Collins ۹۳

آ.۲ نتایج عملکرد شبکه عصبی در آستانه‌های ثابت مختلف با انواع ویژگی‌ها برای مجموعه داده Krogan Core ۹۴

آ.۳ نتایج عملکرد شبکه عصبی درآستانه‌های ثابت مختلف با انواع ویژگی‌ها برای مجموعه داده Krogan Extended ۹۵

آ.۴ نتایج عملکرد شبکه عصبی درآستانه‌های ثابت مختلف با انواع ویژگی‌ها برای مجموعه داده Biogrid ۹۶

آ.۵ نتایج عملکرد شبکه عصبی درآستانه‌های ثابت مختلف با انواع ویژگی‌ها برای مجموعه داده DIP ۹۷

آ.۶ مقایسه عملکرد مدل با ویژگی‌های تصادفی با سه رویکرد ماتریس همانی، ویژگی‌های تعبیه تصادفی و ویژگی‌های دودویی تصادفی بر روی مجموعه‌داده‌های Collins و BioGRID ۹۸

فصل ۱

معرفی پژوهش

۱.۱ مقدمه

پروتئین‌ها مولکول‌های بزرگ و پیچیده‌ای هستند که وظایف زیستی حیاتی‌ای مانند نقش ساختاری و حمایتی از سلول‌ها، عملکرد پادتنی، نقش‌های پیام رسانی و یا نقش آنزیمی را عهده‌دار هستند. بسیاری از فرآیندهای زیستی به وسیله‌ی مجموعه‌ای از پروتئین‌ها انجام می‌گیرد که پیمانه‌های عملکردی نامیده می‌شوند. شناخت هر چه بهتر این مجموعه‌های پروتئینی به درک بهتر ما از فرآیندهای زیستی و همچین درک نقش پروتئین‌های کمتر شناخته شده کمک شایانی می‌کند. تشخیص این پیمانه‌ها به کمک روش‌های آزمایشگاهی سخت و هزینه‌بر است از این روی تلاش‌های بسیاری در جهت ارائه‌ی روش‌های محاسباتی کارا به منظور شناسایی این مجموعه‌های پروتئینی انجام شده است. در ادامه‌ی این بخش به بیان بهتر مسئله پیش‌رو و همچنین مفاهیم بنیادی مورد نیاز می‌پردازیم [۵].

زیست‌انفورماتیک سعی بر پاسخ به مسائل و پرسش‌های زیست شناسی به کمک ابزارهای محاسباتی و مدل‌سازی‌های آماری دارد. یافتن پاسخ مناسب برای هر یک از این مسائل می‌تواند تأثیر به‌سزایی در

فهم بیشتر ما از عملکردهای زیستی داشته باشد. در این پژوهش، ما بر روی پروتئین‌ها تمرکز کرده‌ایم و هدف، شناسایی مجموعه‌های پروتئینی، به کمک شبکه برهم‌کنش پروتئین_پروتئین می‌باشد.

۲.۱ بیان مسئله

با پایان یافتن پروژه‌ی توالی‌یابی ژنوم انسان و ورود به دوره‌ی پساژنی[۱]، پژوهش‌های پروتئومیک[۲] به یکی از مهم‌ترین و فعال‌ترین حوزه‌های علوم زیستی تبدیل شده‌اند. پروتئومیک به مطالعه‌ی جامع ویژگی‌های پروتئین‌ها با هدف توصیف ساختار، عملکرد و سازوکارهای کنترلی سیستم‌های زیستی می‌پردازد. پروتئین‌ها عموماً به صورت منفرد عمل نمی‌کنند، بلکه از طریق تعامل با یکدیگر مجموعه‌هایی را تشکیل می‌دهند که انجام بسیاری از وظایف حیاتی سلولی را امکان‌پذیر می‌سازند. تعاملات پروتئین_پروتئین[۳] نقشی اساسی در فرآیندهایی نظیر تکثیر ماده ژنتیکی[۴]، کنترل بیان ژن[۵]، انتقال سیگنال‌های سلولی[۶] و مرگ برنامه‌ریزی‌شده‌ی سلولی[۷] ایفا می‌کنند. از این‌رو، تحلیل شبکه‌های PPI برای درک عمیق‌تر سازماندهی و عملکرد سلولی امری ضروری محسوب می‌شود [۶].

زیست‌انفورماتیک[۸] به عنوان یک حوزه‌ی میان‌رشته‌ای، با تلفیق دانش زیست‌شناسی، علوم کامپیوتر، ریاضیات و آمار، به ذخیره‌سازی، مدیریت و تحلیل داده‌های زیستی می‌پردازد. این علم با بهره‌گیری از ابزارها و فناوری‌های محاسباتی، داده‌های مرتبط با توالی‌های DNA[۹]، RNA[۱۰] و پروتئین‌ها را پردازش و تفسیر می‌کند و با توجه به حجم عظیم داده‌ها و اهمیت استخراج دانش کاربردی از آن‌ها، جایگاهی

[1] Postgenomic era
[2] Proteomics
[3] Protein–protein interactions (PPI)
[4] Gene substance copy
[5] Gene expression control
[6] Cellular signal transduction
[7] Cell apoptosis
[8] Bioinformatic
[9] Deoxyribonucleic acid - DNA
[10] Ribonucleic acid - RNA

کلیدی در پژوهش‌های نوین زیستی یافته است [۷].

مطالعات زیستی نشان می‌دهد که یک مجموعه‌ی پروتئینی[۱] در شبکه‌های PPI به صورت یک ساختار مولکولی منسجم تعریف می‌شود که از پروتئین‌هایی با سازگاری عملکردی و ساختاری تشکیل شده است [۶]. به بیان دیگر، پروتئین‌هایی که در شبکه PPI با یکدیگر تعامل دارند، غالباً از منظر کارکردهای زیستی نیز شباهت‌های معناداری از خود نشان می‌دهند. بر این اساس، زیرشبکه‌های به‌هم‌پیوسته و با تراکم بالای پروتئین‌ها می‌توانند به عنوان پیمانه‌های عملکردی[۲] یا مجموعه‌های پروتئینی در نظر گرفته شوند که در انجام فرآیندهای زیستی خاص نقش دارند. شناسایی این ساختارها علاوه بر امکان بررسی تعامل میان مجموعه‌های پروتئینی مختلف، می‌تواند به کشف مجموعه‌های پروتئینی ناشناخته نیز منجر شود [۶].

یکی از رویکردهای کارآمد برای مطالعه‌ی شبکه‌های PPI، مدل‌سازی و تحلیل آن‌ها از منظر نظریه گراف و شبکه‌های پیچیده است. با اتخاذ این دیدگاه و با توجه به مقیاس بزرگ داده‌های زیستی، یکی از چالش‌های اساسی در دوره پساژنی، طراحی الگوریتم‌های بهینه و مقیاس‌پذیر به منظور شناسایی مؤثر پیمانه‌های عملکردی و مجموعه‌های پروتئینی زیستی است [۸]. از آن‌جایی که پروتئین‌های یک مجموعه‌ی پروتئینی در شبکه PPI دارای تعاملات متراکم و فراوانی با یکدیگر هستند، این نواحی متراکم در شبکه را می‌توان به عنوان مجموعه‌های پروتئینی احتمالی در نظر گرفت. در نتیجه، مسئله شناسایی مجموعه‌های پروتئینی شباهت زیادی به مسئله خوشه‌بندی در شبکه‌های پیچیده دارد [۹] و می‌توان آن را به صورت یک مسئله خوشه‌بندی گرافی مدل‌سازی کرد.

بخش عمده‌ای از پژوهش‌های پیشین در این حوزه صرفاً بر پایه اطلاعات ساختاری شبکه‌های PPI ارائه شده‌اند در حالی که امروزه داده‌های غنی و متنوعی برای توصیف ویژگی‌های پروتئین‌ها در دسترس است. به عنوان نمونه، پایگاه داده هستی شناسی ژن[۳] اطلاعات جامعی درباره ژن‌ها و پروتئین‌ها از

[1] Protein complex
[2] Functional module
[3] Gene Ontology

منظر فرآیندهای زیستی، عملکردهای مولکولی و مؤلفه‌های سلولی فراهم می‌کند و به طور گسترده مورد استفاده پژوهشگران قرار گرفته است [۱۰]. افزون بر این، از آن‌جایی که پروتئین‌ها محصولات بیان ژن هستند، برخی مطالعات از داده‌های بیان ژنی مرتبط با هر پروتئین نیز به منظور توصیف دقیق‌تر آن‌ها در شبکه‌های PPI بهره برده‌اند [۱۱]. ترکیب این اطلاعات تکمیلی با ساختار شبکه PPI می‌تواند به شناسایی دقیق‌تر و مؤثرتر مجموعه‌های پروتئینی منجر شود.

برای بهره‌برداری مناسب از این اطلاعات، نیاز به الگوریتم‌های خوشه‌بندی گرافی وجود دارد که بتوانند به صورت هم‌زمان ساختار شبکه و ویژگی‌های گره‌ها را در فرآیند خوشه‌بندی در نظر بگیرند. به این دسته از روش‌ها، خوشه‌بندی گراف‌های ویژگی‌دار[1] گفته می‌شود [۱۲]. از سوی دیگر، با توجه به این‌که یک پروتئین می‌تواند در چندین فرآیند زیستی مختلف مشارکت داشته باشد، بسیاری از مجموعه‌های پروتئینی دارای هم‌پوشانی هستند، بنابراین الگوریتم مورد نظر باید قادر به شناسایی مجموعه‌های پروتئینی هم‌پوشان نیز باشد.

اگرچه بسیاری از پژوهش‌های پیشین تنها با تکیه بر ساختار شبکه‌های PPI و بدون در نظر گرفتن ویژگی‌های شناخته‌شده پروتئین‌ها، الگوریتم‌های کلاسیکی را برای شناسایی پیمانه‌های عملکردی ارائه کرده‌اند، اما با پیشرفت‌های اخیر در حوزه هوش مصنوعی و الگوریتم‌های یادگیری ماشین، به‌ویژه یادگیری عمیق، ضرورت بررسی توانمندی شبکه‌های عصبی، به‌خصوص شبکه‌های عصبی گرافی، در این زمینه بیش از پیش احساس می‌شود. هرچند در برخی مطالعات، ترکیبی از روش‌های کلاسیک و شبکه‌های عصبی مورد استفاده قرار گرفته است، اما تاکنون یک رویکرد کاملاً مبتنی بر یادگیری عمیق و به صورت یکپارچه[2] به طور جدی مورد توجه قرار نگرفته است.

در مجموع، هدف این پژوهش ارائه یک الگوریتم گراف‌محور برای کشف مجموعه‌های پروتئینی و پیمانه‌های عملکردی هم‌پوشان در شبکه‌های PPI، با بهره‌گیری هم‌زمان از ساختار شبکه و داده‌های

[1] Attributed graph clustering

[2] End-to-end

تکمیلی استخراج شده از پایگاه‌های داده زیستی، در قالب چارچوب خوشه‌بندی گراف‌های دارای گره‌های ویژگی‌دار است. در ادامه، اهمیت موضوع، پرسش‌های اصلی پژوهش و روش پیشنهادی به صورت خلاصه مورد بررسی قرار خواهند گرفت.

۳.۱ اهمیت و ضرورت انجام پژوهش

در حال حاضر زیست شناسان توجه خود را از مطالعه ساختار و عملکرد انفرادی پروتئین‌ها به سمت مطالعه‌ی ساختاری و عملکردی مجموعه‌های پروتئینی تغییر داده‌اند و مولکول‌های پروتئین‌ها را درون یک شبکه‌ی زیستی کلی بررسی می‌کنند [۱۳]. دلیل این موضوع این است که بررسی یک پروتئین باید در ارتباط با سایر پروتئین‌ها و مجموعه‌های پروتئینی که به آن‌ها تعلق دارد، انجام شود. از سوی دیگر، جهش‌های موجود در DNA می‌توانند نحوه‌ی برهم‌کنش پروتئین‌ها را در یک مجموعه‌ی پروتئینی تغییر دهند و به این ترتیب باعث تغییر در عملکرد و رفتار آن مجموعه شوند. این تغییرات نقش مهمی در بررسی فرآیند توسعه داروها و همچنین شناخت علل بروز بیماری‌ها دارند [۱۴]. به عنوان مثال پژوهش [۱۵] نشان داده است که برخی از بیماری‌های ژنتیکی به وسیله پروتئین‌هایی با برهم‌کنش‌های عملکردی مشابه به وجود می‌آیند. همچنین مجموعه‌های پروتئینی به واسطه ارتباط‌شان با مسیرهای زیستی[1]، برای فهم بهتر نحوه‌ی توزیع، جذب، متابولیسم و دفع دارو ضروری هستند. از این روی شناسایی مجموعه‌های پروتئینی برای کشف و توسعه‌ی داروها اهمیت زیادی دارند. با وجود اهمیت کشف مجموعه‌های پروتئینی، چالش اصلی زمان‌بر و هزینه‌بر بودن فرآیند کشف آن‌ها در آزمایشگاه است که سبب توجه بیشتر محققان به روش‌های محاسباتی جهت کشف پیمانه‌های عملکردی شده است [۵].

[1] Pathway

۴.۱ پرسش‌های پژوهش

در این پژوهش تلاش می‌شود به پرسش‌های زیر پاسخ داده شود:

- کدام جنبه‌ها از مسئله شناسایی پیمانه‌های عملکردی در شبکه‌های PPI تاکنون کمتر مورد توجه پژوهشگران قرار گرفته‌اند؟
- آیا بهره‌گیری از ویژگی‌های زیستی مرتبط می‌تواند به شناسایی دقیق‌تر پیمانه‌های عملکردی کمک کرده و عملکرد روش‌های محاسباتی موجود را بهبود دهد؟
- ویژگی‌های زیستی شناخته‌شده برای ژن‌های کدکننده پروتئین‌ها که از منابع داده‌ای نظیر GO استخراج می‌شوند، چگونه باید در فرآیند مدل‌سازی به‌طور مؤثر مورد استفاده قرار گیرند؟
- با توجه به ماهیت گرافی شبکه‌های تعامل پروتئین_پروتئین، استفاده از روش‌های یادگیری عمیق گرافی تا چه میزان می‌تواند به بهبود عملکرد روش‌های شناسایی پیمانه‌های عملکردی کمک کند؟
- با وجود ارائه برخی روش‌های مبتنی بر شبکه‌های عصبی گرافی برای شناسایی پیمانه‌های عملکردی، تاکنون رویکردی یکپارچه برای این مسئله ارائه نشده است. آیا ارائه یک چارچوب یکپارچه می‌تواند منجر به بهبود عملکرد مدل در این زمینه شود؟

۵.۱ نوآوری‌های پژوهش

پژوهش حاضر به‌طور خاص به بررسی کارایی شبکه‌های عصبی گرافی در شناسایی پیمانه‌های عملکردی در شبکه‌های PPI می‌پردازد. نوآوری‌ها و دستاوردهای اصلی این پژوهش را می‌توان به صورت زیر بیان کرد:

- مطالعات انجام شده در این حوزه به منظور بررسی استفاده از شبکه‌های عصبی گرافی برای

شناسایی پیمانه‌های عملکردی بسیار محدود هستند. در این پژوهش، سعی شده است مؤلفه‌های مؤثر در مدل‌سازی، از جمله ساختار شبکه، نوع ویژگی‌های ورودی و توابع فعال‌سازی، به‌صورت سیستماتیک مورد بررسی و ارزیابی قرار گیرند.

- بررسی امکان ترکیب ویژگی‌های دودویی و تعبیه‌های Node2Vec به‌منظور ارتقای عملکرد شبکه‌های عصبی گرافی در فرآیند شناسایی پیمانه‌های عملکردی.
- ارائه یک چارچوب یکپارچه مبتنی بر شبکه‌های عصبی گرافی برای شناسایی پیمانه‌های عملکردی در شبکه‌های PPI.
- ارائه دو نسخه تغییریافته از تابع هزینه NOCD با هدف افزایش دقت در شناسایی پیمانه‌های عملکردی.
- ارائه روشی که با در نظر گرفتن هم‌پوشانی میان پیمانه‌های عملکردی و استفاده از یک آستانه تجمیعی، منجر به بهبود عملکرد روش پیشنهادی می‌شود.

۶.۱ جمع‌بندی

در این فصل به تعریف مسئله پژوهش و اهمیت آن پرداختیم. همچنین به صورت کلی روش پیشنهادی و سوالات پیش‌روی پژوهش را مورد بررسی قرار دادیم.

در ادامه، در فصل دوم به مبانی پایه مورد نیاز جهت فهم بهتر پژوهش اشاره خواهد شد. فصل سوم به معرفی پژوهش‌های پیشین که در زمینه شناسایی پیمانه‌های عملکردی و مجموعه پروتئینی بر پایه روش‌های محاسباتی هستند اختصاص دارد. فصل چهارم مربوط به روش‌شناسی پژوهش است که در ابتدا داده‌های استفاده شده در این پژوهش سپس روش پیشنهادی خود را مطرح می‌کنیم. در فصل پنجم، به بررسی پیاده‌سازی روش پیشنهادی و نتایج حاصل بر اساس معیارهای ارزیابی می‌پردازیم. همچنین عملکرد روش پیشنهادی را با دیگر روش‌های پیشین مقایسه کرده و برتری روش خود را شرح

می‌دهیم. در نهایت، در فصل آخر، پژوهش حاضر را جمع‌بندی می‌کنیم و ایده‌هایی را برای ادامه مسیر این پژوهش مطرح می‌کنیم.

فصل ۲

مفاهیم بنیادی

۱.۲ مقدمه

در این فصل، مفاهیم بنیادی و پیش نیازهایی که برای درک بهتر پژوهش حاضر ضروری هستند معرفی می‌شوند. از آنجا که این پایان‌نامه در تقاطع علوم زیستی و روش‌های محاسباتی قرار دارد، آشنایی با مفاهیم هر دو حوزه برای دنبال کردن مطالب فصل‌های بعدی اهمیت ویژه‌ای دارد. بر همین اساس، در بخش نخست این فصل، مفاهیم زیستی مرتبط با موضوع پژوهش مورد بررسی قرار می‌گیرند. سپس در بخش دوم، به معرفی مفاهیم محاسباتی مورد استفاده پرداخته می‌شود و تمرکز اصلی بر مباحث مرتبط با شبکه‌های عصبی گرافی و چارچوب‌های یادگیری مبتنی بر گراف خواهد بود. در نهایت، در بخش پایانی این فصل، معیارهای ارزیابی به‌کاررفته در این پژوهش برای سنجش کیفیت شناسایی پیمانه‌های عملکردی معرفی شده و به‌طور خلاصه تشریح می‌شوند تا زمینه لازم برای تحلیل نتایج در فصل‌های بعدی فراهم شود.

۲.۲ مفاهیم زیستی

در این پژوهش، یک روش محاسباتی به‌منظور شناسایی مجموعه‌های پروتئینی ارائه می‌شود. در این راستا، با برخی مفاهیم زیستی مرتبط مواجه می‌شویم که در این بخش، توضیحات مختصر و روشنی از هر یک با هدف تسهیل درک موضوع پژوهش ارائه شده است.

۱.۲.۲ پروتئین

پروتئین‌ها از مهم‌ترین درشت مولکول‌های زیستی در سلول‌های زنده به‌شمار می‌آیند که از تکرار واحدهای اسید آمینه ساخته شده‌اند و نقش‌های حیاتی و متنوعی را در ساختار و عملکرد سلول ایفا می‌کنند. این مولکول‌ها به‌طور ویژه به عنوان کارگزاران مولکولی سلول شناخته می‌شوند، زیرا در فرآیندهایی مانند کاتالیز واکنش‌های شیمیایی (از طریق آنزیم‌ها)، انتقال مولکول‌ها، پیام‌رسانی درون سلولی، ایجاد حرکت و حفظ یکپارچگی ساختار سلولی نقش اساسی دارند. توالی اسیدهای آمینه هر پروتئین توسط ژن مربوطه تعیین شده و طی فرآیند ترجمه از روی RNA پیام‌رسان [1] ایجاد می‌شود. سپس پروتئین‌ها از طریق فرآیند تاخوردگی[2] به ساختارهای سه‌بعدی مشخصی دست می‌یابند که برای عملکرد زیستی آن‌ها ضروری است. ویژگی‌های عملکردی هر پروتئین به ترتیب خاص اسیدهای آمینه و برهم‌کنش‌های فضایی میان آن‌ها وابسته است. گستردگی و تنوع عملکردهای پروتئین‌ها به‌گونه‌ای است که تقریباً تمامی فرآیندهای زیستی سلول، به‌صورت مستقیم یا غیرمستقیم، تحت تأثیر یا کنترل آن‌ها قرار دارند [۱۶].

۲.۲.۲ پیمانه‌های عملکردی

فعالیت‌های زیستی در سلول و به‌طور کلی در بدن، معمولاً حاصل عملکرد یک پروتئین منفرد نیستند، بلکه نتیجه‌ی همکاری هماهنگ مجموعه‌ای از پروتئین‌ها می‌باشند که به‌صورت سازمان یافته با یکدیگر

[1] mRNA: messenger ribonucleic acid

[2] Folding

در ارتباط هستند. این پروتئین‌ها از طریق تعاملات مختلف، به‌ویژه تعاملات فیزیکی، در انجام یک یا چند وظیفه‌ی زیستی مشخص مشارکت می‌کنند [۵].



شکل ۱.۲: پیمانه‌های عملکردی موجود در یک شبکه تعامل پروتئین_پروتئین، این تصویر انتزاعی هفت پیمانه هم‌پوشان را نمایش می‌دهد.

به چنین مجموعه‌ای از پروتئین‌ها که به‌صورت هماهنگ برای انجام یک عملکرد زیستی مشترک عمل می‌کنند، مجموعه‌ی پروتئینی یا پیمانه عملکردی گفته می‌شود. هر پیمانه عملکردی معمولاً بیانگر یک فرآیند زیستی، مسیر مولکولی یا سازوکار تنظیمی خاص در سلول است و اجزای آن، از نظر عملکردی به یکدیگر وابسته‌اند [۱۷].

تعامل فیزیکی میان پروتئین‌ها که تحت عنوان تعامل پروتئین_پروتئین شناخته می‌شود، نقش محوری در شکل‌گیری و پایداری این پیمانه‌های عملکردی ایفا می‌کند. این تعاملات امکان انتقال سیگنال، تنظیم فعالیت‌های آنزیمی و هماهنگی زمانی و مکانی پروتئین‌ها را فراهم می‌سازند و از این رو، برای درک صحیح بسیاری از فعالیت‌های زیستی ضروری هستند [۱۸].

از جمله فرآیندهای زیستی مهمی که مبتنی بر پیمانه‌های عملکردی هستند می‌توان به رونوشت DNA، رونوشت RNA پیام‌رسان و تنظیم چرخه سلولی اشاره کرد. در هر یک از این فرآیندها، گروه مشخصی از پروتئین‌ها به‌صورت شبکه‌ای از تعاملات عمل می‌کنند و اختلال در هر یک از اجزای این شبکه می‌تواند منجر به بروز نقص عملکردی در کل فرآیند شود.

در سال‌های اخیر، پیشرفت در شناسایی و تحلیل پیمانه‌های عملکردی، به یکی از موضوعات مهم در زیست‌شناسی سامانه‌ای و زیست‌انفورماتیک تبدیل شده است. شناسایی دقیق این پیمانه‌ها کاربردهای گسترده‌ای از جمله پیش‌بینی عملکرد پروتئین‌های ناشناخته [۱۹]، درک سازوکارهای مولکولی بیماری‌ها [۲۰] و کشف اهداف دارویی جدید [۲۱] دارد. از این رو، مطالعه و مدل‌سازی پیمانه‌های عملکردی نقش کلیدی در توسعه‌ی روش‌های نوین تشخیصی و درمانی ایفا می‌کند.

۳.۲.۲ بیان ژن

بیان ژن[1] فرآیندی است که طی آن اطلاعات نهفته در توالی DNA به محصولات عملکردی، عمدتاً RNA و پروتئین، تبدیل می‌شود. این فرآیند شامل مراحل متعددی از جمله رونوشت DNA به RNA و در بسیاری از موارد ترجمه RNA به پروتئین است و نقش اساسی در تعیین ساختار، عملکرد و رفتار سلول ایفا می‌کند. سطح بیان هر ژن نشان‌دهنده میزان فعالیت آن ژن در یک شرایط زیستی خاص بوده و به‌طور دقیق تحت تأثیر سازوکارهای تنظیمی مختلفی مانند عوامل رونویسی، تغییرات اپی‌ژنتیکی و سیگنال‌های درون‌سلولی و برون‌سلولی قرار دارد. تفاوت در الگوهای بیان ژن میان سلول‌ها، بافت‌ها یا شرایط فیزیولوژیک و پاتولوژیک مختلف، عامل اصلی تنوع عملکردی سلول‌ها محسوب می‌شود. از این رو، تحلیل داده‌های بیان ژن ابزار مهمی برای درک فرآیندهای زیستی، شناسایی مسیرهای مولکولی مختل‌شده در بیماری‌ها و استخراج نشانگرهای زیستی به‌شمار می‌رود [۲۲].

[1] Gene expression

۴.۲.۲ پایگاه داده هستی‌شناسی ژن

پایگاه داده هستی‌شناسی ژن یک بانک داده و سیستم طبقه‌بندی است که با هدف ایجاد یک زبان استاندارد برای توصیف ژن‌ها و محصولات ژنی (که پروتئین‌ها نیز جزو آنها هستند) ایجاد شده است. این پروژه اطلاعات ساختاریافته و قابل پرداش از فرآیندهای زیستی، عملکرد مولکولی و مؤلفه‌ی سلولی ژن‌ها فراهم می‌کند. داده‌های پروژه GO به صورت گسترده‌ای در تحقیقات مربوط به علوم زیستی مورد استفاده قرار می‌گیرد و همینطور همواره اطلاعات آن از نظر کمیت و کیفیت درحال تغییر است [۱].

Accession GO:0016597
Name amino acid binding
Ontology molecular_function
Synonyms None
Alternate IDs None
Definition Interacting selectively and non-covalently with an amino acid, organic acids containing one or more amino substituents. *Source:* GOC:ai
Comment None
History See term history for GO:0016597 at QuickGO
Subset goslim_metagenomics
goslim_pir
Related Link to all **genes and gene products** annotated to amino acid binding.
Link to all direct and indirect **annotations** to amino acid binding.
Link to all direct and indirect **annotations download** (limited to first 10,000) for amino acid binding.

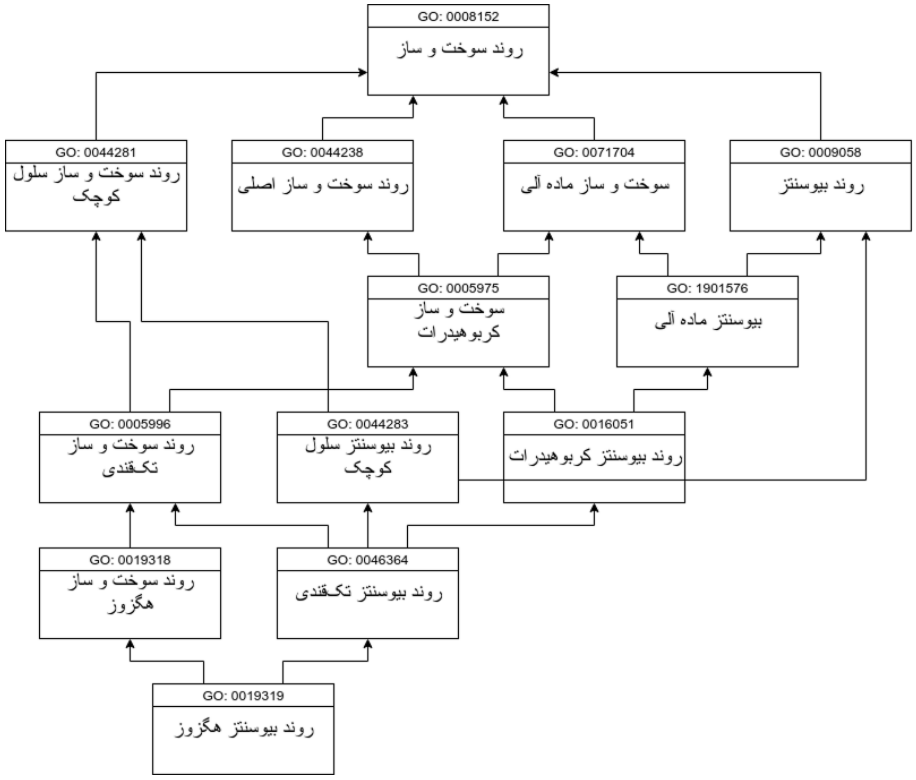
شکل ۲.۲: ویژگی‌های عبارت GO:0016597 [۱]

هر عبارت GO شامل موارد زیر می‌شود:

- یک نام که برای انسان قابل فهم باشد.
- یک شناساگر مختص آن عبارت که با پیشوند :GO آغاز می‌شود.
- یک تعریف مختصر از مفاهیمی که توسط این عبارت GO نمایش داده می‌شود.
- ارتباط آن با سایر عبارات GO ، که در گراف GO هر عبارت (به جز عبارات ریشه‌ای) فرزند یک عبارت GO دیگر است.

اطلاعات موجود در بانک داده GO به صورت ساختمان داده گرافی ذخیره شده‌اند. هر عبارت دارای

یک یا چند فرزند است که در نتیجه ساختار گراف GO، یک گراف جهت‌دار سلسله مراتبی[1] است .



شکل ۳.۲: ساختار هستی‌شناسی ژن [۱]

گراف GO شامل چهار نوع یال `is_a`، `part_of`، `regulates` و `has_part` است که هر یک به‌ترتیب بیانگر رابطه «نوعی از»، «جزئی از»، «نقش تنظیم‌کنندگی» و «دارا بودن جزء» میان مفاهیم مختلف در این هستی‌شناسی می‌باشند [۲۳]. این سیستم شامل سه زیرگراف جهت‌دار اصلی است که هر یک از آنها جنبه‌ی خاصی از عملکرد زیستی را توصیف می‌کنند:

- **فرآیند زیستی**[2] : این بخش به فرآیندهای زیستی اشاره دارد که ژن و یا پروتئین خاصی در آن نقش دارد.

[1] Directed hierarchical graph

[2] Biological process

- **عملکرد مولکولی**[1] : این بخش عملکرد دقیق مولکولی ژن یا پروتئین را توصیف می‌کند.
- **مؤلفه سلولی**[2] : این بخش به مکانی که ژن یا پروتئین در آن قرار دارد اشاره می‌کند. از ویژگی‌های دیگر این بانک داده نمایش اطلاعات به صورت سازماندهی شده و سلسله مراتبی است که شامل شبکه‌های بدون دور می‌شود و ویژگی‌ها به این صورت مرتب شده‌اند [۱۰].

۵.۲.۲ شبکه‌های PPI و ویژگی‌های آنها

یک شبکه‌ی PPI معمولا به صورت یک گراف بدون جهت $G = (V, E)$ نشان داده می‌شود که V و E به ترتیب نمایانگر پروتئین‌ها و تعاملات بین آنها می‌باشند. وزن‌های روی یال‌ها را می‌توان برای توصیف ویژگی‌های شبکه PPI، مانند ویژگی‌های توپولوژیکی یا عملکردی استفاده کرد. شبکه‌های PPI سه ویژگی توپولوژیکی زیر را دارند:

- توزیع بدون مقیاس[3] : $P(k)$ مفهوم توزیع درجه یعنی احتمال اینکه یک گره در یک شبکه دقیقاً k پیوند داشته باشد را نشان می‌دهد. یک شبکه PPI دارای توزیع درجه توانی $P(k) \sim k^{-\lambda}$ می‌باشد [۲۴] . این ویژگی به این معنی است که پروتئین‌های تعامل‌دار در شبکه‌های PPI به طور یکنواخت توزیع نمی‌شوند، بیشتر پروتئین‌ها تنها در چند تعامل شرکت می‌کنند در حالی که مجموعه کوچکی از پروتئین‌ها در ده‌ها تعامل (تشکیل گره هاب[4]) شرکت می‌کنند.
- ویژگی جهان کوچک[5] : پروتئین‌های یک شبکه PPI دارای میانگین طول مسیر کم و ضرایب خوشه‌ای بالا هستند [۲۵] که سیگنال‌های هر گره در شبکه PPI را قادر می‌سازد تا از طریق چند جهش به سرعت به هر گره دیگری برسند. در نتیجه شبکه‌های PPI هم زمان انتقال سیگنال و

[1] Molecular function
[2] Cellular component
[3] Scale free distribution
[4] Hub
[5] Small world property

هم زمان پاسخ کوتاهی خواهند داشت.

- شبکه با پیمانه‌های عملکردی[1] : شبکه PPI یک شبکه پیمانه‌ای و سلسله مراتبی می‌باشد. یک پیمانه عملکردی در یک شبکه PPI یک مجموعه با بیشترین تعداد پروتئین که عملکرد یکسانی دارند، می‌باشد. بارزترین مشخصه پیمانه عملکردی، ارتباط بین ساختار توپولوژیکی شبکه PPI و عملکرد پروتئین‌های آن است که مبنای بسیاری از روش‌های تشخیص پیمانه عملکردی است [۲۶].

۳.۲ مفاهیم محاسباتی

در این بخش، مفاهیم محاسباتی مورد استفاده در این پایان‌نامه معرفی می‌شوند. از آن‌جا که روش پیشنهادی این پژوهش بر پایه‌ی تحلیل شبکه‌ها و یادگیری عمیق استوار است، آشنایی با مبانی نظری مرتبط با گراف‌ها، الگوریتم‌های یادگیری عمیق و شبکه‌های عصبی گرافی برای درک بهتر مراحل روش ارائه شده ضروری است. بدین منظور، در ادامه مروری اجمالی بر مفاهیم و تعاریف اصلی ارائه می‌شود تا چارچوب محاسباتی پژوهش به‌صورت منسجم و شفاف تبیین گردد.

۱.۳.۲ یادگیری ماشین

یادگیری ماشین[2] یکی از شاخه‌های هوش مصنوعی[3] است که به رایانه‌ها امکان می‌دهد بدون تعریف صریح قوانین، الگوها و روابط موجود در داده‌ها را شناسایی کرده و بر اساس آن‌ها به پیش‌بینی یا تصمیم‌گیری بپردازند. در این رویکرد، مدل‌ها با استفاده از داده‌های آموزشی، دانش لازم را استخراج کرده و قادر خواهند بود این دانش را به داده‌های جدید تعمیم دهند. امروزه یادگیری ماشین در بسیاری

[1] Functional modular network
[2] Machine learning
[3] Artificial intelligence

از حوزه‌های پژوهشی و صنعتی مورد استفاده قرار می‌گیرد. به‌طور کلی، روش‌های یادگیری ماشین به سه دسته اصلی یادگیری نظارت‌شده[1]، یادگیری بدون نظارت[2] و یادگیری تقویتی[3] تقسیم می‌شوند که هر یک متناسب با نوع داده‌ها و هدف مسئله به‌کار گرفته می‌شوند [۲۷].

۲.۳.۲ یادگیری عمیق

یادگیری عمیق را می‌توان یکی از زیرشاخه‌های یادگیری ماشین دانست که بر پایه‌ی مدل‌هایی با چندین لایه‌ی پردازشی بنا شده است. این مدل‌ها معمولاً از لایه‌های متصل به‌هم یا لایه‌های پیچیده‌تر تشکیل می‌شوند و به‌دلیل ساختار چند لایه‌ی خود، دارای تعداد پارامترهای قابل یادگیری بیشتری نسبت به الگوریتم‌های کلاسیک یادگیری ماشین هستند. همین ویژگی موجب می‌شود که یادگیری عمیق توانایی بالاتری در مدل‌سازی روابط پیچیده میان داده‌ها داشته باشد.

تفاوت اصلی یادگیری عمیق با روش‌های سنتی یادگیری ماشین در نحوه‌ی استخراج ویژگی‌ها است. در الگوریتم‌های کلاسیک، ویژگی‌ها معمولاً به‌صورت دستی و با دخالت متخصص تعیین می‌شوند، در حالی که روش‌های یادگیری عمیق قادرند با توجه به داده‌های موجود و ماهیت مسئله، ویژگی‌های مناسب را به‌صورت خودکار استخراج کنند. این قابلیت باعث شده است که یادگیری عمیق در مسائل پیچیده و داده‌محور عملکرد بهتری از خود نشان دهد [۲۸].

۳.۳.۲ یادگیری نظارت‌شده

یادگیری نظارت‌شده یکی از رایج‌ترین انواع یادگیری ماشین است که در آن الگوریتم با استفاده از داده‌های ورودی به‌همراه برچسب[4] متناظر با هر نمونه آموزش می‌بیند. هدف از این فرآیند، ساخت

---

1 Supervised learning
2 Unsupervised learning
3 Reinforcement learning
4 Label

مدلی است که بتواند رابطه میان داده‌ها و برچسب‌ها را آموخته و برای داده‌های جدید و دیده نشده عملکرد مناسبی داشته باشد. در این نوع یادگیری، داده‌ها معمولاً به دو مجموعه‌ی آموزشی[1] و آزمایشی[2] تقسیم می‌شوند، بدین‌صورت که مدل با استفاده از داده‌های آموزشی ساخته شده و سپس با داده‌های آزمایشی مورد ارزیابی قرار می‌گیرد. به بیان ساده، وجود برچسب در کنار هر داده، ویژگی اصلی یادگیری نظارت‌شده محسوب می‌شود [۲۹].

۴.۳.۲ یادگیری بدون نظارت

یادگیری بدون نظارت نوعی از یادگیری ماشین است که در آن الگوریتم‌ها با داده‌های بدون برچسب سروکار دارند و هدف اصلی آن‌ها کشف الگوها و ساختارهای پنهان موجود در داده‌ها است. برخلاف یادگیری نظارت‌شده، در این روش اطلاعاتی از خروجی مطلوب در اختیار مدل قرار نمی‌گیرد و الگوریتم تلاش می‌کند بر اساس شباهت‌ها و ویژگی‌های ذاتی داده‌ها، آن‌ها را سازمان‌دهی کند. از شناخته‌شده‌ترین الگوریتم‌های یادگیری بدون نظارت می‌توان به روش‌های خوشه‌بندی اشاره کرد که با هدف قرار دادن داده‌های مشابه در خوشه‌های یکسان به‌کار می‌روند [۳۰].

۵.۳.۲ گراف

یک گراف از مجموعه‌ای غیر خالی از اشیا به نام رأس تشکیل شده، که آن را با V نشان می‌دهیم، و مجموعه‌ای شامل یال‌ها، که رأس‌ها را به هم وصل می‌کنند و با E نمایش می‌دهیم. یک چنین گرافی را با $G = (V, E)$ نشان می‌دهیم. اگر یال e دو رأس v_1 و v_2 را به هم وصل کند می‌نویسیم $e = \{v_1, v_2\}$ [۳۱]. تعریف ارائه شده، تعریف گراف ساده است. اما انواع مختلفی از گراف موجود می‌باشد که در ادامه به بررسی دو نوع از آن‌ها (گراف جهت‌دار و گراف وزن‌دار) می‌پردازیم:

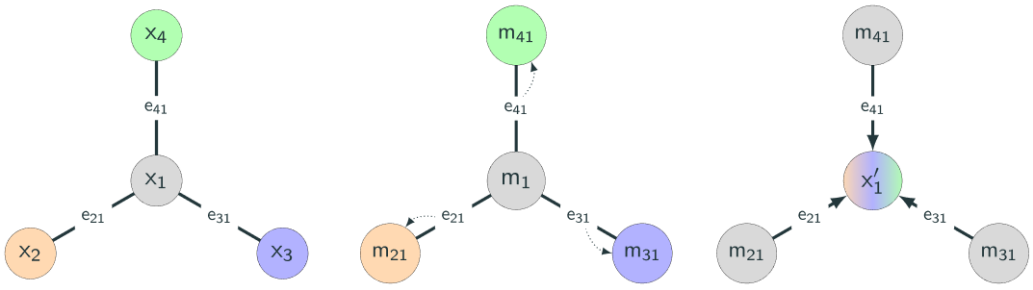
[1] Train dataset

[2] Test dataset

- **گراف جهت‌دار**: گراف $G = (V, E)$ زمانی جهت‌دار است که مجموعه E، از جفت اعضایی همانند $u, v \in V$; (u, v) تشکیل شده باشد و ترتیب این دوتایی‌ها نشان‌دهنده جهت یال مربوطه باشد. به این صورت برای هر یال جهت نیز درنظر گرفته می‌شود که به گراف حاصل، گراف جهت‌دار می‌گوییم.
- **گراف وزن‌دار**: گراف $G = (V, E, W)$ که $W \in R^{|E|}$ یک مقدار عددی به هر یک از یال‌ها اختصاص می‌دهد که میزان وزن آن یال است.

۶.۳.۲ شبکه‌های عصبی گرافی

شبکه‌های عصبی گرافی[1] اولین بار در سال ۲۰۰۵ پیشنهاد شدند [۳۲]. شبکه‌های عصبی گرافی، دسته‌ای از شبکه‌های عصبی هستند که برای مدیریت داده‌های سازمان‌دهی شده در ساختارهای گراف طراحی شده‌اند. شبکه‌های عصبی گرافی بر پایه سازوکار انتقال پیام[2] هستند.



شکل ۴.۲: شماتیک سازوکار انتقال پیام در شبکه‌های عصبی گرافی [۲]

[1] Graph neural networks - GNNs

[2] Message passing

در ابتدا یک گراف با ماتریس ویژگی گره‌ها $X \in R^{|V| \times d}$ به عنوان ورودی در نظر گرفته می‌شود که $|V|$ تعداد گره‌های گراف و d بعد ویژگی‌های گراف می‌باشد. در شبکه‌های عصبی گرافی از این ویژگی‌ها در کنار ساختار گراف برای تولید بازنمایی‌های هر گره استفاده می‌شود. در هر تکرار، هر گره اطلاعاتی را از گره‌های همسایگی خود جمع‌آوری می‌کند که این عمل را به صورت کلی جمع‌آوری[1] می‌نامند. در مرحله بعد شبکه باید اطلاعات جمع‌آوری شده را با اطلاعات موجود گره ادغام کند و بازنمایی جدیدی از گره مورد نظر ارائه دهد. به صورت کلی این مرحله از انتقال پیام را نیز به‌روزرسانی[2] می‌نامند. به طورخلاصه در یکبار انتقال پیام مراحل به صورت معادله ۱.۲ انجام می‌شود.

$$h_u^{(k+1)} = UPDATE^{(k)}(h_u^{(k)}, AGGREGATE(\{h_v^{(k)}, \forall_v \in N(u)\})) \qquad (۱.۲)$$

در معادله ۱.۲ نمادهای AGGREGATE و UPDATE، دو تابع دلخواه مشتق‌پذیر (به عنوان مثال یک شبکه عصبی) هستند و $N(u)$ نشانگر مجموعه همسایگان گره u است. همچنین $h_u^{(k)}$ نشان‌دهنده بازنمایی گره u در مرحله kام است.

با افزایش این مراحل، بازنمایی هر گره داده‌های بیشتری از گره‌های دورتر از خود در گراف خواهد داشت. پس از اولین تکرار ($k = ۱$)، هر بازنمایی گره اطلاعات مربوز به همسایگی تک گامی خود را حفظ می‌کند، که ممکن است در گراف از طریق مسیری به طول ۱ قابل دسترسی باشد [۳۳]. بعد از دومین تکرار ($k = ۲$)، بازنمایی هر گره شامل اطلاعاتی از همسایگی با دو گام است، به طور کلی، پس از k مرحله، بازنمایی هر گره می‌تواند شامل داده‌هایی از گره‌هایی با فاصله $k - hop$ از خود باشد. براساس سازوکار انتقال پیام در شبکه‌های عصبی گرافی، این شبکه‌ها در تولید بازنمایی‌هایی که هم اطلاعات مربوط به ساختار گراف و هم ویژگی‌های گره‌ها را حفظ کنند بسیار موفق بوده‌اند. به همین دلیل در بسیاری از مسائل مورد استفاده قرار گرفته‌اند. بنابر توابع استفاده شده به عنوان تابع

[1] Aggregate
[2] Update

جمع‌آوری و به‌روزرسانی، شبکه‌های عصبی گرافی به انواع مختلفی همانند شبکه‌های عصبی گرافی پیچشی، شبکه‌های عصبی گرافی توجه محور و دیگر دسته‌ها تقسیم بندی می‌شوند [۳۴].

۷.۳.۲ شبکه‌های عصبی گرافی پیچشی

پژوهش کیف و ولینگ [۳۵] با هدف ارائه مدلی ساده، مقیاس‌پذیر و قابل‌اجرا برای یادگیری روی گراف‌های بزرگ، شبکه‌های عصبی گرافی پیچشی[1] را معرفی کرد. روش‌های طیفی پیشین مبتنی بر تجزیه‌ی لاپلاسین گراف بوده و نیازمند محاسبه‌ی مقادیر ویژه و بردارهای ویژه بودند که این امر هزینه‌ی محاسباتی بالایی داشته و استفاده از آن‌ها را در گراف‌های بزرگ محدود می‌کرد. در شبکه گرافی پیشنهادی، ویژگی‌ها از همسایگان به‌صورت محلی و با وزن‌دهی مشترک تجمیع می‌شوند و پس از ضرب در ماتریس وزن قابل‌آموزش و اعمال تابع فعال‌ساز، خروجی هر لایه طبق معادله ۲.۲ محاسبه می‌گردد. این ساختار از آن رو پیچشی نامیده می‌شود که همانند کانولوشن در شبکه‌های عصبی کلاسیک، بر یادگیری الگوهای محلی با پارامترهای مشترک استوار است.

$$H^{(k+1)} = \sigma(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}H^{k}W^{k}) \qquad (۲.۲)$$

در اینجا، $\tilde{A} = A + I_N$ ماتریس مجاورت گراف بدون جهت G با در نظر گرفتن یال‌های خودی[2] است. I_N ماتریس همانی بوده و $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$ عناصر قطری ماتریس درجه متناظر را تشکیل می‌دهد. همچنین، $W^{(k)}$ یک ماتریس وزن قابل‌آموزش مخصوص لایه kام است. تابع $\sigma(\cdot)$ نشان‌دهنده یک تابع فعال‌سازی است که برای مثال می‌تواند تابع ReLU به‌صورت $\mathrm{ReLU}(\cdot) = \max(0, \cdot)$ باشد. ماتریس $H^{(k)} \in \mathbb{R}^{N \times D}$ نمایش‌دهنده فعال‌سازی‌ها در لایه kام بوده و $H^{(0)} = X$ به‌عنوان ورودی اولیه شبکه در نظر گرفته می‌شود که X ماتریس ویژگی گره‌ها است. با توجه به تعریف ارائه شده در بخش شبکه‌های

[1] Graph convolutional networks-GCN

[2] Self connections

عصبی گرافی و سازوکار انتقال پیام، توابع AGGREGATE و UPDATE، به ترتیب از معادله‌های $S = \tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}H^{(k)}$ و $\sigma(SW^{(k)})$ پیروی می‌کنند.

با وجود سادگی و کارایی بالا، شبکه‌های عصبی گرافی پیچشی دارای محدودیت‌هایی نیز هستند. از جمله این محدودیت‌ها می‌توان به پدیده‌ی هموارسازی بیش‌ازحد[1] در صورت افزایش تعداد لایه‌ها اشاره کرد که در آن بردار بازنمایی گره‌ها به مرور شباهت زیادی به یکدیگر پیدا می‌کنند و توان تفکیک مدل کاهش می‌یابد. علاوه براین، در این شبکه‌ها، تمامی گره‌های همسایه به یک اندازه در تشکیل بازنمایی جدید نقش دارند و این در حالی است که در بسیاری از گراف‌ها میزان اهمیت تمامی گره‌ها یکسان نیست. این محدودیت‌ها انگیزه‌ای برای توسعه‌ی مدل‌های پیشرفته‌تر شبکه‌های عصبی گرافی در پژوهش‌های بعدی بوده است.

۸.۳.۲ شبکه‌های عصبی گرافی توجه محور

ولیکویک و همکاران [۳]، با هدف رفع محدودیت‌های شبکه‌های عصبی گرافی پیچشی در تخصیص وزن یکسان به تمامی همسایه‌ها، مدل شبکه‌های عصبی گرافی با سازوکار توجه[2] را معرفی کردند. این مدل امکان یادگیری وزن‌های متفاوت برای هر یال همسایگی را فراهم می‌کند و بدین ترتیب اهمیت نسبی گره‌های همسایه در تشکیل بردار بازنمایی هر گره به صورت داده‌محور تعیین می‌شود. این ویژگی باعث می‌شود GAT توانایی مدل‌سازی پیچیدگی‌های ساختاری گراف‌هایی با ارتباطات غیرهمگن را داشته باشد، در حالی که GCN تمامی همسایه‌ها را با وزن یکسان در نظر می‌گیرد.

در GAT، انتقال پیام با استفاده از سازوکار توجه خودـ توجهی [3] در معادله ۳.۲ تعریف می‌شود.

[1] Over smoothing

[2] Graph attention network — GAT

[3] Self attention

$$h_i^{(k+1)} = \sigma\Big(\sum_{j \in \mathcal{N}(i)} \alpha_{ij} W h_j^{(k)} \Big) \tag{۳.۲}$$

که در آن، $h_i^{(k+1)}$ نمایش به‌روزشده گره i، $h_j^{(k)}$ ویژگی‌های گره همسایه j، W ماتریس وزن قابل‌آموزش و $\sigma(\cdot)$ تابع فعال‌سازی است. ضریب توجه α_{ij} اهمیت گره j را نسبت به گره i مشخص می‌کند و با استفاده از یک شبکه کوچک خطی و تابع LeakyReLU مطابق معادله ۴.۲ محاسبه می‌شود.

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(a^T [W h_i^{(k)} | W h_j^{(k)}]))}{\sum_{n \in \mathcal{N}(i)} \exp(\text{LeakyReLU}(a^T [W h_i^{(k)} | W h_n^{(k)}]))} \tag{۴.۲}$$

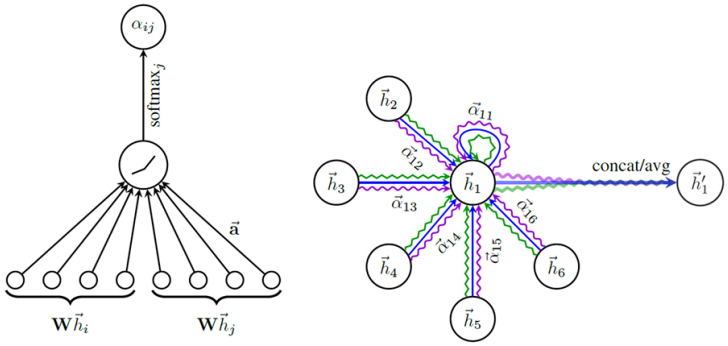
$$\text{LeakyReLU}(x) = \begin{cases} x, & x \geq ۰, \\ \lambda x, & x < ۰, \end{cases} \tag{۵.۲}$$

در معادله ۵.۲ که تابع فعال‌ساز LeakyReLU را نمایش می‌دهد، λ یک پارامتر دلخواه جهت تنظیم رفتار تابع فعال‌ساز در قسمت منفی محور مختصات است. در معادله ۴.۲ a بردار وزن قابل‌آموزش برای سازوکار توجه و | عملگر ادغام ویژگی‌های گره‌ها است. به این ترتیب، تابع AGGREGATE در GAT به صورت جمع وزنی گره‌های همسایه با ضرایب توجه بوده و تابع UPDATE شامل اعمال ماتریس وزن و تابع فعال‌سازی روی مقدار جمع وزنی شده است.

یکی از نوآوری‌های مهم GAT استفاده از توجه چندسر[1] است. در این روش، K سازوکار توجه مستقل بر روی همان لایه اعمال می‌شود و نتایج هر سر با هم ادغام می‌شوند (الحاق[2] یا میانگین‌گیری) تا نمایی غنی‌تر و پایدارتر از ویژگی‌های گره‌ها تولید شود که در معادله ۶.۲ نمایش داده شده است.

$$h_i^{(k+1)} = \Big\|_{m=1}^{M} \sigma\Big(\sum_{j \in \mathcal{N}(i)} \alpha_{ij}^{(m)} W^{(m)} h_j^{(k)} \Big) \tag{۶.۲}$$

استفاده از سازوکار توجه چند سر، علاوه بر افزایش ظرفیت مدل، باعث کاهش حساسیت شبکه به نویز و نوسانات محلی گراف می‌شود و کمک می‌کند تا مدل بتواند اطلاعات مفیدی از همسایگان مختلف در سطوح گوناگون استخراج کند.



شکل ۵.۲: سازوکار توجه در شبکه‌های عصبی گرافی [۳]

با وجود مزایای قابل‌توجه، GAT نیز محدودیت‌هایی دارد. پیچیدگی محاسباتی آن نسبت به GCN بالاتر است، به ویژه در گراف‌های بزرگ با درجه بالا. همچنین، انتخاب تعداد سرهای توجه و تنظیمات مربوط به آنها می‌تواند تأثیر زیادی بر عملکرد شبکه داشته باشد و نیازمند تنظیمات دقیق است. با این حال، GAT به‌خوبی امکان مدل‌سازی اهمیت متفاوت همسایگان، کاهش اثرات هموارسازی بیش‌ازحد و استخراج ویژگی‌های غیرهمگن را فراهم می‌کند و به همین دلیل در بسیاری از مسائل یادگیری روی

[1] Multi head attention

[2] Concat

گراف، نتایج بهتری نسبت به GCN ارائه می‌دهد.

۹.۳.۲ شبکه‌های عصبی گرافی با پرش دانش بین لایه‌ها

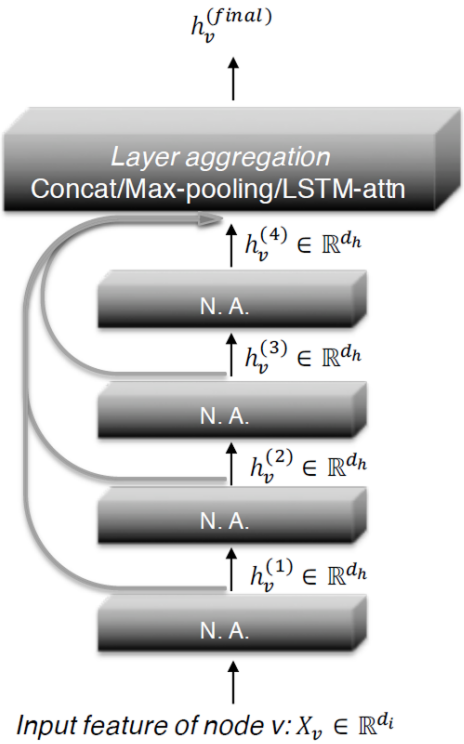
شبکه‌های عصبی گرافی با پرش دانش بین لایه‌ها[1] برای نخستین بار در پژوهش ژو و همکاران [۴] معرفی شدند. این پژوهش به یکی از چالش‌های اساسی در شبکه‌های عصبی گرافی اشاره می‌کند که ناشی از استفاده از بازنمایی‌های مبتنی بر فاصله‌های ثابت همسایگی برای تمام گره‌ها است. در چنین رویکردی، تمامی گره‌ها صرف‌نظر از موقعیت ساختاری خود در گراف، با تعداد یکسانی از لایه‌ها پردازش می‌شوند، در حالی‌که ساختار زیرگرافی گره‌ها می‌تواند به‌طور قابل‌توجهی با یکدیگر متفاوت باشد. نویسندگان این پژوهش بر این باورند که به‌منظور استخراج بازنمایی مناسب‌تر برای هر گره، لازم است مرتبه‌ی بازنمایی آن متناسب با ویژگی‌های ساختاری همان گره انتخاب شود. به بیان دیگر، برخی گره‌ها برای دستیابی به بازنمایی معنادار به اطلاعات محلی نیاز دارند، در حالی که برای برخی دیگر، بهره‌گیری از همسایگی‌های دورتر ضروری است.

برای نمونه، در پژوهش کیف و همکاران [۳۵] که منجر به معرفی شبکه‌های عصبی گرافی پیچشی شد، نتایج تجربی نشان می‌دهد که استفاده از دو لایه بهترین عملکرد را به همراه دارد. این در حالی است که از منظر تئوری، افزایش تعداد لایه‌ها باید امکان تجمیع اطلاعات گسترده‌تر و یادگیری بازنمایی‌های غنی‌تر را فراهم کند. این ناسازگاری بیانگر وجود محدودیت‌هایی در تعمیق شبکه‌های عصبی گرافی است. در حوزه‌ی بینایی ماشین، مشکل تعمیق شبکه‌ها با بهره‌گیری از سازوکار اتصال باقیمانده[2] تا حد زیادی برطرف شده است [۳۶]. با این حال، در شبکه‌های عصبی گرافی، حتی با وجود استفاده از اتصال‌های باقیمانده، مسئله‌ی هموار شدن بیش‌ازحد بازنمایی گره‌ها و محدودیت شعاع همسایگی هم‌چنان باقی می‌ماند. در همین راستا، ژو و همکاران با هدف رفع مشکل شعاع ثابت همسایگی و افزایش انعطاف‌پذیری در استخراج بردار بازنمایی گره‌ها، سازوکار پرش دانش بین لایه‌ها را پیشنهاد

[1] Jumping knowledge graph neural networks - JKNets

[2] Residual connection

کردند. این سازوکار امکان ترکیب تطبیقی اطلاعات حاصل از لایه‌های مختلف شبکه را برای هر گره فراهم می‌کند و بدین ترتیب، هر گره می‌تواند از سطح مناسبی از اطلاعات محلی یا سراسری بهره‌مند شود.



شکل ۶.۲: شماتیک پرش دانش در شبکه‌های عصبی گرافی [۴]

سازوکار پرش دانش بین لایه‌ها مستقل از نوع معماری بوده و قابلیت اعمال بر روی انواع شبکه‌های عصبی گرافی را دارد. با در نظر گرفتن بازنمایی‌های استخراج شده از لایه‌های مختلف شبکه برای گره v به‌صورت $h_v^{(۱)}, h_v^{(۲)}, \ldots, h_v^{(k)}$ ، این سازوکار اقدام به ترکیب این بازنمایی‌ها با استفاده از روش‌های مختلفی نظیر بیشینه‌گیری[۱]، الحاق[۲]، یا به‌کارگیری شبکه‌های حافظه‌ی کوتاه‌مدت بلندمدت مبتنی بر سازوکار توجه[۳] می‌کند. بدین ترتیب، بردار بازنمایی نهایی هر گره به‌صورت تطبیقی و متناسب با

[1] Max pooling
[2] Concatenation
[3] LSTM-attention

ساختار آن در گراف شکل می‌گیرد.

۱۰.۳.۲ تعبیه گره‌ها با روش Node2Vec

روش Node2Vec یک الگوریتم مقیاس‌پذیر[1] نیمه‌نظارتی[2] برای یادگیری ویژگی‌ها از روی گراف است. این الگوریتم به‌طور مستقیم از الگوریتم یادگیری تعبیه کلمات Word2Vec [۳۷] که در زمینه‌ی پردازش زبان طبیعی[3] استفاده می‌شود، ایده گرفته است. در این روش هدف تابع بهینه‌سازی، بیشینه کردن احتمال مشاهده‌ی گره‌های همسایه یک گره به شرط مشاهده‌ی خود آن گره است. هدف نهایی این الگوریتم یادگیری یک بردار تعبیه d بعدی برای هر گره است [۳۸]. این روش در ابتدا اقدام به جایگشت تصادفی بر روی گراف به کمک الگوریتم‌های نمونه برداری اول سطح[4] و اول عمق[5] می‌کند. انتخاب روش مناسب نمونه‌برداری از اهمیت بالایی برخوردار است. در نمونه‌برداری اول سطح، هدف اصلی استخراج تعبیه‌های مشابه برای گره‌هایی است که از قوانین ساختاری یکسانی پیروی می‌کنند، در حالی‌که نمونه‌برداری اول عمق بر ایجاد تعبیه‌های مشابه برای گره‌هایی تمرکز دارد که به‌صورت چگال به یکدیگر متصل هستند. در عمل، بهترین راهکار استفاده از یک روش ترکیبی است،

به‌گونه‌ای که بخشی از توالی‌ها با استفاده از نمونه‌برداری اول عمق و بخش دیگری با استفاده از نمونه‌برداری اول سطح تولید شوند. سپس یک شبکه‌ی عصبی آموزش داده می‌شود تا با استفاده از مشاهده‌ی مسیرهای پیشین، گره‌ی بعدی را پیش‌بینی کند (مشابه فرآیند آموزش در روش Word2Vec).

[1] Scalable
[2] Semi supervised
[3] Natural language processing - NLP
[4] Breadth first sampling - BFS
[5] Depth first sampling - DFS

بدین منظور، تابع هزینه[1] مطابق با معادله ۷.۲ تعریف می‌شود.

$$\max_{f} \sum_{u \in V} \log Pr(N_S(u) \mid f(u)) \tag{۷.۲}$$

تابع f به صورت $f : V \rightarrow R^d$ تعریف می‌شود که هر گره را به یک بردار تعبیه d بعدی نگاشت می‌کند. هدف تابع هزینه معادله ۷.۲ بیشینه کردن لگاریتم احتمال مشاهده گره‌های همسایه گره u به شرط مشاهده بردار تعبیه $f(u)$ است که با استراتژی جستجوی S بدست آمده‌اند ($N_S(u)$). در نهایت به کمک تابع f که معمولا به کمک یک شبکه عصبی مدل‌سازی می‌شود، می‌توان بردار تعبیه هر یک از گره‌ها را محاسبه کرد.

۱۱.۳.۲ خوشه‌بندی گراف با گره‌های ویژگی‌دار

با فرض گراف $G = (V, E, F)$ که در آن V مجموعه گره‌ها، E مجموعه یال‌ها است و F ماتریس ویژگی‌های گره‌ها می‌باشد، یک خوشه‌بندی از گراف G را می‌توان با C نشان داد که مجموعه‌ای از زیر مجموعه‌های V است، به صورتی که $C_i \in C; C_i \subset V$. هدف از خوشه‌بندی این است که خوشه‌هایی که هم از نظر ساختاری و هم از نظر ویژگی‌های گره‌ها بهم بیشترین شباهت را دارند، پیدا کنیم. همچنین خوشه‌های ایجاد شده باید از نظر ارتباط یال‌های داخل خوشه چگال و در ارتباط یال‌ها با دیگر خوشه‌ها تنک باشند. نکته مهم دیگر در این قسمت وجود و یا عدم وجود هم‌پوشانی در بین خوشه‌ها می‌باشد که به خوشه‌بندی بدون هم‌پوشانی، افرازبندی[2] نیز می‌گویند. به عبارت دیگر در افرازبندی شرط:

$$\forall i, j;\ i \neq j;\ C_i \in C \ \ and \ \ C_j \in C;\ C_i \cap C_j \subseteq \phi$$

باید حتما رعایت شود این در حالیست که در خوشه‌بندی با هم‌پوشانی چنین شرطی الزامی نیست.

[1] Loss function

[2] Partitioning

۱۲.۳.۲ دسته‌بندی و روش‌های کلی خوشه‌بندی گراف

روش‌های خوشه‌بندی گراف را می‌توان از دیدگاه‌های مختلفی تقسیم‌بندی کرد. این تقسیم‌بندی‌ها بر اساس معیارها و ویژگی‌های خاصی صورت می‌گیرند که به نحوه‌ی برخورد با داده‌های گرافی، نوع اطلاعات استفاده شده، و تکنیک‌های به کار گرفته شده بستگی دارد. در این پژوهش از آن‌جایی که نوع گراف ورودی مشخص است و قصد خوشه‌بندی گراف‌های PPI با گره‌های دارای ویژگی را داریم، روش‌های خوشه بندی را بر اساس روش مورد استفاده تقسیم‌بندی می‌کنیم:

- روش‌های طیفی[۱] : از مقادیر ویژه[۲] ماتریس لاپلاسین یا مجاورت برای یافتن خوشه‌ها استفاده می‌کنند.
- روش‌های فاکتورگیری ماتریسی[۳] : از روش‌های تجزیه ماتریسی مانند تجزیه نامنفی ماتریس[۴] یا تجزیه مقدار تکین[۵] برای ایجاد بردار بازنمایی و خوشه‌بندی استفاده می‌کنند.
- روش‌های سلسله‌مراتبی[۶] : گراف را به صورت سلسله مراتبی خوشه‌بندی می‌کنند که به دو روش تقسیمی و تجمعی دسته‌بندی می‌شوند.
- روش‌های مبتنی بر بازنمایی[۷] : ابتدا گره‌ها به فضای برداری کم‌بعد نگاشت می‌شوند و سپس خوشه‌بندی روی این فضای برداری انجام می‌شود و تمرکز اصلی در این روش‌ها یافتن بردار بازنمایی مناسب برای خوشه‌بندی گراف است. الگوریتم های CNN، GCN، Deep Walk و Node2Vec جزء این دسته محسوب می‌شوند.

---

[1] Spectral clustering
[2] Eigenvalues
[3] Matrix factorization
[4] Non negative matrix factorization
[5] Singular value factorization
[6] Hierarchical clustering
[7] Embedding based methods

- روش‌های بدون بازنمایی[1] : مستقیماً از ساختار گراف برای خوشه‌بندی استفاده می‌شود بدون اینکه گره‌ها به فضای برداری منتقل شوند. به عنوان مثال می‌توان روش‌های مبتنی بر graph-cut و یا روش Louvain را نام برد.

۴.۲ معیارهای ارزیابی

در این قسمت به بررسی معیارهای ارزیابی عملکرد الگوریتم‌های شناسایی مجموعه‌های پروتئینی می‌پردازیم. در بین معیارهای موجود، معیارهای دقت[2]، بازیابی[3]، صحت[4]، امتیاز F ، بیشترین استفاده را در بین پژوهش‌ها داشته‌اند که ما نیز به‌منظور تحلیل و مقایسه‌ی عملکرد روش خود از آنها استفاده می‌کنیم. در ابتدا برای شروع به معیار شباهت همسایگی که برای محاسبه‌ی تمامی معیارهای مذکور مورد نیاز است، می‌پردازیم:

۱.۴.۲ شباهت همسایگی

در تعریف شباهت همسایگی[5]، با در نظر گرفتن P به‌عنوان مجموعه‌ای از مجموعه‌های پروتئینی شناسایی شده توسط الگوریتم، عملکرد الگوریتم به وسیله‌ی تعداد مجموعه‌های پروتئینی مشترک بین P و مجموعه‌ای از مجموعه پروتئین‌های مرجع[6] B بدست می‌آید. برای مشخص کردن اینکه آیا یک مجموعه پروتئین شناسایی شده $p \in P$ با یک مجموعه پروتئین مرجع $b \in B$ یکسان هستند یا خیر ما

[1] Non embedding methods
[2] Precision
[3] Recall
[4] Accuracy
[5] Neighborhood affinity
[6] Reference protein complex

اقدام به محاسبه‌ی معیار شباهت همسایگی به کمک معادله ۸.۲ می‌کنیم.

$$NA(p,b) = \frac{|V_p \cap V_b|^2}{|V_p| \times |V_b|} \tag{۸.۲}$$

که V_p مجموعه پروتئین‌های حاضر در ترکیب p و به طور مشابه V_b مجموعه پروتئین‌های حاضر در b هستند. برای تفسیر شباهت همسایگی یک آستانه[1] از قبل تعیین شده (معمولا ۰/۲۵) در نظر گرفته می‌شود که شباهت همسایگی‌های بالاتر از آستانه به معنی یکسانی دو مجموعه است. همچنین تعداد مجموعه‌های شناسایی شده‌ای که حداقل با یک مجموعه مرجع یکسان در نظر گرفته می‌شوند را با N_{cp} و تعداد مجموعه های مرجعی که حداقل با یکی از مجموعه‌های شناسایی شده الگوریتمی یکسان در نظر گرفته می‌شوند را با N_{cb} نمایش می‌دهیم [۸].

$$N_{cp} = \{p | p \in P, \exists b \in B, NA(p,b) \geq \omega\} \tag{۹.۲}$$

$$N_{cb} = \{b | b \in B, \exists p \in P, NA(p,b) \geq \omega\} \tag{۱۰.۲}$$

۲.۴.۲ دقت

دقت یک معیار ارزیابی مجموعه پروتئینی‌های شناسایی شده است که نشان می‌دهد چند مورد از مجموعه‌های پیش‌بینی شده الگوریتم به درستی انتخاب شده‌اند و از معادله ۱۱.۲ محاسبه می‌شود.

$$Precision = \frac{N_{cp}}{|P|} \tag{۱۱.۲}$$

[1] Threshold

۳.۴.۲ بازیابی

بازیابی دیگر معیار مورد توجه است که نشان می‌دهد چند مورد از مجموعه پروتئینی‌های مرجع توسط الگوریتم پیش‌بینی شده‌اند. به دیگر عبارت میزان پوشش الگوریتم از مجموعه پروتئینی‌های مرجع را اندازه‌گیری می‌کند که به صورت معادله ۱۲.۲ بیان می‌شود.

$$Recall = \frac{N_{cb}}{|B|} \tag{۱۲.۲}$$

۴.۴.۲ امتیاز F

معیار امتیاز F میانگین همساز[1] بین دو معیار دقت و بازیابی می‌باشد که با معادله ۱۳.۲ تعریف می‌شود.

$$F - score = \frac{۲ \times Precision \times Recall}{Precision + Recall} \tag{۱۳.۲}$$

۵.۴.۲ صحت

معیار صحت به کمک دو معیار دیگر حساسیت خوشه‌بندی[2] و ارزش پیش‌بینی مثبت خوشه‌بندی[3] محاسبه می‌شود. با در نظر گرفتن $T_{i,j}$ به عنوان تعداد پروتئین‌هایی که هم در مجموعه پروتئینی i ام و هم در مجموعه پروتئینی پیش‌بینی j ام یافت می‌شوند و همچنین N به عنوان تعداد پروتئین‌های

[1] Harmonic mean

[2] Clustering-wise sensitivity (Sn)

[3] Clustering-wise positive predictive value (PPV)

مجموعه پروتئینی مرجع i، می‌توانیم Sn و PPV را با معادله ۱۴.۲ تعریف کنیم.

$$PPV = \frac{\sum_{j=1}^{|P|} max_{i=1}^{|B|} |T_{ij}|}{\sum_{j=1}^{|P|} \sum_{i=1}^{|B|} T_{ij}}$$
$$Sn = \frac{\sum_{i=1}^{|B|} max_{j=1}^{|P|} |T_{ij}|}{\sum_{i=1}^{|B|} N_i} \quad (۱۴.۲)$$

از نظر مفهومی، معیار PPV نشان‌دهنده‌ی نسبت مجموع بیشینه پروتئین‌های تطبیق‌یافته هر مجموعه پیش‌بینی شده با مجموعه‌های پروتئینی مرجع، به تعداد کل پروتئین‌های تطبیق‌یافته در مجموعه‌های پروتئینی پیش‌بینی‌شده است. از سوی دیگر، معیار Sn بیان‌کننده‌ی نسبت مجموع بیشینه پروتئین‌های تطبیق‌یافته هر مجموعه پروتئینی مرجع با مجموعه‌های پروتئینی پیش‌بینی‌شده، به تعداد کل پروتئین‌های موجود در مجموعه‌های پروتئینی مرجع است. در نهایت به کمک این دو معیار می‌توان معیار صحت را به صورت معادله ۱۵.۲ محاسبه نمود.

$$Acc = \sqrt{Sn.PPV} \quad (۱۵.۲)$$

۵.۲ جمع‌بندی

در این فصل مفاهیم بنیادی شامل مفاهیم زیستی و محاسباتی مورد نیاز در این پژوهش مورد بررسی قرار گرفتند. همچنین معیارهای مورد استفاده جهت ارزیابی و مقایسه عملکرد روش پیشنهادی معرفی شدند. در ادامه، در فصل بعد به بررسی پژوهش‌های پیشین مرتبط با خوشه‌بندی گراف‌های ویژگی‌دار و شناسایی پیمانه‌های عملکردی در شبکه‌های PPI می‌پردازیم.

فصل ۳

بررسی منابع

در این قسمت به بررسی پژوهش‌های پیشینی که به منظور پیدا کردن مجموعه‌های پروتئینی در شبکه‌های PPI انجام شده‌اند، می‌پردازیم. همان‌طور که در بخش‌های پیشین بررسی شد، تمرکز این پژوهش بر روی دید گرافی به شبکه‌های PPI و ادغام اطلاعات زیست‌شناسی پروتئین‌ها به منظور تشخیص دقیق‌تر مجموعه‌های پروتئینی است. از آن‌جایی که پیدا کردن مجموعه‌های پروتئینی در شبکه‌های PPI معادل خوشه‌بندی این شبکه‌ها می‌باشد، ما ابتدا چند نمونه از پژوهش‌های مرتبط با خوشه‌بندی گراف‌های دارای گره‌های ویژگی‌دار که بیشترین ارتباط را با هدف پژوهش ما دارند را بررسی می‌کنیم.

۱.۳ خوشه‌بندی گراف با گره‌های ویژگی‌دار

پژوهش وحید جان‌نثاری و همکارانش [۳۹]، یک الگوریتم بر پایه‌ی تجزیه نامنفی ماتریسی به منظور خوشه‌بندی گراف‌های ویژگی‌دار معرفی می‌کند. روش آن‌ها ابتدا اطلاعات ساختاری که توسط ماتریس همسایگی[۲] نشان داده می‌شود را به کمک تجزیه نامنفی متقارن ماتریس[۳] و اطلاعات ویژگی‌های گره‌ها

[2] Adjacency matrix

[3] Symmetric non negative matrix factorization

را به کمک تجزیه نامنفی بازتابی ماتریس[1] به یک فضای کم بعد مختص خوشه‌بندی (هم بعد با تعداد خوشه‌ها) به صورت جداگانه انتقال می‌دهد که درجه عضویت هر گره به هر خوشه را نمایش می‌دهد. همین‌طور به منظور حفظ ثبات در خوشه بندی در هر دو فضا اقدام به نزدیک کردن این دو ماتریس به کمک تابع هدف می‌کند که به صورت معادله ۱.۳ تعریف شده است.

$$J_{of} = min||A - VV^T||_F^2 + \alpha||VV^T - UU^T||_F^2 + ||F - UU^TF||_F^2 \qquad (۱.۳)$$
$$s.t.\ V \geq 0,\ U \geq 0,\ V^TV = I,\ U^TU = I.$$

که در تابع هدف، A ماتریس همسایگی، $V \in R^{n\times k}$ ماتریس حاصل از تجزیه نامنفی متقارن ماتریس A است. همین‌طور با در نظر گرفتن M (ماتریس شباهت[2] گره‌ها براساس ماتریس ویژگی‌ها) به صورت $M = UU^T; U \in R^{n\times k}$ و عبارت سوم در بهینه سازی که به صورت مقابل بیان شده است: $|F - MF|$ در واقع اقدام به استفاده از ویژگی خودبیانگری[3] داده‌ها کرده‌اند، که در نتیجه روش بیان شده را می‌توان یک روش ترکیبی از خوشه‌بندی زیر فضا[4] و تجزیه نامنفی ماتریس در نظر گرفت.

در پژوهشی دیگر توسط کانگ و همکارانش [۴۰] ، یک روش بر پایه‌ی شبکه‌های پیچشی گرافی و خوشه‌بندی طیفی ارائه شده است. ایده اصلی در این روش بر پایه‌ی پردازش سیگنالی گراف است که در آن یک فیلتر پایین گذر[5] را به منظور نزدیک کردن و ادغام ویژگی‌های گره‌ها و ساختار گراف به ماتریس ویژگی‌ها اعمال می‌کنند. در نتیجه یک بازنمایی جدید بر این اساس را برای گره‌ها بدست می‌آورند:

$$\bar{X} = (I - 1/2L)^k X \qquad (۲.۳)$$

[1] Projective non negative matrix factorization
[2] Similarity matrix
[3] Self expression
[4] Subspace clustering
[5] Low pass filter

همچنین در معادله بالا k یک هایپر پارامتر است که میزان مرتبه‌ی مجاورت بازنمایی به‌دست آمده را مشخص می‌کند به عبارت دیگر مقادیر کوچک‌تر k دید محلی‌تری به ساختار گراف دارند و بالعکس. L ماتریس لاپلاسی نرمال شده[1] است که به‌صورت $L = I - A$ تعریف می‌شود. در مرحله‌ی بعد برای اعمال خوشه‌بندی طیفی، نیاز به محاسبه‌ی ماتریس شباهت بین گره‌ها است که از معادله ۳.۳ شده است.

$$\min_{S} ||\bar{X}^T - \bar{X}^T S||_F^2 + ||S - f(A)||_F^2 \qquad (۳.۳)$$

در این معادله ماتریس شباهت S از بهینه‌سازی تابع هدف ۳.۳ بدست می‌آید و سپس با یک انتقال به یک ماتریس متقارن نامنفی تبدیل شده و در نهایت نیز خوشه‌بندی طیفی روی آن اعمال می‌شود. یکی از مشکلات این روش انتخاب مناسب هایپر پارامتر k است که به‌طور مستقیم بر خروجی الگوریتم تأثیر می‌گذارد که توسط پژوهش دیگری که توسط ژانگ و همکارانش انجام شده است، دو استراتژی AGC[2] و IAGC[3] برای پیدا کردن مقدار مناسب k ارائه شده است [۴۰].

بهومیک و همکاران [۴۱] روشی مبتنی بر بیشینه‌سازی ماژولاریتی با عنوان DGCluster ارائه داده‌اند که در آن از شبکه‌های عصبی گرافی برای خوشه‌بندی گراف‌های ویژگی‌دار استفاده می‌شود. در این چارچوب، ابتدا یک شبکه عصبی گرافی پیچشی دولایه با تابع فعال‌ساز SELU به‌منظور ایجاد بردارهای بازنمایی گره‌ها به‌کار گرفته می‌شود. سپس با اعمال مجموعه‌ای از تبدیلات غیرخطی و نرمال‌سازی، بازنمایی‌های حاصل به فضای مختصات مثبت محدود می‌گردند تا محاسبه شباهت بین گره‌ها تسهیل شود. در ادامه، با استفاده از شباهت کسینوسی میان بردارهای بازنمایی گره‌ها، نسخه تغییر یافته‌ای از ماژولاریتی مطابق معادله ۴.۳ تعریف شده و تابع هزینه متناظر با آن به‌صورت منفی ماژولاریتی

[1] Normalized laplacian matrix

[2] Adaptive Graph Convolution - AGC

[3] Improved Adaptive Graph Convolution - IAGC

معادله‌بندی می‌شود.

$$L_۱ = -\hat{Q} = \frac{۱}{۲m} Tr(BXX^T) \qquad (۴.۳)$$

که در آن هر درایه ماتریس B به صورت $B_{ij} = (A_{ij} - \frac{d_i d_j}{۲m})$ و X ماتریس بازنمایی هر گره حاصل از شبکه عصبی گرافی بعد می‌باشد. پس از آموزش شبکه عصبی با هدف بیشینه‌سازی ماژولاریتی، فرآیند خوشه‌بندی نهایی بر روی بردارهای بازنمایی آموخته‌شده و با استفاده از الگوریتم خوشه‌بندی سلسله‌مراتبی BIRCH انجام می‌گیردکه نیازی به تعیین تعداد خوشه‌ها از قبل ندارد [۴۲].

در پژوهش هی و همکاران [۴۳]، یک چارچوب یکپارچه با عنوان SSAGCN[1] برای خوشه‌بندی گراف‌ها معرفی شده است. در این روش، ابتدا گراف ورودی ویژگی‌دار به‌صورت $G(V, E, A, X)$ در نظر گرفته می‌شود. سپس گراف کمکی دیگری به شکل $G(V, E_a, A_a, X)$ ساخته می‌شود که تفاوت آن با گراف اولیه در مجموعه یال‌ها و ماتریس مجاورت است. این گراف کمکی بر اساس محاسبه‌ی شباهت بین ویژگی‌های گره‌ها با استفاده از معیار شباهت کسینوسی تشکیل شده و در آن هر گره به k گره مشابه خود متصل می‌شود. در ادامه، هر دو گراف به دو شبکه عصبی گرافی پیچشی با وزن‌های به اشتراک گذاشته شده وارد شده و بردارهای بازنمایی حاصل از آن‌ها با بهره‌گیری از یک سازوکار توجه برای هر گره ترکیب می‌شوند. تابع هزینه پیشنهادی به‌صورت ترکیب خطی و مبتنی بر بیشینه‌سازی ماژولاریتی، بازسازی ماتریس مجاورت و بازسازی ماتریس ویژگی‌ها تعریف شده است که از آن با عنوان سازوکار رمزگشای دوگانه[2] یاد می‌شود. در نهایت، با استفاده از بازنمایی‌های نهایی به‌دست‌آمده، میزان تعلق هر گره به خوشه‌های مختلف محاسبه شده و هر گره به خوشه‌ای اختصاص می‌یابد که بیشترین میزان تعلق را داشته باشد.

یکی از مشکلات روش‌های بر پایه بازنمایی این است که دو فرآیند بازنمایی داده‌ها و خوشه‌بندی از

[1] Self-Supervised Adaptive Graph Convolutional Network

[2] Dual decoder

یکدیگر مستقل‌اند در نتیجه نمی‌توان اطمینان داشت که بازنمایی‌های ایجاد شده برای وظیفه موردنظر (در اینجا خوشه‌بندی) مناسب هستند و همچنین نمی‌توان الگوریتم بازنمایی را بر اساس خطای خوشه‌بندی به طور مناسب به‌روزرسانی نمود. از این روی، وانگ و همکاران [۴۴] یک روش خوشه بندی یکپارچه توجه محور بر پایه شبکه عصبی گرافی ارائه داده‌اند که مرحله بازنمایی و خوشه‌بندی را با هم ترکیب می‌کند. در این پژوهش از یک شبکه گرافی توجه محور به عنوان کدگذار[۱] استفاده شده است. ضرایب توجه کدگذار با استفاده از یک ماتریس مجاورت با مرتبه بالا همانند پژوهش قبلی محاسبه می‌شوند. قسمت کدگشا[۲] نیز از ضرب داخلی بردارهای بازنمایی کدگذار به منظور بازسازی ماتریس مجاورت گراف استفاده می‌کند که برای خروجی این قسمت تابع هزینه بازسازی در نظر گرفته شده است. نوآوری این مقاله در معرفی مفهوم بازنمایی خود بهینه‌ساز است که در آن به طور مکرر نقاط مربوط به هر خوشه براساس مقدار اطمینان تعلق به خوشه به‌روزرسانی می‌شود و به طور همزمان بازنمایی‌ها را نیز به وسیله آن اصلاح می‌کند.

از جمله پژوهش‌های شاخص در زمینه خوشه‌بندی گراف‌های ویژگی‌دار می‌توان به کار شچور[۳] و گانمن[۴] اشاره نمود [۴۵] که به‌عنوان مبنای اصلی این پایان‌نامه نیز مورد استفاده قرار گرفته است. در این پژوهش، یک الگوریتم یکپارچه برای شناسایی خوشه‌های هم‌پوشان در گراف‌ها به نام NOCD ارائه شده است که ایده اصلی آن بر تلفیق توانمندی‌های شبکه‌های عصبی گرافی با یک مدل مولد احتمالاتی برنولی‌ـ پواسون[۵] استوار است.

در چارچوب این روش، گراف ورودی به‌صورت $G(A, X)$ در نظر گرفته می‌شود که در آن ماتریس مجاورت به صورت $A \in \{۰, ۱\}^{n \times n}$ و $X \in \mathbb{R}^{n \times d}$ ماتریس ویژگی گره‌ها است. هدف، آموزش یک شبکه عصبی گرافی با پارامترهای θ (وزن‌های شبکه عصبی گرافی)، موسوم به GNN_θ، به‌منظور

[1] Decoder
[2] Encoder
[3] Shchur
[4] Günnemann
[5] Probabilistic Bernoulli–Poisson Generative Model

استخراج ماتریس عضویت خوشه‌ای F می‌باشد:

$$F = GNN_\theta(A, X) \tag{۵.۳}$$

در این رابطه، $F \in \mathbb{R}^{n \times C}_{\geq ۰}$ ماتریس انتساب گره‌ها به خوشه‌ها بوده و هر مؤلفه F_{uc} بیانگر میزان تعلق گره u به خوشه c است. شبکه عصبی گرافی به‌کاررفته در این پژوهش، یک شبکه گرافی پیچشی دولایه با تابع فعال‌ساز ReLU است که مطابق معادله ۶.۳ تعریف می‌شود. در این ساختار، با افزودن یال‌های خوداتصالی و نرمال‌سازی ماتریس مجاورت، اطلاعات ساختاری و ویژگی‌های گره‌ها به‌صورت همزمان در فرآیند یادگیری مورد استفاده قرار می‌گیرند.

$$\begin{aligned}
&\tilde{A} = A + I_N \\
&\tilde{D}_{ii} = \sum_j \tilde{A}_{ij} \\
&\hat{A} = \tilde{D}^{-۱/۲} \tilde{A} \tilde{D}^{-۱/۲} \\
&F = ReLU(\hat{A} ReLU(\hat{A} X W^{(۱)}) W^{(۲)})
\end{aligned} \tag{۶.۳}$$

پس از استخراج ماتریس F، یک مدل مولد برنولی‌ـ‌پواسون به‌عنوان رمزگشا به‌کار گرفته می‌شود که هدف آن بازسازی ماتریس مجاورت گراف است. در این مدل، وجود یال میان دو گره u و v به‌صورت یک متغیر تصادفی برنولی با پارامتر $۱ - e^{-F_u F_v^T}$ مدل‌سازی می‌شود:

$$A_{uv} \sim Bernoulli(۱ - e^{-F_u F_v^T}) \tag{۷.۳}$$

بر این اساس، احتمال مشاهده ماتریس مجاورت A با شرط دانستن ماتریس عضویت F به صورت

ضرب احتمال‌ها بر روی یال‌های موجود و ناموجود طبق معادله ۸.۳ محاسبه می‌شود.

$$P(A|F) = \prod_{A_{uv} \in E} ۱ - e^{-F_u F_v^T} \times \prod_{A_{uv} \notin E} e^{-F_u F_v^T} \tag{۸.۳}$$

در نهایت، تابع هزینه مدل به صورت $-log^{p(A|F)}$ تعریف شده و به شکل معادله ۹.۳ قابل بیان است.

$$L(F) = -\sum_{A_{uv} \in E} log(۱ - exp(-F_u F_v^T)) + \sum_{A_{uv} \notin E} F_u F_v^T \tag{۹.۳}$$

پژوهشگران در این مقاله به یک چالش اساسی در تابع هزینه فوق اشاره می‌کنند. از آن‌جا که گراف‌های واقعی عموماً تنک[1] هستند، تعداد جفت گره‌هایی که بین آن‌ها یال وجود ندارد به مراتب بیشتر از یال‌های موجود است، در نتیجه، عبارت دوم تابع هزینه غالب شده و می‌تواند فرآیند یادگیری را تحت تأثیر قرار دهد. به‌منظور رفع این مشکل، نویسندگان با استفاده از امید ریاضی هر یک از عبارات تابع هزینه و فرض یک توزیع یکنواخت بر روی یال‌ها، نسخه اصلاح‌شده‌ای از تابع هزینه را ارائه می‌دهند که منجر به پایداری بیشتر و بهبود عملکرد مدل در گراف‌های تنک می‌شود.

$$L(F) = -E_{(U,V) \sim P_E}[log(۱ - exp(-F_u F_v^T))] + E_{(u,v) \sim P_N}[F_u F_v^T] \tag{۱۰.۳}$$

که در معادله ۱۰.۳، علامت E نشان‌دهنده امید ریاضی است، عبارت P_E توزیع یکنواخت بر روی یال‌ها و P_N توزیع یکنواخت بر روی گره‌هایی است که یالی بین آن‌ها وجود ندارد. پس از آموزش

[1] Sparse

شبکه عصبی، برای پیدا کردن خوشه‌ها با استفاده از ماتریس وابستگی F از آستانه φ استفاده می‌شود.

$$F_{uc} = \begin{cases} ۱ & \text{if } F_{uc} > \varphi \\ ۰ & \text{otherwise} \end{cases} \quad (۱۱.۳)$$

۲.۳ پیش‌بینی مجموعه‌های پروتئینی

در ادامه به بررسی روش‌های استفاده شده به منظور پیش‌بینی مجموعه‌های پروتئینی در شبکه‌های PPI می‌پردازیم و یک دسته‌بندی برای این روش‌ها ارائه می‌دهیم.

۱.۲.۳ روش‌های بر پایه شبکه

این روش‌ها تنها بر ساختار شبکه PPI تمرکز می‌کنند. که به دو زیر دسته تقسیم می‌شوند:

- روش‌های تقسیمی [۱]: این دسته از روش‌ها، شبکه را به زیر شبکه‌ها تقسیم می‌کنند و این عمل را تا رسیدن به درجه دلخواه خوشه‌بندی تکرار می‌کنند. معروف‌ترین الگوریتم این دسته الگوریتم خوشه‌بندی مارکوف[۲] [۴۶] است که زیر شبکه‌ها را به کمک ولگشت تصادفی[۳] در شبکه پیدا می‌کند.
- روش‌های تجمعی [۴]: با مجموعه کوچکی از پروتئین‌ها شروع کرده و با ترکیب آن‌ها اقدام به پیدا کردن مجموعه‌های پروتئینی نهایی می‌کند. الگوریتم CPNM [۴۷] یکی از الگوریتم‌های این دسته است که از بازنمایی موتیف‌های[۵] شبکه به منظور پیدا کردن نقش پروتئین‌ها استفاده

[1] Divisive methods
[2] Markov clustering algorithm
[3] Random walk
[4] Agglomerative methods
[5] Motif

می‌کند. سپس به منظور ایجاد بردار ویژگی پروتئین‌ها از آن‌ها استفاده می‌شود. در نهایت نیز از روش پیدا کردن همسایگان به منظور شناسایی مجموعه‌های پروتئینی استفاده می‌کند. یکی دیگر از الگوریتم‌های تجمعی معروف الگوریتم ClusterONE [۴۸] است. این الگوریتم ابتدا پروتئین‌های با درجه بالاتر را به عنوان پروتئین‌های هسته[1] (پروتئین‌های آغازین) در نظر می‌گیرد. سپس زیرگروه‌هایی از گره‌ها با بیشترین انسجام برای گره‌های هسته انتخاب می‌شوند. در انتها نیز گره هسته از بین گره‌هایی که مربوط به یک ترکیب شناخته شده نیستند انتخاب می‌شوند و این مراحل تکرار می‌شوند تا همه پروتئین‌ها به یک ترکیب مرتبط شوند. الگوریتم دیگر، MCODE[2] [۴۹] است که در سه مرحله انجام می‌شود. این الگوریتم ابتدا گره‌ها را وزن دهی می‌کند، سپس به شناسایی مجموعه‌ها می‌پردازد و در انتها نیز اقدام به اضافه / حذف کردن پروتئین‌ها به/از مجموعه‌های شناسایی شده با توجه به یک معیار اتصال می‌کند.

۲.۲.۳ روش‌های مبتنی بر آگاهی از زمینه‌های زیستی

اگرچه روش‌های بر پایه شبکه عملکرد خوبی دارند، اما عملکرد آنها می‌تواند با به کارگیری اطلاعات تکمیلی بهبود یابد. این اطلاعات می‌توانند از منابع گوناگونی مثل اطلاعات دامنه‌ای پروتئین‌ها، برچسب‌های ژن شناسی، نمایه بیان ژنی جمع آوری شوند. پژوهش آلن و همکارانش [۵۰]، الگوریتم PCIA را توسعه داده‌اند که از ترکیب اطلاعات GO در کنار ساختار شبکه استفاده می‌کند. پژوهش دیگر ژانگ و همکارانش [۵۱] رابطه‌ی بین شکل‌گیری مجموعه‌های پروتئینی و هم بیانی پروتئین‌ها را نشان داده است.

- روش‌های هسته_اتصال[3]: روش‌های هسته_اتصال بر پایه این ایده هستند که هر مجموعه پروتئینی از یک هسته تشکیل شده است که شامل پروتئین‌هایی با هم‌بیانی بالا می‌باشند. الگوریتم

[1] Seed
[2] Molecular complex detection
[3] Core-attachment

COACH [۵۲] یکی از شناخته شده‌ترین الگوریتم‌های این دسته است که از دو مرحله شناسایی پروتئین‌های هسته‌ای و اضافه کردن پروتئین‌ها به پروتئین‌های هسته‌ای تشکیل شده است. تمرکز این الگوریتم بر ایجاد مجموعه‌های پروتئینی است که از نظر زیستی نیز با معنی باشند. الگوریتم CORE [۵۳] نیز از سه مرحله، پیش‌بینی پروتئین‌های هسته‌ای، حذف هسته‌های با اهمیت پایین (بر اساس یک معیار اتصال)، و محاسبه اهمیت مجموعه‌های شناسایی شده، تشکیل شده است. اخیرا نیز الگوریتم CO-DPC از این دسته بندی ارائه شده است که از نمایه بیان ژنی در کنار شبکه PPI استفاده می‌کند.

- الگوریتم‌های مبتنی بر اطلاعات عملکردی[1]: دسته دوم الگوریتم‌ها روش‌های مبتنی بر اطلاعات عملکردی هستند که از اطلاعات ناهمگون پروتئین‌ها به منظور شناسایی مجموعه‌های با معنی استفاده می‌کنند. یکی از الگوریتم‌های این دسته، الگوریتم PCP [۵۴] است که از اطلاعات ساختاری به منظور وزن‌دهی شبکه PPI استفاده می‌کند. سپس ابتدا اقدام به شناسایی کلیک‌های بیشینه[2] در شبکه PPI کرده، در مرحله بعد چگالی بین خوشه‌ها را محاسبه می‌کند و در نهایت اقدام به ترکیب جزئی کلیک‌ها می‌کند. از دیگر پژوهش‌های شاخص در این بخش می‌توان به پژوهش برهمند و همکارانش [۵۵] اشاره کرد. این پژوهش با تأکید بر این نکته که شناسایی دقیق‌تر پیمانه‌های عملکردی مستلزم بهره‌گیری همزمان از ساختار شبکه و ویژگی‌های زیستی پروتئین‌هاست، روشی با عنوان TADW-SC را پیشنهاد کرده‌اند. در این روش، علاوه بر ساختار شبکه PPI، از ویژگی‌های استخراج‌شده از GO نیز استفاده می‌شود. بدین منظور، در گام نخست با بهره‌گیری از روش TADW[3] [۵۶] ، بردارهای بازنمایی‌ای برای هر گره محاسبه می‌شوند که به‌گونه‌ای طراحی شده‌اند تا همزمان اطلاعات ساختاری گراف و ویژگی‌های گره‌ها را حفظ کنند. در مرحله بعد، با استفاده از بردارهای بازنمایی آموخته‌شده، یک ماتریس شباهت بین

[1] Functional information based
[2] Maximal clique
[3] Text associated deep walk

گره‌ها ایجاد می‌شود. سپس الگوریتم خوشه‌بندی طیفی بر روی این ماتریس شباهت اعمال شده و پیمانه‌های عملکردی استخراج می‌گردند. نتایج تجربی نشان می‌دهد که روش TADW-SC با وجود ساختار ساده، در بسیاری از شبکه‌های PPI عملکرد قابل قبولی از خود نشان داده و می‌تواند به‌عنوان یک رویکرد کارا برای شناسایی پیمانه‌های عملکردی مورد استفاده قرار گیرد.

لازم به ذکر است که استراتژی‌های دیگری که در سایر پژوهش‌های مربوط به پردازش گراف‌ها و خوشه‌بندی آنها خوب عمل کرده‌اند نیز مورد توجه قرار گرفته‌اند که از جمله آنها می‌توان به روش‌های بر پایه بازنمایی [۵۷] و تجزیه ماتریسی [۵۸] اشاره کرد که به منظور شناسایی مجموعه‌های پروتئینی نیز مورد استفاده قرار گرفته‌اند.

۳.۲.۳ روش‌های مبتنی بر شبکه‌های عصبی گرافی

در این میان، روش‌های مبتنی بر شبکه‌های عصبی گرافی برای شناسایی مجموعه‌های پروتئینی به‌طور محدود مورد مطالعه قرار گرفته‌اند و بررسی و توسعه این دسته از روش‌ها یکی از اهداف اصلی پژوهش حاضر به‌شمار می‌رود. با این حال، نتایج امیدوارکننده‌ای از به‌کارگیری شبکه‌های عصبی گرافی در این حوزه گزارش شده است، به‌گونه‌ای که روش پیشنهادی چن و همکاران [۵۹] در مقایسه با بسیاری از رویکردهای پیشین، بهترین عملکرد را در شناسایی پیمانه‌های عملکردی شبکه‌های PPI نشان داده است. در پژوهش چن و همکاران، چارچوبی با عنوان AdaPPI را برای شناسایی مجموعه‌های پروتئینی در شبکه‌های برهم‌کنش PPI معرفی می‌کند. این چارچوب ترکیبی از یک شبکه عصبی گرافی پیچشی و یک راهبرد یادگیری بازنمایی تطبیقی در سطح گره است که با هدف استخراج بازنمایی‌هایی متناسب با ساختار محلی و سراسری شبکه طراحی شده است. در این روش، پس از استخراج بازنمایی‌های گره‌ها، شناسایی پیمانه‌های عملکردی با بهره‌گیری از بازنمایی‌های آموخته‌شده و با استفاده از الگوریتم کلاسیک یافتن کلیک‌های هسته‌ای و گسترش آن‌ها انجام می‌شود.

در AdaPPI، ویژگی‌های مربوط به GO هر پروتئین شامل فرآیندهای زیستی و عملکردهای مولکولی،

از زیرگراف‌های متناظر استخراج شده و به‌صورت بردارهای دودویی کدگذاری می‌شوند. این ویژگی‌ها به‌عنوان ورودی اولیه به شبکه عصبی گرافی پیچشی داده می‌شوند. در ادامه، خروجی هر لایه از شبکه عصبی گرافی به یک شبکه عصبی بازگشتی وارد می‌شود که وظیفه آن پیش‌بینی میزان هموارسازی مناسب برای بازنمایی هر گره است. این شبکه بازگشتی[1] به‌صورت همزمان با شبکه عصبی گرافی آموزش داده می‌شود.

ایده اصلی این سازوکار بر این فرض استوار است که گره‌های مختلف در شبکه PPI به سطوح متفاوتی از اطلاعات همسایگی نیاز دارند.از دیدگاه زیستی نیز، این تفاوت می‌تواند بازتاب‌کننده‌ی نقش‌های متفاوت پروتئین‌ها در شبکه، ازجمله پروتئین‌های مرکزی با مشارکت در چندین فرآیند زیستی و پروتئین‌های اختصاصی‌تر با نقش‌های محدود و وابسته به زمینه باشد. به‌طور خاص، گره‌های با درجه بالا عمدتاً از اطلاعات همسایگان مرتبه پایین‌تر بهره می‌برند، در حالی که گره‌های با درجه پایین‌تر برای به‌روزرسانی بازنمایی خود نیازمند دسترسی به اطلاعات همسایگان با مراتب بالاتر هستند. راهبرد یادگیری بازنمایی تطبیقی در AdaPPI از بروز پدیده‌ی هموارسازی بیش از حد یا کمتر از حد بازنمایی‌ها جلوگیری کرده و امکان استخراج بازنمایی‌های گره‌ای متمایزتر را فراهم می‌سازد. پس از یادگیری بازنمایی‌ها، با استفاده از ساختار گراف و بازنمایی‌های حاصل، کلیک‌های هسته‌ای در شبکه شناسایی شده و سپس از طریق الگوریتم گسترش کلیک، پیمانه‌های عملکردی نهایی استخراج می‌شوند. تابع هزینه مورد استفاده در این پژوهش به‌گونه‌ای طراحی شده است که فاصله بین بازنمایی گره‌های متعلق به یک خوشه را کاهش داده و همزمان فاصله بازنمایی گره‌های متعلق به خوشه‌های

[1] Recurrent neural network - RNN

متفاوت را افزایش دهد. این تابع هزینه به‌صورت معادله ۱۲.۳ تعریف می‌شود:

$$
\begin{aligned}
L_{\text{intra}} &= \frac{۱}{|C|} \sum_{c \in C} \frac{۱}{|c|(|c|-۱)} \sum_{i,j \in c,\, i \neq j} \|\bar{X}_i - \bar{X}_j\|_۲ \\
L_{\text{inter}} &= \frac{۱}{|C|} \sum_{c \in C} \frac{۱}{|c|(n-|c|)} \sum_{i \in c,\, j \notin c} \|\bar{X}_i - \bar{X}_j\|_۲ \\
L &= L_{\text{intra}} + \beta \frac{۱}{L_{\text{inter}}}
\end{aligned}
\tag{۱۲.۳}
$$

با توجه به اینکه چارچوب پیشنهادی AdaPPI از ترکیب شبکه‌های عصبی و الگوریتم‌های کلاسیک خوشه‌بندی بهره می‌برد و فرآیند شناسایی پیمانه‌های عملکردی در دو مرحله مجزا انجام می‌شود، این روش در دسته الگوریتم‌های یکپارچه قرار نمی‌گیرد. با این حال، نتایج تجربی نشان می‌دهد که این روش در بسیاری از شبکه‌های PPI عملکرد بهتری نسبت به روش‌های پیشین داشته و به‌عنوان یکی از مؤثرترین الگوریتم‌ها برای شناسایی پیمانه‌های عملکردی در این حوزه مطرح است.

فصل ۴

روش شناسی پژوهش

۱.۴ مقدمه

پژوهش حاضر به شناسایی پیمانه‌های عملکردی پروتئینی در شبکه‌های PPI با بهره‌گیری از شبکه‌های عصبی گرافی می‌پردازد. همان‌گونه که در بخش بیان مسئله مطرح شد، مسئله شناسایی پیمانه‌های عملکردی پروتئینی را می‌توان به‌صورت یک مسئله خوشه‌بندی در شبکه‌های PPI مدل‌سازی کرد. از این رو، در فصل پژوهش‌های پیشین، مروری بر مطالعات مرتبط با خوشه‌بندی گراف و روش‌های شناسایی پیمانه‌های عملکردی ارائه شد.

بررسی مطالعات پیشین نشان می‌دهد که با وجود پیشرفت‌های قابل توجه در حوزه خوشه‌بندی شبکه‌های زیستی، تعداد پژوهش‌هایی که به‌طور مستقیم از روش‌های مبتنی بر شبکه‌های عصبی گرافی برای تحلیل شبکه‌های PPI استفاده کرده‌اند، همچنان محدود است. افزون بر این، تاکنون چارچوب یادگیری یکپارچه و منسجمی که به‌صورت خاص برای شناسایی پیمانه‌های عملکردی در شبکه‌های PPI طراحی شده باشد، به‌طور کامل مورد توجه قرار نگرفته است. آموزش شبکه به صورت یکپارچه در تئوری باید

به مدل کمک کند تا در لایه‌های نخست ویژگی‌های مختص به خوشه‌بندی را بهتر استخراج کند، که این موضوع می‌تواند به بهبود عملکرد روش پیشنهادی کمک کند. این پژوهش در پی آن است تا با بررسی دقیق‌تر ظرفیت‌ها و قابلیت‌های شبکه‌های عصبی گرافی، گامی در جهت پر کردن این خلأ پژوهشی بردارد.

از آن‌جا که مسئله شناسایی پیمانه‌های عملکردی ذاتاً یک مسئله یادگیری بدون نظارت به شمار می‌رود، انتخاب تابع هزینه مناسب و تعیین معیارهای توقف مؤثر نقش بسزایی در تضمین همگرایی و کارایی فرآیند یادگیری ایفا می‌کنند. علاوه بر این، روش پیشنهادی باید قادر باشد به‌صورت هم‌زمان اطلاعات ساختاری شبکه و ویژگی‌های زیستی پروتئین‌ها را به‌طور مؤثر مدل‌سازی کند. در این راستا، در نظر گرفتن هم‌پوشانی میان خوشه‌ها از اهمیت ویژه‌ای برخوردار است، چرا که در شبکه‌های زیستی واقعی، پیمانه‌های عملکردی پروتئینی اغلب دارای هم‌پوشانی قابل توجهی با یکدیگر هستند.

این فصل به دو بخش کلی تقسیم می‌شود. در بخش نخست، مجموعه‌داده‌های مورد استفاده معرفی می‌شوند که شامل شبکه‌های PPI مورد بررسی، پایگاه داده هستی‌شناسی ژن، مراحل پیش‌پردازش داده‌ها و فرآیند آماده‌سازی آن‌ها است. در بخش دوم، روش پیشنهادی این پژوهش به‌طور جامع ارائه شده و اجزای مختلف آن به‌صورت دقیق مورد تحلیل و بررسی قرار می‌گیرند.

۲.۴ مجموعه‌داده

در دهه‌های اخیر، شبکه‌های تعامل پروتئین–پروتئین به واسطه توسعه روش‌های آزمایشگاهی با توان عملیاتی بالا[1] به‌طور قابل توجهی گسترش یافته‌اند. از جمله این روش‌ها می‌توان به سیستم‌های دوگانه هیبریدی[2] [۶۰] و طیف‌سنجی جرمی[3] [۶۱] اشاره کرد. افزون بر این، روش‌های مبتنی بر متن‌کاوی[4]

[1] High throughput
[2] Two hybrid systems
[3] Mass spectrometry
[4] Text mining

نیز به‌صورت گسترده برای استخراج تعاملات پروتئینی و ایجاد شبکه‌های PPI مورد استفاده قرار گرفته‌اند [۶۲].

از منظر مدل‌سازی گرافی، این منابع داده امکان نمایش شبکه‌های PPI را به‌صورت یک گراف بدون جهت $G = (V, E)$ فراهم می‌کنند که در آن هر گره $v \in V$ متناظر با یک پروتئین و هر یال $e \in E$ بیانگر وجود تعامل میان دو پروتئین است. در حالت کلی، منابع داده PPI را می‌توان به سه دسته شامل داده‌های آزمایشگاهی، پایگاه‌های داده مبتنی بر روش‌های محاسباتی و پایگاه‌های داده ادغام‌شده تقسیم‌بندی کرد. شبکه‌های PPI برای گونه‌های زیستی مختلفی نظیر انسان، موش و مخمر در دسترس هستند. با این حال، در این پژوهش تمرکز صرفاً بر شبکه‌های مربوط به گونه مخمر نان[1] قرار دارد، چرا که بخش عمده‌ای از داده‌های مرجع، مطالعات پیشین و پیمانه‌های عملکردی تأیید شده برای این گونه زیستی فراهم شده‌اند. تمامی مجموعه‌داده‌های مورد استفاده مربوط به این گونه بوده و تفاوت آن‌ها عمدتاً در تعداد گره‌ها و یال‌ها و نیز نوع روش استخراج تعاملات است. از جمله پایگاه‌های داده شناخته شده مربوط به گونه مخمرنان می‌توان به BioGRID [۶۳]، DIP [۶۴] و Collins [۶۵] اشاره کرد.

در این پژوهش، شبکه‌های PPI نه تنها به‌عنوان یک ساختار گرافی، بلکه به‌عنوان ورودی اصلی مدل‌های یادگیری مبتنی بر شبکه‌های عصبی گرافی در نظر گرفته می‌شوند. از این رو، علاوه بر توپولوژی شبکه، وجود وزن یال‌ها و ویژگی‌های معنایی گره‌ها نقش کلیدی در فرآیند یادگیری و استخراج نمایش‌های نهفته ایفا می‌کند. همچنین، به‌منظور ارزیابی عملکرد روش پیشنهادی در شناسایی پیمانه‌های عملکردی، از مجموعه‌های مرجع شامل پیمانه‌های پروتئینی شناخته‌شده نظیر CYC2008 [۶۶] و MIPS [۶۷] به‌عنوان معیار صحت‌سنجی استفاده می‌شود.

[1] Saccharomyces cerevisiae

۱.۲.۴ مجموعه‌داده شبکه‌های PPI

شبکه‌های PPI مورد استفاده در این پژوهش به‌صورت گراف‌های بدون جهت و وزن‌دار مدل‌سازی می‌شوند که به‌طور رسمی به شکل $G = (V, E, W, X)$ قابل نمایش هستند. در این نمایش، V مجموعه گره‌ها (پروتئین‌ها)، E مجموعه یال‌ها (تعاملات پروتئینی)، W ماتریس وزن یال‌ها و X ماتریس ویژگی‌های گره‌ها است. این چارچوب نمایش، مستقیماً با الزامات ورودی شبکه‌های عصبی گرافی مورد استفاده در روش پیشنهادی سازگار است.

مجموعه‌داده‌های Collins، Gavin، Krogan-Core و Krogan-Extended از مقاله مربوط به الگوریتم IMHRC [۶۸] که توسط پژوهشگاه دانش‌های بنیادی (IPM) منتشر شده است، دریافت شده‌اند. این مجموعه‌داده‌ها شامل وزن یال‌ها بوده و بنابراین مستقیماً به‌عنوان گراف‌های وزن‌دار در مدل‌های عصبی گرافی مورد استفاده قرار می‌گیرند.

در مقابل، برای شبکه‌هایی نظیر BioGRID و DIP که فاقد وزن یال هستند، داده‌های مورد استفاده از پژوهش AdaPPI استخراج شده‌اند. اگرچه مجموعه‌های مربوطه از طریق وب‌سایت اصلی این پایگاه‌ها نیز قابل دسترسی هستند، اما به‌منظور انجام مقایسه‌ای منصفانه با روش AdaPPI، از همان داده‌های ارائه شده در این پژوهش استفاده شده است. از آن‌جا که روش پیشنهادی مبتنی بر یادگیری پیام در شبکه‌های عصبی گرافی نیازمند وزن یال‌ها به‌منظور تنظیم شدت انتشار اطلاعات میان گره‌ها است، وزن هر یال با استفاده از شباهت کسینوسی بین بردارهای ویژگی مبتنی بر عبارات هستی‌شناسی ژن مربوط به هر جفت پروتئین محاسبه شده است. این بردارها ماتریس ویژگی گره‌ها X را تشکیل داده و نحوه استخراج آن‌ها در بخش بعدی تشریح خواهد شد.

به منظور شفاف‌سازی ساختار داده‌ها، مجموعه داده Collins به‌عنوان نمونه بررسی می‌شود. هر مجموعه داده به‌صورت یک فایل جدولی با فرمت CSV ارائه شده و شامل فیلدهای زیر است:

	protein1	protein2	weight
0	YDR143C	YER068W	0.44729
1	YMR207C	YNR016C	0.82921
2	YIL135C	YMR139W	0.0899
3	YNL316C	YOL082W	0.1092
4	YHR211W	YNL255C	0.0001

شکل ۱.۴: نمونه‌ای از فایل مجموعه‌داده شبکه PPI

- **protein1**: شناسه یا نام معنایی[1] پروتئین اول (گره مبدأ).
- **protein2**: شناسه یا نام معنایی پروتئین دوم (گره مقصد).
- **weight**: وزن یال بین دو پروتئین که شدت تعامل یا میزان شباهت زیستی را مدل‌سازی می‌کند.

۲.۲.۴ استخراج ویژگی‌ها از پایگاه هستی‌شناسی ژن

در این بخش، نحوه‌ی استخراج ویژگی‌های زیستی مربوط به هر پروتئین با استفاده از پایگاه داده هستی‌شناسی ژن تشریح می‌شود. ویژگی‌های استخراج شده، ماتریس ویژگی گره‌ها X را در نمایش گرافی شبکه‌های PPI تشکیل داده و به‌عنوان ورودی اصلی شبکه عصبی گرافی در روش پیشنهادی مورد استفاده قرار می‌گیرند.

پایگاه داده GO در سه نسخه اصلی شامل go-basic، go و go-plus ارائه می‌شود که هر یک از نظر میزان جزئیات و همچنین نوع روابط برقرار میان عبارات، تفاوت‌هایی دارند. در این پژوهش، نسخه go-basic به‌عنوان منبع اصلی برای استخراج ویژگی‌ها انتخاب شده است. دلیل این انتخاب آن است که این نسخه عمدتاً شامل روابط سلسله مراتبی پایه بوده و ساختار ساده‌تر و منسجم‌تری نسبت به سایر نسخه‌ها دارد. از سوی دیگر، در نسخه‌های جامع‌تر نظیر go و go-plus، انواع مختلفی از یال‌ها با تفاوت‌های معنایی قابل توجه وجود دارد، به‌گونه‌ای که اجرای الگوریتم Node2Vec بر روی چنین گرافی نمی‌تواند به‌صورت معنادار و قابل تفسیر انجام شود. بنابراین، استفاده از نسخه go-basic امکان

[1] Semantic name

جدول ۱.۴: تفاوت نسخه‌های هستی شناسی ژن

نوع	توضیحات
go-basic	نسخه‌ی فیلترشده‌ی GO که به‌صورت قطعی بدون دور است. در این نسخه، به دلیل عدم وجود دور، برچسب‌ها به‌راحتی به گره‌های والد نسبت داده می‌شوند. انواع یال‌ها در این نسخه شامل part_of، regulates، positively regulates و negatively regulates هستند. همچنین، در این نسخه سه زیرگراف MF، BP و CC به‌طور کامل از یکدیگر جدا بوده و هیچ یالی میان گره‌های این زیرگراف‌ها وجود ندارد.
go	هسته‌ی اصلی GO است که نسبت به نسخه پایه، دو نوع یال has_part و occurs_in را نیز شامل می‌شود. وجود این روابط باعث ایجاد دور در گراف شده و میان زیرگراف‌ها ارتباط برقرار می‌کند.
go-plus	نسخه کامل‌تری از GO است که ارتباط با سایر هستی‌شناسی‌ها، از جمله ChEBI، Cell Ontology و Uberon را نیز شامل می‌شود و دارای مجموعه کاملی از روابط است که صرفاً به GO محدود نمی‌شود.

استخراج تعبیه‌های پایدارتر و قابل تفسیرتر را فراهم می‌کند. خلاصه‌ای از تفاوت میان این نسخه‌ها در جدول ۱.۴ ارائه شده است.

برای هر گونه‌ی زیستی، یک فایل حاشیه‌نویسی ژن[1] وجود دارد که نگاشت میان ژن‌ها و عبارات GO را مشخص می‌کند. در این پژوهش، تمرکز بر گونه مخمر نان است و برای هر ژن، شناسه اختصاصی آن موسوم به SGD ID مورد استفاده قرار می‌گیرد. این شناسه امکان استخراج عبارات GO متناظر با هر ژن را در سه زیرهستی‌شناسی شامل فرآیند زیستی، عملکرد مولکولی و مؤلفه سلولی فراهم می‌کند.

از آن‌جا که در شبکه‌های PPI، پروتئین‌ها اغلب با نام‌های معنایی معرفی می‌شوند، یک گام پیش‌پردازشی برای نگاشت این نام‌ها به SGD ID متناظر آن‌ها ضروری است. بدین‌منظور، از ابزار ارائه‌شده در وب‌سایت yeastgenome.org استفاده شده است که امکان تبدیل نام‌های معنایی پروتئین‌های مخمر به شناسه‌های SGD را به‌صورت خودکار فراهم می‌کند. پس از انجام این نگاشت، تمامی عبارات GO مرتبط با هر پروتئین از فایل حاشیه نویسی ژن استخراج می‌شوند.

[1] Gene annotation file (GAF)

در ساده‌ترین حالت، می‌توان هر پروتئین را به‌صورت یک بردار دودویی با بعدی برابر تعداد کل عبارات GO نمایش داد، به‌طوری که هر مؤلفه نشان دهنده وجود یا عدم وجود یک عبارت GO برای آن پروتئین باشد. به‌عنوان نمونه، شبکه PPI مربوط به مجموعه داده Collins شامل ۲۲۴۸ عبارت GO متمایز است و در نتیجه، نمایش دودویی ویژگی‌های پروتئین‌ها دارای همین بعد خواهد بود. با وجود آن‌که نمایش‌های دودویی مبتنی بر GO به‌دلیل سادگی و تفسیرپذیری، در بسیاری از پژوهش‌های پیشین مورد استفاده قرار گرفته‌اند، این بردارها به‌طور ذاتی تنک و دارای بعد بالا هستند که می‌تواند منجر به کاهش کارایی یادگیری در مدل‌های مبتنی بر شبکه‌های عصبی گرافی شود.

بر این اساس، در این پژوهش علاوه بر استفاده از بردارهای ویژگی دودویی، از بردارهای تعبیه‌شده حاصل از روش‌های یادگیری تعبیه گراف، نظیر Node2Vec، نیز بهره گرفته شده است تا اطلاعات معنایی و ساختاری نهفته در روابط میان عبارات GO به‌صورت فشرده‌تری در نمایش ویژگی‌ها منعکس شود.

به‌منظور دستیابی به نمایش‌های غنی‌تر و کم‌بعدتر، از رویکرد تعبیه‌سازی عبارات GO مشابه روش ارائه‌شده در [۶۹] استفاده شده است. بدین منظور، ابتدا الگوریتم Node2Vec بر روی گراف GO اعمال شده و برای هر عبارت GO یک بردار تعبیه‌ای استخراج می‌شود. در پژوهش حاضر، الگوریتم Node2Vec به‌طور مستقیم بر روی گراف GO اجرا نشده است. در عوض، از تعبیه‌های از پیش محاسبه‌شده‌ای استفاده شده است که از مخزن گیت‌هاب[1] استخراج گردیده‌اند. در این مخزن، الگوریتم Node2Vec بر روی گراف go-basic اعمال شده و برای هر یک از اصطلاحات GO در زیرفضاهای BP، MF و CC، یک بردار تعبیه مستقل با بعد ۱۲۸ یادگیری شده است.

با فرض $G_S \in \mathbb{R}^{m_S \times d}$ به‌عنوان ماتریس تعبیه عبارات GO در زیرفضای $S \in \{\mathrm{BP}, \mathrm{MF}, \mathrm{CC}\}$، که در آن m_S تعداد عبارات GO در زیرفضای S و d بعد تعبیه آموخته‌شده برای هر عبارت است، و با درنظرگرفتن $p_i \in V$ به‌عنوان پروتئین iـام در شبکه PPI، ابتدا مجموعه عبارات GO منتسب به این

[1] https://github.com/marcopodda/go-node2vec

پروتئین در هر زیرفضا را به‌صورت $f_S(p_i)$ تعریف می‌کنیم. سپس، بردار هر پروتئین در هر زیرفضا از میانگین تعبیه عبارات متناظر آن به‌دست می‌آید:

$$\mathbf{h}_i^S = \frac{1}{|f_S(p_i)|} \sum_{g \in f_S(p_i)} \mathbf{G}_S[g], \qquad S \in \{\mathrm{BP}, \mathrm{MF}, \mathrm{CC}\}, \tag{۱.۴}$$

که در آن $\mathbf{G}_S[g] \in \mathbb{R}^d$ بردار تعبیه عبارت GO مربوط به g در زیرفضای S است. در نهایت، نمایش نهایی پروتئین p_i با الحاق بردارهای حاصل از سه زیرفضای MF،BP و CC تشکیل می‌شود:

$$\mathbf{x}_i = \mathbf{h}_i^{\mathrm{BP}} \parallel \mathbf{h}_i^{\mathrm{MF}} \parallel \mathbf{h}_i^{\mathrm{CC}} \in \mathbb{R}^{3d}, \tag{۲.۴}$$

که در آن $\parallel$ عملگر الحاق بردارها است. بنابراین، بردار نهایی هر پروتئین اطلاعات معنایی حاشیه‌نویسی‌های GO آن را از هر سه جنبه عملکرد مولکولی، فرایند زیستی و مؤلفه سلولی در بر می‌گیرد.

به بیان ساده‌تر، عبارات تعبیه GO هر پروتئین در هر زیرفضا میانگین‌گیری شده و در نهایت، بردارهای حاصل از سه زیرهستی‌شناسی با یکدیگر الحاق شده و یک بردار ویژگی نهایی با بعد ۳۸۴ برای هر پروتئین تشکیل می‌شود. این بردار به‌عنوان نمایش ویژگی گره متناظر با هر پروتئین در ماتریس X قرار گرفته و به‌صورت یکپارچه در فرآیند یادگیری شبکه عصبی گرافی روش پیشنهادی مورد استفاده قرار می‌گیرد. در جدول ۲.۴ اطلاعات مربوط به هر یک از مجموعه‌داده‌ها و ویژگی‌های آنها نشان داده شده است.

جدول ۲.۴: اطلاعات مجموعه داده‌های PPI

مجموعه داده	تعداد پروتئین	تعداد تعاملات	بعد ویژگی دودویی	بعد ویژگی تعبیه	میانگین درجه	درجه بیشینه
Collins	۱۶۲۲	۹۰۷۴	۲۲۴۸	۳۸۴	۱۸۹.۱۱	۱۲۷
Krogan Core	۲۷۰۸	۷۱۲۳	۳۵۲۹	۳۸۴	۲۶۱.۵	۱۴۱
Krogan Extended	۳۶۷۲	۱۴۳۱۷	۴۲۶۱	۳۸۴	۷۹۸.۷	۲۱۳
DIP	۴۹۲۸	۱۷۲۰۱	۴۷۱۴	۳۸۴	۹۸۱.۶	۲۸۳
Biogrid	۵۶۴۰	۵۹۷۴۸	۴۹۸۶	۳۸۴	۱۸۷.۲۱	۲۵۷۰

۳.۲.۴ مجموعه‌های پروتئینی مرجع و پروتکل ارزیابی

به‌منظور ارزیابی و صحت‌سنجی عملکرد الگوریتم پیشنهادی در شناسایی پیمانه‌های عملکردی پروتئینی، استفاده از مجموعه‌های پروتئینی مرجع ضروری است تا بتوان نتایج به دست آمده را با دانش زیستی موجود مقایسه کرد. مجموعه‌های پروتئینی مرجع وابسته به گونه زیستی بوده و برای گونه مخمر نان چندین مجموعه مرجع شناخته شده در دسترس است که از جمله مهم‌ترین آن‌ها می‌توان به MIPS و CYC2008 اشاره کرد. در مقایسه روش‌های محاسباتی مختلف، انتخاب مجموعه پروتئینی مرجع مورد استفاده نقش تعیین‌کننده‌ای در تفسیر نتایج ایفا می‌کند. از این رو، با توجه به این‌که روش پایه مورد استفاده برای مقایسه با روش پیشنهادی، چارچوب AdaPPI است، در این پژوهش نیز از همان مجموعه‌های پروتئینی مرجع به‌کاررفته در آن مطالعه استفاده شده است. این مجموعه ترکیبی از سایر مجموعه‌های پروتئینی شامل MIPS، CYC2008، Aloy، SGD و TAP06 می‌باشد.

این مجموعه پروتئینی مرجع به‌صورت یک فایل متنی ذخیره شده است که در آن، هر خط متناظر با یک پیمانه پروتئینی بوده و شامل نام‌های معنایی پروتئین‌های عضو آن پیمانه است که با خط فاصله از یکدیگر جدا شده‌اند. شکل ۲.۴ نمونه‌ای از ساختار این مجموعه مرجع را نشان می‌دهد.

به‌منظور ارزیابی مجموعه‌های پروتئینی استخراج شده از هر شبکه PPI، ابتدا تنها پروتئین‌هایی که در شبکه PPI متناظر حضور دارند، در هر مجموعه مرجع حفظ می‌شوند. سپس، مجموعه‌هایی که تعداد پروتئین‌های آن‌ها کمتر از سه عضو باشد حذف می‌گردند. این فرآیند پیش‌پردازش، مطابق با

```
YIR022W YML055W YJR010C-A
YDL159W YGR040W YBL016W YDR103W YLR362W
YBR288C YPL195W YGR261C YJL024C
YNL082W YCR092C YOL090W
YPR051W YEL053C YCR020C-A
YKL003C YGL129C YPL118W YKL155C YJR113C YBR251W YDR041W YMR158W YNL306W YBL090W YDR347W YDR036C YGR084C YDR337W YBR146W YHL004W
YNL311C YDR219C YMR275C YER116C YER125W YDR306C YDL013W YOR057W YML111W YLR224W YJL204C YJL047C
YNL103W YIR017C YDR253C YPL038W YJR060W
YPR020W Q0130 Q0085 Q0080 YDR377W YML081C-A YOL077W-A YDR322C-A YLR295C
```

شکل ۲.۴: نمونه‌ای از مجموعه‌های پروتئینی در فایل مجموعه مرجع

پروتکل ارزیابی به‌کاررفته در روش AdaPPI انجام شده و امکان مقایسه منصفانه و سازگار نتایج روش پیشنهادی با روش‌های مرجع را فراهم می‌کند.

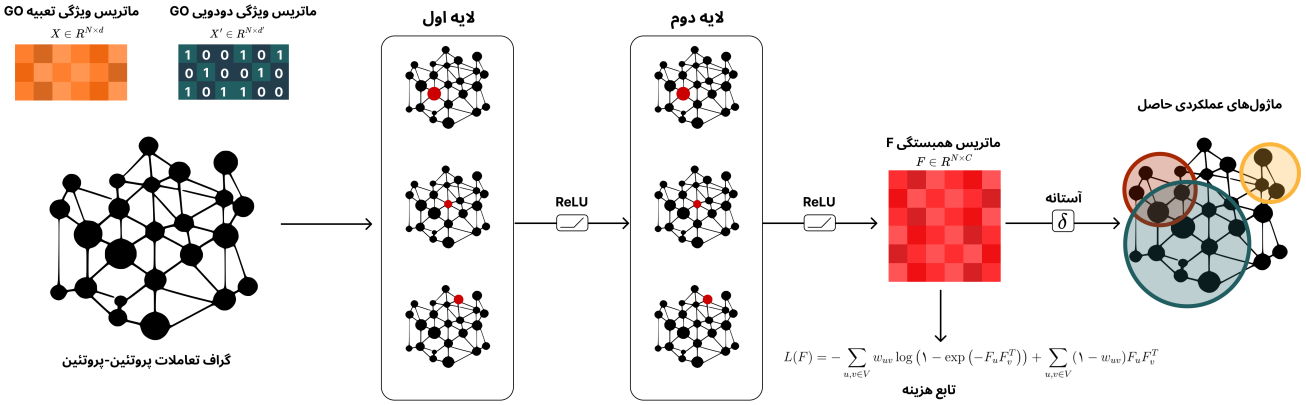
۳.۴ روش پیشنهادی

در بخش پیشین، مجموعه داده‌های مورد استفاده در این پژوهش و نیز فرآیند استخراج ویژگی‌ها به‌صورت جامع مورد بررسی قرار گرفت. در این بخش، ابتدا چارچوب کلی روش پیشنهادی برای شناسایی پیمانه‌های عملکردی پروتئینی معرفی می‌شود و سپس پیاده‌سازی‌ها و تغییرات اعمال شده بر این چارچوب مورد تحلیل قرار می‌گیرند. بدین منظور، ابتدا چارچوب کلی روش پیشنهادی و نحوه توسعه آن بر پایه مدل NOCD که به‌طور مفصل در فصل پژوهش‌های پیشین بررسی شده است، تشریح می‌شود. در ادامه، معماری‌های مختلف شبکه‌های عصبی گرافی به‌کاررفته در این پژوهش معرفی و تحلیل خواهند شد. در گام بعد، تأثیر انواع ویژگی‌های ورودی بر عملکرد مدل مورد بررسی قرار می‌گیرد و در نهایت، روش ترکیبی پیشنهادی ارائه و تشریح می‌شود.

۱.۳.۴ چارچوب کلی روش پیشنهادی

در چارچوب پیشنهادی، همان‌گونه که در شکل ۳.۴ مشاهده می‌شود، ابتدا گراف تعامل پروتئین‌ـ پروتئین به همراه ویژگی‌های متناظر با هر پروتئین به‌عنوان ورودی به یک شبکه عصبی گرافی داده می‌شود. خروجی این شبکه، یک ماتریس وابستگی به‌صورت $F \in \mathbb{R}^{n \times c}$ است که در آن n نشان دهنده تعداد پروتئین‌ها و c بیانگر تعداد خوشه‌ها می‌باشد. هر سطر از این ماتریس میزان تعلق یک پروتئین به

خوشه‌های مختلف را نشان می‌دهد.



شکل ۳.۴: نمایی از چارچوب کلی روش پیشنهادی

انتخاب ویژگی‌های ورودی نیز نقش مهمی در عملکرد مدل ایفا می‌کند. در این پژوهش، انواع مختلف ویژگی‌های ورودی مورد ارزیابی قرار گرفته‌اند که شامل ویژگی‌های دودویی مبتنی بر اصطلاحات GO، تعبیه برداری اصطلاحات GO و همچنین استفاده همزمان از هر دو نوع ویژگی می‌باشد. نتایج حاصل از این بررسی‌ها در بخش‌های بعدی ارائه و تحلیل خواهند شد.

همچنین، به‌منظور آموزش شبکه عصبی گرافی، تعریف یک تابع هزینه مناسب امری ضروری است. در روش پیشنهادی، تابع هزینه پایه مشابه روش NOCD در نظر گرفته شده است، با این تفاوت که در این پژوهش نسخه‌ای وزن‌دار از آن معرفی شده است. اعمال وزن در تابع هزینه موجب بهبود عملکرد مدل در شناسایی ساختارهای هم‌پوشان در گراف تعامل پروتئین_پروتئین شده است که جزئیات آن در ادامه این فصل تشریح خواهد شد. علاوه بر این، انتخاب معماری مناسب برای شبکه عصبی گرافی یکی از چالش‌های اصلی این پژوهش بوده است. در این تحقیق، تأثیر معماری‌های مختلف شبکه‌های عصبی گرافی بر عملکرد شناسایی مجموعه‌های پروتئینی مورد بررسی و مقایسه قرار گرفته است.

در انتها، روش NOCD برای استخراج خوشه‌ها نیاز به تعیین یک مقدار آستانه مشخص بر روی ماتریس

وابستگی دارد. با این حال، انتخاب آستانه مناسب همواره چالش برانگیز بوده و می‌تواند بر نتایج نهایی تأثیر قابل توجهی داشته باشد. از این رو، در روش پیشنهادی این محدودیت حذف شده و خوشه‌ها بر اساس مجموعه‌ای از آستانه‌های مختلف استخراج می‌شوند. این رویکرد امکان تحلیل پایداری خوشه‌ها و کاهش وابستگی نتایج به یک مقدار آستانه خاص را فراهم می‌کند که دلایل و مزایای آن در ادامه مورد بحث قرار می‌گیرد.

۲.۳.۴ تابع هزینه

در این بخش، تابع هزینه پیشنهادی این پژوهش تشریح می‌شود. به‌عنوان نقطه شروع، از تابع هزینه روش NOCD استفاده می‌کنیم که سازوکار آن به‌طور مفصل در فصل پژوهش‌های پیشین مورد بررسی قرار گرفته است. این تابع هزینه مبتنی بر یک مدل مولد احتمالی بوده و هدف آن یادگیری ماتریس وابستگی هم‌پوشان گره‌ها به پیمانه‌ها است.

تابع هزینه NOCD به‌صورت معادله ۳.۴ تعریف می‌شود.

$$L(F) = -\sum_{(u,v)\in E} \log\left(1 - \exp(-F_u F_v^\top)\right) + \sum_{(u,v)\notin E} F_u F_v^\top \qquad (۳.۴)$$

که در آن $F \in \mathbb{R}^{|V|\times K}$ ماتریس وابستگی گره‌ها به K پیمانه پنهان است، F_u بردار وابستگی گره u، و E مجموعه یال‌های موجود در گراف می‌باشد. جمله اول تابع هزینه متناظر با جفت گره‌هایی است که بین آن‌ها یال وجود دارد و احتمال مشاهده تعامل را بیشینه می‌کند، در حالی که جمله دوم به جفت گره‌های بدون یال مربوط بوده و به‌عنوان یک منظم‌کننده برای جلوگیری از ایجاد تعاملات کاذب عمل می‌کند.

به‌منظور بهبود عملکرد این تابع هزینه در زمینه شناسایی پیمانه‌های عملکردی پروتئینی در شبکه‌های PPI، در این پژوهش دو نوآوری متفاوت بر روی تابع هزینه NOCD مورد بررسی قرار گرفته است.

نوآوری نخست مبتنی بر بازسازی ماتریس همسایگی مرتبه دوم به‌جای ماتریس همسایگی مرتبه اول است و نوآوری دوم به وارد کردن وزن تعاملات پروتئین‌ـ پروتئین در فرمول‌بندی تابع هزینه اختصاص دارد. در ادامه، هر یک از این توسعه‌ها به تفصیل تشریح می‌شوند.

بازسازی ماتریس همسایگی مرتبه دوم

ایده استفاده از ماتریس همسایگی مرتبه دوم از تحلیل ساختار شبکه‌های PPI و بررسی مجموعه‌های پروتئینی مرجع الهام گرفته شده است. بررسی تجربی این شبکه‌ها نشان می‌دهد که پروتئین‌های عضو یک پیمانه عملکردی لزوماً دارای تعامل مستقیم (یال مرتبه اول) با یکدیگر نیستند، بلکه در بسیاری از موارد، ارتباط آن‌ها از طریق مسیرهای کوتاه با طول دو یا حتی سه یال برقرار می‌شود. به‌ویژه، وجود تعاملات مرتبه دوم میان پروتئین‌های یک پیمانه به‌طور گسترده مشاهده می‌شود.

بر این اساس، به‌جای استفاده صرف از ماتریس همسایگی مرتبه اول A، از ماتریس همسایگی مرتبه دوم برای تعریف ساختار تعاملات استفاده می‌شود. ماتریس همسایگی مرتبه دوم به‌صورت $A^2 = AA$ محاسبه شده و سپس به‌صورت یک ماتریس دودویی آستانه‌گذاری می‌شود:

$$\hat{A}_{ij} = \begin{cases} 1 & \text{if } A^2_{ij} > 0, \\ 0 & \text{otherwise} \end{cases} \tag{۴.۴}$$

در این حالت، وجود یک مقدار غیرصفر در A^2_{ij} نشان‌دهنده وجود حداقل یک مسیر با طول دو میان گره‌های i و j است. در نسخه اصلاح شده تابع هزینه، به‌جای استفاده از ماتریس همسایگی A برای تعیین مجموعه یال‌ها E، از ماتریس $\hat{A}$ استفاده می‌شود. این تغییر امکان مدل‌سازی تعاملات غیرمستقیم اما زیستی معنادار را در فرآیند یادگیری فراهم می‌کند.

علاوه بر این، به‌منظور ایجاد تعادل میان اطلاعات تعاملات مستقیم و غیرمستقیم، یک نسخه ترکیبی

از تابع هزینه نیز در نظر گرفته شده است که به‌صورت یک ترکیب محدب از دو تابع هزینه مبتنی بر A و $\hat{A}$ مطابق معادله ۵.۴ تعریف می‌شود.

$$L(F) = (1 - \lambda)\, L_A(F) + \lambda\, L_{\hat{A}}(F) \tag{۵.۴}$$

که در آن $\lambda \in (0, 1)$ یک ابرپارامتر تنظیم‌کننده است و میزان تأثیر تعاملات مرتبه دوم را در فرآیند یادگیری کنترل می‌کند. این فرمول‌بندی انعطاف‌پذیری لازم را برای سازگاری تابع هزینه با ساختارهای متفاوت شبکه‌های PPI فراهم می‌آورد.

استفاده از وزن تعاملات

یکی دیگر از نوآوری‌های اعمال شده در این پژوهش، وزن‌دار کردن تعاملات پروتئین‌ـپروتئین در فرآیند یادگیری ماتریس وابستگی F است. انگیزه اصلی این رویکرد، در نظر گرفتن میزان اطمینان و شدت تعاملات زیستی و کاهش اثر یال‌های ضعیف یا نویزی در فرآیند شناسایی پیمانه‌های عملکردی می‌باشد.

بدین منظور، همان‌گونه که در بخش مجموعه داده‌ها توضیح داده شد، برای شبکه‌های PPI وزن‌دار از وزن‌های ارائه شده در خود مجموعه داده استفاده شده است. در مقابل، برای شبکه‌هایی که فاقد وزن تعاملات هستند، وزن هر تعامل به کمک شباهت کسینوسی میان بردارهای تعبیه‌ی ویژگی‌های GO مربوط به دو پروتئین محاسبه شده است. این رویکرد امکان وارد کردن دانش عملکردی زیستی مستقل از ساختار گراف را به تابع هزینه فراهم می‌سازد و به‌ویژه در شبکه‌های بدون وزن، نقش مؤثری در هدایت فرآیند یادگیری ایفا می‌کند.

به‌منظور لحاظ کردن وزن تعاملات در چارچوب NOCD، تابع هزینه این روش به صورت وزن‌دار و مطابق با معادله ۶.۴ بازنویسی شده است. در این فرمول‌بندی، وزن w_{uv} بیانگر قدرت یا میزان اطمینان

تعامل بین دو پروتئین u و v می‌باشد. بدیهی است در صورتی که بین دو پروتئین $u, v \in V$ هیچ‌گونه تعامل ثبت‌شده‌ای وجود نداشته باشد، مقدار $w_{uv} = ۰$ در نظر گرفته می‌شود.

$$L(F) = -\sum_{u,v \in V} w_{uv} \log\left(۱ - \exp\left(-F_u F_v^T\right)\right) + \sum_{u,v \in V} (۱ - w_{uv}) F_u F_v^T \qquad (۶.۴)$$

در این تابع هزینه، تعاملاتی با وزن بالاتر سهم بیشتری در جمله نخست داشته و مدل را به بازسازی دقیق‌تر این یال‌ها ترغیب می‌کنند، در حالی که تعاملات با وزن پایین یا صفر، تأثیر کمتری در فرآیند یادگیری داشته و عملاً مشابه یال‌های غایب در نظر گرفته می‌شوند. برخلاف تابع هزینه NOCD که تمامی تعاملات مشاهده شده را به‌صورت هم‌ارزش مدل‌سازی می‌کند، نسخه وزن‌دار پیشنهادی امکان تمایز بین تعاملات با درجات مختلف اعتبار زیستی را فراهم کرده و به بهبود کیفیت شناسایی پیمانه‌های عملکردی در شبکه‌های PPI منجر می‌شود.

در پایان باید ذکر کرد که در فصل بعد یعنی فصل نتایج، عملکرد تجربی هر یک از نسخه‌های معرفی شده از تابع هزینه NOCD به صورت کمی مورد بررسی و مقایسه قرار می‌گیرند.

۳.۳.۴ شبکه‌های عصبی گرافی

انتخاب معماری مناسب شبکه عصبی گرافی نقش تعیین کننده‌ای در عملکرد الگوریتم شناسایی پیمانه‌های عملکردی ایفا می‌کند، چرا که نوع مدل گرافی به‌طور مستقیم بر نحوه استخراج و انتشار اطلاعات ساختاری و ویژگی‌محور در شبکه اثرگذار است. از همین رو، در این پژوهش به بررسی و مقایسه چندین معماری متداول و پیشرفته از شبکه‌های عصبی گرافی پرداخته شده است. معماری‌های مورد مطالعه شامل شبکه‌های عصبی گرافی مبتنی بر کانولوشن، مدل‌های توجه‌محور و شبکه‌های دارای سازوکار پرش دانش می‌باشند. در ادامه، نقش هر یک از این معماری‌ها در بهبود فرآیند شناسایی پیمانه‌های عملکردی به‌صورت مجزا در شبکه‌های PPI مورد بررسی قرار می‌گیرد.

شبکه عصبی گرافی پیچشی

نحوه‌ی عملکرد شبکه‌های عصبی گرافی پیچشی در فصل مفاهیم بنیادی و به‌ویژه در بخش مفاهیم محاسباتی به‌صورت تفصیلی مورد بررسی قرار گرفته است. در این بخش، تمرکز اصلی بر معرفی و تحلیل ابرپارامترهایی است که برای معماری شبکه‌ی پیشنهادی در نظر گرفته شده‌اند. یکی از مهم‌ترین ابرپارامترهای این معماری، تعداد لایه‌های شبکه است، زیرا این پارامتر به‌صورت مستقیم با پدیده‌ی هموارسازی بیش‌ازحد یا هموارسازی ناکافی[۱] در ارتباط است. علاوه بر آن، ابعاد بازنمایی ویژگی‌ها نیز یکی از دیگر ابرپارامترهای کلیدی محسوب می‌شود که نقش مهمی در کیفیت استخراج ویژگی‌ها از گراف ایفا می‌کند.

در مجموعه‌ای از آزمایش‌های تکمیلی، تأثیر استفاده از لایه‌ی نرمال‌سازی دسته‌ای[۲]، عبارت منظم‌سازی L2[۳] در تابع هزینه، استفاده از اتصالات باقیمانده[۴] و نیز دراپ‌اوت[۵] در ساختار شبکه مورد آزمایش قرار گرفت. نتایج این ارزیابی‌ها نشان داد که افزودن هر یک از این اجزا به معماری پیشنهادی، منجر به کاهش نسبی عملکرد مدل شده است. از همین روی، در معماری نهایی روش پیشنهادی از هیچ یک از روش‌های منظم‌سازی ذکر شده استفاده نشده است.

شبکه‌های عصبی گرافی توجه‌محور

در شبکه‌های عصبی گرافی توجه‌محور، افزون بر ابرپارامترهایی چون تعداد لایه‌ها و ابعاد بازنمایی، تعداد سرهای سازوکار توجه نیز نقش بسیار مهمی در عملکرد مدل ایفا می‌کند. بر این اساس، در مجموعه آزمایش‌های انجام شده، تأثیر تعداد سرهای متفاوت شامل ۱، ۴ و ۸ سر توجه به‌طور جداگانه نیز بررسی شده است.

---

[1] Under smoothing

[2] Batch normalization layer

[3] L2 regularization term

[4] Residual connections

[5] Dropout

به‌طور کلی، انتظار می‌رود که عملکرد شبکه‌های عصبی گرافی توجه‌محور در مقایسه با شبکه‌های عصبی گرافی پیچشی بهبود قابل‌توجهی داشته باشد. دلیل این امر آن است که در شبکه‌های عصبی گرافی پیچشی، در فرآیند به‌روزرسانی بازنمایی یک پروتئین، تمامی همسایگان با وزن یکسان در نظر گرفته می‌شوند. در مقابل، شبکه‌های عصبی گرافی توجه‌محور با یادگیری ضرایب توجه، میزان اهمیت نسبی هر یک از همسایگان را به‌صورت پویا مدل‌سازی می‌کنند و در نتیجه، بازنمایی غنی‌تر و دقیق‌تری بر اساس میزان تأثیر هر همسایه ایجاد می‌نمایند.

علاوه بر نسخه‌ی پایه‌ی شبکه‌ی عصبی گرافی توجه‌محور، در این بخش معماری‌های پیشرفته‌تری از این خانواده، از جمله SuperGAT و GATv2، نیز مورد بررسی قرار گرفته‌اند تا تأثیر این ساختارهای بهبودیافته بر عملکرد مدل به‌صورت دقیق و نظام‌مند ارزیابی شود.

شبکه عصبی گرافی دارای سازوکار پرش دانش

با توجه به این واقعیت که در شبکه‌های PPI، پروتئین‌های مختلف برای دستیابی به بازنمایی‌های مؤثر، به اطلاعات همسایگی در مرتبه‌های متفاوتی نیاز دارند، بررسی عملکرد سازوکار JKNet در این پژوهش ضروری به نظر می‌رسد. این سازوکار امکان تجمیع بازنمایی‌های حاصل از لایه‌های مختلف شبکه عصبی گرافی را فراهم می‌کند و بدین ترتیب، وابستگی هر گره به عمق‌های متفاوت شبکه به‌طور تطبیقی مدل‌سازی می‌شود. در این راستا، نسخه‌های گوناگونی از JKNet شامل بیشینه‌گیری، الحاق و سازوکار توجه مبتنی بر شبکه عصبی Bi-LSTM مورد بررسی و ارزیابی قرار گرفته‌اند. در ادامه، مروری کلی بر هر یک از این روش‌ها ارائه می‌شود:

- **بیشینه‌گیری:** در این روش، بردارهای بازنمایی حاصل از هر لایه شبکه عصبی برای هر پروتئین، به‌صورت مؤلفه‌به‌مؤلفه با یکدیگر بیشینه‌گیری می‌شوند و بردار حاصل به‌عنوان بازنمایی نهایی آن پروتئین در نظر گرفته می‌شود.
- **الحاق:** در این رویکرد، بازنمایی‌های تولید شده در لایه‌های مختلف شبکه عصبی گرافی با

یکدیگر الحاق شده و بردار به‌دست‌آمده به‌عنوان بازنمایی نهایی پروتئین مورد استفاده قرار می‌گیرد.

- **سازوکار توجه مبتنی بر شبکه عصبی Bi-LSTM:** در این روش، برای هر پروتئین، بازنمایی‌های حاصل از لایه‌های مختلف شبکه به‌صورت یک توالی به یک شبکه عصبی بازگشتی دوسویه از نوع Bi-LSTM داده می‌شوند. سپس با بهره‌گیری از سازوکار توجه، میزان اهمیت هر بازنمایی لایه‌ای به‌صورت تطبیقی یاد گرفته شده و در نهایت، با ترکیب وزن‌دار این بازنمایی‌ها، بازنمایی نهایی هر پروتئین تولید می‌شود.

شایان ذکر است که سازوکار JKNet مستقل از معماری شبکه عصبی گرافی پایه بوده و قابلیت ترکیب با مدل‌های مختلف را دارد. در این پژوهش، شبکه عصبی گرافی پایه از نوع GAT در نظر گرفته شده است.

۴.۳.۴ توابع فعال‌سازی

توابع فعال‌سازی نقش اساسی در شبکه‌های عصبی ایفا می‌کنند، زیرا با ایجاد غیرخطی‌بودن در مدل، امکان یادگیری الگوها و روابط پیچیده میان داده‌ها را فراهم می‌سازند. ازاین‌رو، در این پژوهش تأثیر انتخاب تابع فعال‌سازی بر عملکرد روش پیشنهادی مورد بررسی و تحلیل قرار گرفته است. توابع فعال‌سازی ارزیابی‌شده در این مطالعه شامل موارد زیر هستند:

- **ReLU**[1]: این تابع با صفر کردن مقادیر منفی و عبور مستقیم مقادیر مثبت، به یادگیری پایدار و کاهش مشکل ناپدیدشدن گرادیان کمک می‌کند:

$$\mathrm{ReLU}(x) = \max(0, x) \qquad (۷.۴)$$

[1] Rectified Linear Unit

- **GELU**[1]: تابع GELU با وزن‌دهی نرم به ورودی‌ها بر اساس توزیع نرمال، رفتار غیرخطی پیوسته‌تری نسبت به ReLU ایجاد می‌کند:

$$\begin{aligned} \mathrm{GELU}(x) &= x\,\Phi(x) = x \cdot \frac{۱}{۲}\left(۱ + \mathrm{erf}\left(\frac{x}{\sqrt{۲}}\right)\right) \\ erf(x) &= \frac{۲}{\sqrt{\pi}} \int_{۰}^{x} e^{-t^{۲}} dt \end{aligned} \tag{۸.۴}$$

- **ELU**[2]: این تابع با اختصاص مقادیر منفی اشباع‌شده برای ورودی‌های منفی، میانگین خروجی‌ها را به صفر نزدیک کرده و همگرایی شبکه را بهبود می‌بخشد:

$$\mathrm{ELU}(x) = \begin{cases} x, & x > ۰, \\ \alpha\left(e^{x} - ۱\right), & x \leq ۰ \end{cases} \tag{۹.۴}$$

شایان ذکر است که با توجه به ماهیت تابع هزینه پایه مورد استفاده در این پژوهش، یعنی NOCD، که نیازمند ماتریس وابستگی F با شرط نامنفی بودن عناصر آن به‌صورت $\forall i, j;\ F_{ij} \geq ۰$ می‌باشد، تابع فعال‌سازی لایه نهایی شبکه در تمامی آزمایش‌ها به‌صورت ثابت از نوع ReLU در نظر گرفته شده است.

۵.۳.۴ استخراج مجموعه‌های پروتئینی و تعیین آستانه

در روش پیشنهادی این پژوهش، به‌منظور استخراج پیمانه‌های عملکردی از ماتریس وابستگی به‌دست‌آمده از شبکه آموزش‌دیده، از تعیین یک مقدار آستانه ثابت استفاده نشده است. در واقع آستانه‌های بالاتر، پیمانه‌هایی با ضریب اطمینان بالا را دربر می‌گیرند ولی بسیاری از پیمانه‌های موجود را از دست می‌دهند،

[1] Gaussian Error Linear Unit

[2] Exponential Linear Unit

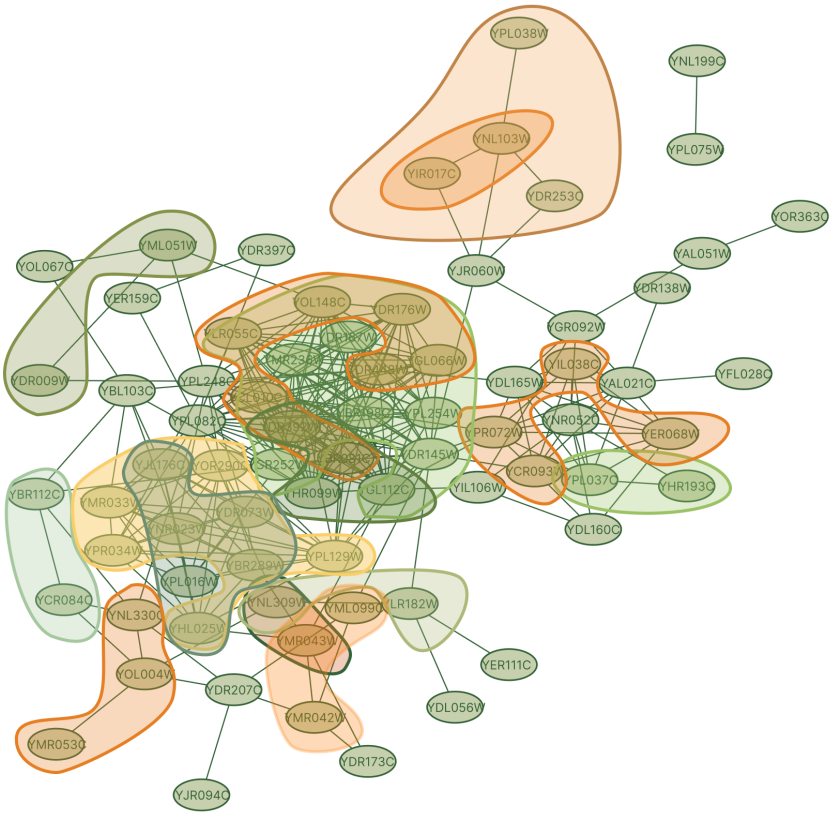
این مورد باعث افزایش دقت و در مقابل کاهش بازیابی می شود. در آستانه‌های پایین‌تر این موضوع برعکس می‌باشد. در نتیجه با توجه به هم‌پوشانی موجود در شبکه‌های PPI و همینطور برقراری تعادل بین دقت و بازیابی الگوریتم در این پژوهش تصمیم به استفاده از آستانه تجمیعی شده است. در روش پیشنهادی این پژوهش، مجموعه‌های متناظر با آستانه‌های مختلف در بازه ۰٫۷ , ۰٫۳, . . . , ۰٫۲ به‌صورت مستقل استخراج می‌شوند. سپس اجتماع این مجموعه‌های پروتئینی محاسبه شده و تنها مجموعه‌های یکتا نگه داشته می‌شوند تا از ایجاد مجموعه‌های تکراری جلوگیری شود.

انگیزه اصلی این رویکرد همانطور که در تصویر ۴.۴ قابل مشاهده است، وجود هم‌پوشانی میان مجموعه‌های پروتئینی است. به‌گونه‌ای که با بررسی پیمانه‌های موجود در مجموعه مرجع مشاهده می‌شود برخی پیمانه‌های کوچک‌تر به‌طور کامل درون چند پیمانه بزرگ‌تر قرار گرفته‌اند. بنابراین، انتخاب تنها یک آستانه مشخص قادر به نمایش مناسب این ساختار هم‌پوشان نبوده و استفاده از چندین آستانه امکان شناسایی دقیق‌تر این روابط تو در تو را فراهم می‌کند.

۴.۴ جمع‌بندی

در این فصل، ابتدا مروری بر شبکه‌های PPI ارائه شد و سپس نحوه بهره‌گیری از انواع ویژگی‌های مربوط به پروتئین‌های موجود در این شبکه‌ها مورد بررسی قرار گرفت. در ادامه، مجموعه‌های مرجع مورد استفاده معرفی شده و روش ارزیابی چارچوب پیشنهادی بر اساس این مجموعه‌ها تشریح گردید. پس از آن، چارچوب کلی روش پیشنهادی این پژوهش به‌صورت جامع بیان شد و تابع هزینه به‌کاررفته در آن، که نسخه بهبودیافته‌ای از روش NOCD و از نوآوری‌های این پژوهش محسوب می‌شود، مورد توضیح قرار گرفت.

در گام بعد، انواع معماری‌های شبکه‌های عصبی گرافی که در این پژوهش مورد آزمایش قرار گرفته‌اند، بررسی شدند. همچنین، انواع توابع فعال‌سازی ارزیابی‌شده در این پژوهش معرفی شدند. در پایان،



شکل ۴.۴: نمونه‌ای از هم‌پوشانی‌های مجموعه‌های پروتئینی در مجموعه مرجع

نحوه‌ی استخراج مجموعه‌های پروتئینی و چگونگی تعیین آستانه‌های مورد نیاز در روش پیشنهادی به‌طور کامل بررسی و تشریح شده است.

فصل ۵

نتایج

۱.۵ مقدمه

در این فصل، ابتدا محیط پیاده‌سازی روش‌های محاسباتی مورد استفاده در این پژوهش معرفی می‌شود. سپس، ابرپارامترهای مربوط به هر یک از روش‌ها تشریح خواهد شد. در ادامه، روش‌های مختلف به‌کاررفته در این پژوهش تعریف شده و نتایج حاصل از به‌کارگیری معماری‌های گوناگون شبکه‌های عصبی گرافی، شامل شبکه عصبی گرافی پیچشی، شبکه عصبی گرافی مبتنی بر سازوکار توجه و شبکه عصبی گرافی مجهز به سازوکار پرش دانش، بر روی مجموعه داده PPI گزارش می‌گردد. در گام بعدی، نتایج مربوط به انواع توابع فعال‌سازی مورد بررسی و تحلیل قرار می‌گیرد. در ادامه، روش پیشنهادی بر اساس آزمایش‌های انجام شده و همچنین تأثیر تعیین آستانه به‌صورت بازه‌ای مورد ارزیابی قرار گرفته و در نهایت، نتایج نهایی با پژوهش‌های پیشین در زمینه کشف پیمانه‌های عملکردی در شبکه‌های PPI مقایسه می‌شود.

۲.۵ محیط پیاده‌سازی

در پیاده‌سازی روش‌های محاسباتی این پژوهش، از زبان برنامه‌نویسی پایتون نسخه ۳/۱۲ استفاده شده است. به‌منظور خواندن و پردازش فایل‌های مربوط به هستی‌شناسی ژن، کتابخانه goatools به‌کار گرفته شده و پیاده‌سازی الگوریتم‌های یادگیری و شبکه‌های عصبی گرافی با استفاده از کتابخانه‌های torch و torch-geometric انجام شده است. همچنین، تعبیه‌های مربوط به عبارات GO که از الگوریتم Node2Vec حاصل شده‌اند، به کمک کتابخانه gensim بارگذاری شده‌اند.

برای ایجاد و نمایش گراف‌ها، از کتابخانه‌های NetworkX و Matplotlib استفاده شده است. در نهایت، برای تابع هزینه پایه، از پیاده‌سازی ارائه شده در پژوهش NOCD که در مخزن گیت‌هاب این پروژه[1] در دسترس است بهره گرفته شده و بردارهای تعبیه مربوط به هستی‌شناسی ژن نیز از مخزن گیت‌هاب پروژه go-node2vec[2] استخراج و مورد استفاده قرار گرفته‌اند. در جدول ۱.۵ اطلاعات مربوط به نسخه هر یک از این کتابخانه‌ها ذکر شده‌اند.

جدول ۱.۵: مشخصات کتابخانه‌های مورد استفاده در این پژوهش به همراه نسخه مربوطه

کتابخانه	نسخه
torch	۱/۵/۲
torch-geometric	۱/۶/۲
pandas	۳/۲/۲
numpy	۴/۲۶/۱
goatools	۱۲/۴/۱
gensim	۳/۳/۴
networkx	۲/۴/۳
matplotlib	۲/۹/۳

[1] github.com/shchur/overlapping-community-detection

[2] github.com/marcopodda/go-node2vec

۳.۵ نتایج مربوط به عملکرد شبکه‌های عصبی گرافی و تابع هزینه

در این بخش، عملکرد دو معماری پرکاربرد شبکه‌های عصبی گرافی شامل GCN و GAT در مسئله شناسایی پیمانه‌های عملکردی مورد ارزیابی و مقایسه قرار می‌گیرد. هدف از این بررسی، تحلیل تأثیر نوع معماری و سناریوهای مختلف تابع هزینه بر کیفیت خوشه‌بندی در شبکه‌های PPI است.

کلیه آزمایش‌ها تحت مجموعه‌ای از شرایط یکسان انجام شده‌اند. در تمامی سناریوها، ویژگی‌های ورودی به‌صورت دودویی بوده و شامل زیرهستی‌شناسی‌های فرآیندهای زیستی و عملکرد مولکولی می‌باشند. بر اساس انجام آزمایش‌های انجام شده و تحلیل نتایج حاصل، تعداد لایه‌های شبکه در تمامی آزمایش‌ها برابر با ۲ در نظر گرفته شد. افزون بر این، در معماری GAT، تعداد سرهای توجه برابر با ۴ تنظیم گردید تا تعادل مناسبی میان پیچیدگی مدل و عملکرد آن برقرار شود. همچنین، مطابق با چارچوب روش NOCD، آستانه تشخیص عضویت هم‌پوشان ثابت و برابر با ۰/۳ انتخاب شده است. سایر ابرپارامترهای آموزش شامل نرخ یادگیری[1] ($۱۰^{-۴}$)، بهینه‌ساز Adam در تمامی آزمایش‌ها ثابت نگه داشته شده‌اند تا امکان مقایسه منصفانه بین روش‌ها فراهم شود.

سناریوهای مورد بررسی در این بخش، مبتنی بر نسخه‌های مختلف تابع هزینه NOCD بوده و شامل موارد زیر هستند:

- تابع هزینه NOCD که در پژوهش [۴۵] معرفی شده است.
- نسخه بهبودیافته و وزن‌دار تابع NOCD که به‌عنوان یکی از نوآوری‌های این پژوهش با هدف مدل‌سازی دقیق‌تر شدت تعاملات معرفی شده است.
- نسخه مبتنی بر همسایگی مرتبه بالاتر تابع NOCD که با در نظر گرفتن ساختار غیرمحلی شبکه‌های PPI، در این پژوهش پیشنهاد شده است.

[1] Learning rate

برای هر یک از معماری‌های GCN و GAT، تمامی سناریوهای فوق به صورت مستقل ارزیابی شده‌اند. نتایج حاصل بر اساس معیارهای دقت، بازیابی، امتیاز F1 و صحت مورد مقایسه قرار گرفته و در جداول آ.۱، ۳.۵ و ۴.۵ ارائه شده‌اند.

این آزمایش‌ها بر روی سه مجموعه داده Collins، Krogan-Core و DIP انجام شده است. با توجه به اندازه بزرگ‌تر و تعداد بیشتر پروتئین‌ها و تعاملات در مجموعه داده DIP، فرآیند آموزش در این مجموعه نیازمند تعداد ایپاک‌های بیشتری بوده و برابر با ۵۰۰۰ ایپاک در نظر گرفته شده است، در حالی که برای دو مجموعه داده دیگر آموزش شبکه‌ها پس از ۲۰۰۰ ایپاک همگرا شده‌اند. این تفاوت در تعداد ایپاک‌ها به‌منظور دستیابی به همگرایی پایدار در شبکه‌های بزرگ‌تر اعمال شده است. همچنین، به‌منظور انتخاب پیکربندی بهینه پیمانه‌های شناسایی شده در هر سناریو، از معیار ماژولاریتی به‌عنوان یک شاخص ارزیابی کمکی در فرآیند انتخاب مدل استفاده شده است.

جدول ۲.۵: نتایج عملکرد شبکه عصبی و تابع هزینه برای مجموعه داده Collins

شبکه عصبی	تابع هزینه	λ	Precision	Recall	F1	Accuracy	NCP	NCB
GCN	NOCD	تعریف نشده	۰/۸۹۱	۰/۳۳۷	۰/۴۸۹	۰/۲۵۲	۴۹	۱۸۷
GCN	NOCD وزن‌دار	تعریف نشده	۰/۶۸۷	**۰/۶۹۵**	۰/۶۹۱	**۰/۳۲۶**	۱۶۷	**۳۸۵**
GCN	NOCD مرتبه بالاتر	۰/۵	۰/۸۱۸	۰/۳۱۶	۰/۴۵۶	۰/۲۵۴	۵۴	۱۷۵
GCN	NOCD مرتبه بالاتر	۱	۰/۶۶۲	۰/۲۱۲	۰/۳۲۲	۰/۲۴۵	۴۹	۱۱۸
GAT	NOCD	تعریف نشده	۰/۸۲۵	۰/۵۲۲	۰/۶۴۰	۰/۲۹۵	۱۵۶	۲۸۹
GAT	NOCD وزن‌دار	تعریف نشده	۰/۸۷۹	۰/۶۳۰	**۰/۷۳۴**	۰/۲۹۲	**۲۴۰**	۳۴۹
GAT	NOCD مرتبه بالاتر	۰/۵	۰/۸۸۰	۰/۵۲۵	۰/۶۵۸	۰/۲۸۲	۱۶۱	۲۹۱
GAT	NOCD مرتبه بالاتر	۱	**۰/۹۱۶**	۰/۳۸۱	۰/۵۳۸	۰/۲۷۶	۱۸۶	۲۱۱

همان‌گونه که در جدول آ.۱ مشاهده می‌شود، بیشترین مقدار دقت مربوط به شبکه عصبی GAT با تابع هزینه NOCD مرتبه بالاتر است. از نظر معیار بازیابی، بهترین عملکرد به شبکه GCN با تابع هزینه NOCD وزن‌دار اختصاص دارد. همچنین، از منظر معیار صحت، شبکه GCN با تابع هزینه NOCD وزن‌دار بالاترین مقدار را کسب کرده است.

با این حال، معیار اصلی این پژوهش مقدار F1 است که به‌عنوان میانگین هارمونیک دقت و بازیابی، شاخصی متوازن‌تر برای ارزیابی عملکرد مدل‌ها محسوب می‌شود. بر اساس این معیار، بهترین نتیجه مربوط به شبکه GAT با تابع هزینه NOCD وزن‌دار است.

جدول ۳.۵: نتایج عملکرد شبکه عصبی و تابع هزینه برای مجموعه داده Krogan-Core

شبکه عصبی	تابع هزینه	λ	Precision	Recall	F1	Accuracy	NCP	NCB
GCN	NOCD	تعریف نشده	۰/۴۳۵	۰/۵۵۵	۰/۴۸۸	۰/۲۹۰	۱۴۱	۳۳۳
GCN	NOCD وزن‌دار	تعریف نشده	۰/۴۷۸	۰/۶۰۳	۰/۵۳۳	**۰/۲۹۴**	۱۵۳	۳۶۲
GCN	NOCD مرتبه بالاتر	۰/۵	۰/۵۰۴	۰/۴۲۸	۰/۴۶۳	۰/۲۶۵	۱۲۳	۲۵۷
GCN	NOCD مرتبه بالاتر	۱	۰/۶۳۲	۰/۳۷۳	۰/۴۶۹	۰/۲۵۱	۱۱۷	۲۲۴
GAT	NOCD	تعریف نشده	۰/۵۹۸	۰/۵۴۳	۰/۵۶۹	۰/۲۵۷	۲۳۸	۳۲۶
GAT	NOCD وزن‌دار	تعریف نشده	**۰/۶۵۵**	**۰/۶۰۵**	**۰/۶۲۹**	۰/۲۶۱	**۲۶۶**	**۳۶۳**
GAT	NOCD مرتبه بالاتر	۰/۵	۰/۵۱۴	۰/۳۶۰	۰/۴۲۳	۰/۲۴۳	۱۸۷	۲۱۶
GAT	NOCD مرتبه بالاتر	۱	۰/۳۰۸	۰/۲۲۰	۰/۲۵۷	۰/۲۰۵	۱۲۲	۱۳۲

همانطور که در جدول ۳.۵ مشاهده می‌شود، بیشترین دقت، بازیابی و F1 مربوط به شبکه GAT با تابع هزینه NOCD وزن‌دار می‌باشد. در معیار صحت نیز شبکه GCN وزن‌دار بهترین عملکرد را در بین دیگر شبکه‌ها داشته است.

جدول ۴.۵: نتایج عملکرد شبکه عصبی و تابع هزینه برای مجموعه داده DIP

شبکه عصبی	تابع هزینه	λ	Precision	Recall	F1	Accuracy	NCP	NCB
GCN	NOCD	تعریف نشده	۰/۲۸۵	۰/۴۴۳	۰/۳۴۷	**۰/۲۷۸**	۱۲۲	۳۴۳
GCN	NOCD وزن‌دار	تعریف نشده	**۰/۵۲۸**	۰/۴۵	۰/۴۸۵	۰/۲۵۷	۱۳۴	۳۴۸
GCN	NOCD مرتبه بالاتر	۰/۵	۰/۳۰۴	۰/۱۶۳	۰/۲۱۲	۰/۲۴۶	۵۶	۱۲۶
GCN	NOCD مرتبه بالاتر	۱	۰/۲۳۳	۰/۱۳۴	۰/۱۷	۰/۲۲۷	۴۵	۱۰۴
GAT	NOCD	تعریف نشده	۰/۳۱۴	۰/۴۱۳	۰/۳۵۷	۰/۲۴۲	۱۵۳	۳۲۰
GAT	NOCD وزن‌دار	تعریف نشده	۰/۵۲۳	**۰/۵۰۶**	**۰/۵۱۵**	۰/۲۴۲	**۲۱۲**	**۳۹۲**
GAT	NOCD مرتبه بالاتر	۰/۵	۰/۱۶۴	۰/۰۷	۰/۰۹۸	۰/۱۷۸	۲۲	۵۴
GAT	NOCD مرتبه بالاتر	۱	۰/۰۳	۰/۰۳۱	۰/۰۳	۰/۱۷۳	۱۱	۲۴

بر اساس نتایج ارائه‌شده در جدول ۴.۵، شبکه GCN وزن‌دار بالاترین مقدار دقت را کسب کرده است.

از سوی دیگر، شبکه GAT وزن‌دار در معیارهای بازیابی و F1 عملکرد برتری نشان می‌دهد. همچنین، بیشترین مقدار معیار صحت مربوط به شبکه GCN است.

در نهایت، با مقایسه نتایج ارائه شده در جداول آ.۱، ۳.۵ و ۴.۵، برتری شبکه GAT نسبت به GCN، به‌ویژه بر اساس معیار F1، به‌وضوح مشاهده می‌شود. همچنین، در میان توابع هزینه مورد مقایسه، تابع هزینه پیشنهادی NOCD وزن‌دار بهترین عملکرد را در مقایسه با سایر توابع هزینه پیشنهادی ارائه داده است. این برتری را می‌توان ناشی از در نظر گرفتن شدت تعاملات پروتئین‌ـ‌پروتئین در فرآیند یادگیری دانست.

بر این اساس، در ادامه این پژوهش، از شبکه GAT همراه با تابع هزینه NOCD وزن‌دار، که برتری آن‌ها در ارزیابی‌های انجام شده به اثبات رسیده است، برای انجام سایر آزمایش‌ها استفاده خواهد شد.

در راستای بهبود تعمیم‌پذیری مدل، تأثیر استفاده از لایه Dropout بر روی بازنمایی‌های حاصل از لایه‌های میانی (پس از اعمال تابع فعال‌ساز ReLU) نیز مورد ارزیابی قرار گرفت. نتایج آزمایش‌ها نشان داد که افزودن دراپ‌اوت منجر به کاهش عملکرد مدل شده است. این رفتار را می‌توان با توجه به تنک بودن ذاتی شبکه‌های PPI و همچنین ساختار نسبتاً کم‌عمق مدل پیشنهادی توضیح داد. از آنجا که معماری مورد استفاده شامل دو لایه گرافی بوده و از پیچیدگی بالایی برخوردار نیست، مدل دچار بیش‌برازش قابل توجهی نمی‌شود، از این‌رو استفاده از روش‌های منظم‌سازی نظیر دراپ‌اوت، نرمال‌سازی دسته‌ای و یا منظم‌کننده L2 ضرورتی نداشته و حتی موجب تضعیف کیفیت بازنمایی‌های آموخته‌شده گردیده است.

علاوه بر این، تأثیر به‌کارگیری اتصالات باقیمانده نیز در معماری مدل مورد بررسی قرار گرفت که نتایج حاصل نشان‌دهنده کاهش عملکرد در این حالت بود. به‌طور کلی، اتصالات باقیمانده در شبکه‌های عمیق به‌منظور مقابله با مشکل محوشدگی گرادیان[1] و تسهیل فرآیند بهینه‌سازی مورد استفاده قرار می‌گیرند؛ در حالی که در معماری کم‌عمق مورد استفاده در این پژوهش، چنین چالشی مشاهده نشد.

[1] Vanishing gradients

افزون بر این، هدف اصلی در این پژوهش یادگیری بازنمایی‌هایی معنادار برای هر پروتئین به‌منظور تخصیص آن‌ها به پیمانه‌های عملکردی هم‌پوشان می‌باشد. استفاده از اتصالات باقیمانده با تأکید بر حفظ ویژگی‌های اولیه گره‌ها و ترکیب مستقیم آن‌ها با بازنمایی‌های عمیق‌تر، می‌تواند منجر به کاهش همگرایی بازنمایی‌ها در فضای نهفته و افزایش تمایز غیرضروری میان پروتئین‌ها شود، امری که در نهایت فرآیند خوشه‌بندی پیمانه‌های عملکردی را با اختلال مواجه می‌سازد.

۴.۵ بررسی عملکرد توابع فعالسازی

در این بخش، تأثیر به‌کارگیری توابع فعال‌سازی مختلف بر عملکرد شبکه عصبی گرافی مورد ارزیابی قرار می‌گیرد و بر اساس نتایج به‌دست آمده، تابع فعال‌سازی مناسب انتخاب می‌شود. این مجموعه آزمایش‌ها برای هر دو نوع ویژگی دودویی و تعبیه انجام شده است. ابتدا نتایج مربوط به تأثیر توابع فعال‌سازی در حالت ویژگی‌های دودویی بررسی می‌شود که در جدول ۵.۵ گزارش شده است.

با توجه به مقادیر گزارش شده، مشاهده می‌شود که در معیار دقت، تابع فعال‌ساز ELU در تمامی مجموعه داده‌ها عملکرد بهتری نسبت به سایر توابع فعال‌ساز ارائه داده است. با این حال، تقریباً در تمامی مجموعه داده‌ها، تابع فعال‌ساز ReLU در سه معیار بازیابی، F1 و صحت عملکرد برتری از خود نشان می‌دهد. تنها مورد استثنا مربوط به مجموعه‌داده Krogan Extended در معیار F1 است که در آن تابع فعال‌ساز GELU حدود دو درصد عملکرد بهتری نسبت به ReLU به دست آورده است.

در مجموع، با توجه به نتایج ارائه شده در جدول ۵.۵ می‌توان نتیجه گرفت که در حالت استفاده از ویژگی‌های دودویی، تابع فعال‌ساز ReLU به‌طور کلی عملکرد بهتری نسبت به سایر توابع فعال‌ساز داشته است. ازاین‌رو، در این پژوهش از تابع فعال‌ساز ReLU به‌عنوان تابع فعال‌ساز اصلی در فرآیند شناسایی مجموعه‌های پروتئینی استفاده شده است.

در جدول ۶.۵ نتایج مربوط به بررسی تأثیر تابع فعال‌ساز بر عملکرد شناسایی پیمانه‌های عملکردی با

جدول ۵.۵: نتایج عملکرد توابع فعال‌سازی با ویژگی‌های دودویی

مجموعه داده	تابع فعالسازی	Precision	Recall	F1	Accuracy	NCP	NCB
Collins	ELU	**۰/۹۲۲**	۰/۴۰۳	۰/۵۶۰	۰/۲۴۰	۷۱	۲۲۳
	GELU	۰/۸۵۲	۰/۴۵۵	۰/۵۹۳	۰/۲۷۰	۹۸	۲۵۲
	ReLU	۰/۸۸۹	**۰/۵۶۳**	**۰/۶۸۹**	**۰/۲۸۶**	**۱۱۲**	**۳۱۲**
Krogan Core	ELU	**۰/۷۰۶**	۰/۴۶۸	۰/۵۶۳	۰/۲۲۵	۱۳۷	۲۸۱
	GELU	۰/۶۷۵	۰/۵۶	**۰/۶۱۲**	۰/۲۵۴	**۲۳۷**	۳۳۶
	ReLU	۰/۶۳۲	**۰/۵۹**	۰/۶۱	**۰/۲۶۳**	۲۰۸	**۳۵۴**
Krogan Extended	ELU	**۰/۸۱**	۰/۳۲۹	۰/۴۶۸	۰/۱۹۴	۹۸	۲۱۸
	GELU	۰/۷۳۴	۰/۴۵۹	**۰/۵۶۴**	۰/۲۴۱	**۲۵۶**	۳۰۴
	ReLU	۰/۶۵۲	**۰/۴۷۱**	۰/۵۴۶	**۰/۲۴۱**	۲۰۲	**۳۱۲**
Biogrid	ELU	**۰/۷۵۹**	۰/۱۵	۰/۲۵	۰/۱۵۸	۴۱	۱۱۸
	GELU	۰/۶۸۲	۰/۳۶۵	۰/۴۷۶	۰/۲۵۷	۱۴۴	۲۸۸
	ReLU	۰/۶۷۵	**۰/۴۵۲**	**۰/۵۴۱**	**۰/۲۷۶**	**۱۶۴**	**۳۵۶**
DIP	ELU	**۰/۶۶۷**	۰/۲۸۳	۰/۳۹۷	۰/۱۸۷	۱۰۲	۲۱۹
	GELU	۰/۶۰۵	۰/۴۷۹	۰/۵۳۵	۰/۲۳۳	**۲۳۳**	۳۷۱
	ReLU	۰/۶۱۴	**۰/۵۲۲**	**۰/۵۶۴**	**۰/۲۴**	۱۹۹	**۴۰۴**

استفاده از ویژگی‌های تعبیه‌شده ارائه شده است. بر اساس این نتایج، در مجموعه‌داده Collins، بهترین عملکرد مربوط به تابع فعال‌ساز ELU است، به‌طوری‌که این تابع به ترتیب حدود ۶ و ۹ درصد بهبود در معیار F1 نسبت به توابع GELU و ReLU نشان می‌دهد. همچنین در این مجموعه‌داده، در معیارهای دقت و صحت به‌ترتیب توابع فعال‌ساز ReLU و GELU عملکرد برتری داشته‌اند.

در مقابل، در سایر مجموعه‌داده‌ها تابع فعال‌ساز ReLU در معیارهای F1، بازیابی و صحت عملکرد بهتری نسبت به دو تابع دیگر ارائه می‌کند. ازاین‌رو، به‌طور کلی می‌توان نتیجه گرفت که تابع فعال‌ساز ReLU در اغلب مجموعه‌داده‌ها اثربخشی بیشتری در استخراج ویژگی‌های تعبیه‌شده داشته و تنها استثنای قابل‌توجه در این میان، مجموعه‌داده Collins است که در آن تابع ELU نتایج مطلوب‌تری

جدول ۶.۵: نتایج عملکرد توابع فعال‌سازی با ویژگی‌های تعبیه

مجموعه داده	تابع فعالسازی	Precision	Recall	F1	Accuracy	NCP	NCB
Collins	ELU	۰/۸۸۲	**۰/۴۳۵**	**۰/۵۸۳**	۰/۲۵۷	۶۰	**۲۴۱**
	GELU	۰/۸۹۲	۰/۳۶۶	۰/۵۲	**۰/۲۸۶**	۵۸	۲۰۳
	ReLU	**۰/۹۰۳**	۰/۳۳۹	۰/۴۹۳	۰/۲۴۹	۵۶	۱۸۸
Krogan Core	ELU	**۰/۹۰۲**	۰/۲۲۵	۰/۳۶	۰/۱۸۸	۳۷	۱۳۵
	GELU	۰/۷۹۲	۰/۳۴۸	۰/۴۸۴	۰/۲۳۶	۷۶	۲۰۹
	ReLU	۰/۶۵۸	**۰/۵۳۵**	**۰/۵۹**	**۰/۲۶۴**	**۱۵۸**	**۳۲۱**
Krogan Extended	ELU	**۰/۸۵۷**	۰/۱۳	۰/۲۲۵	۰/۱۳۸	۱۸	۸۶
	GELU	۰/۷۷۵	۰/۲۶۲	۰/۳۹۲	۰/۲۰۳	۶۲	۱۷۴
	ReLU	۰/۷۷۹	**۰/۳۸۵**	**۰/۵۱۵**	**۰/۲۳۲**	**۱۱۳**	**۲۵۵**
Biogrid	ELU	۰/۶۸۶	۰/۱۱۲	۰/۱۹۲	۰/۱۶۷	۲۴	۸۸
	GELU	**۰/۷۵**	۰/۱۹۸	۰/۳۱۳	۰/۱۹۸	۳۹	۱۵۶
	ReLU	۰/۶۴۶	**۰/۳۶۲**	**۰/۴۶۴**	**۰/۲۶۵**	**۱۰۴**	**۲۸۵**
DIP	ELU	۰/۷۱۴	۰/۰۷۱	۰/۱۲۹	۰/۱۱۶	۱۵	۵۵
	GELU	**۰/۷۸۲**	۰/۲۱۱	۰/۳۳۲	۰/۱۷۷	۶۱	۱۶۳
	ReLU	۰/۶۷۴	**۰/۳۸**	**۰/۴۸۶**	**۰/۲۲**	**۱۱۶**	**۲۹۴**

ارائه می‌دهد.

۵.۵ بررسی عملکرد روش پرش دانش

در این قسمت به بررسی عملکرد روش‌های مبتنی بر پرش دانش می‌پردازیم و آن را با شبکه‌های عصبی گرافی توجه محور مقایسه می‌کنیم. نتایج عملکرد روش‌های مبتنی بر پرش دانش یا JKNet در جدول ۷.۵ ارائه شده‌اند.

با مقایسه نتایج ارائه شده در جدول ۷.۵ و برای سه مجموعه داده Collins، Krogan Core و DIP مشاهده می‌شود که معماری‌های مبتنی بر توجه، به‌ویژه شبکه GAT، در اغلب معیارهای ارزیابی عملکرد

برتری نسبت به سازوکارهای مختلف روش JKNet نشان می‌دهند. در مجموعه داده Collins اگرچه تفاوت‌ها محدودتر است، اما GAT همچنان بالاترین مقدار F1 را در میان مدل‌های مقایسه شده کسب کرده است. در مجموعه داده Krogan Core، مقدار معیار F1 در شبکه GAT به‌طور محسوسی بالاتر از بهترین حالت JKNet است و همزمان مقادیر بازیابی نیز بهبود یافته است. این نتایج بیانگر آن است که سازوکار توجه در GAT با تخصیص وزن‌های متفاوت به همسایگان و تمرکز بر تعاملات زیستی مهم‌تر، توانایی بهتری در استخراج بازنمایی‌های معنادار برای شناسایی پیمانه‌های عملکردی دارد، در حالی که JKNet با وجود بهره‌گیری از تجمیع چندسطحی، در این مسئله خاص مزیت محسوسی ایجاد نکرده است. بر این اساس، با توجه به عملکرد پایدارتر و مقادیر بالاتر F1 در اغلب مجموعه داده‌ها، شبکه GAT به‌عنوان معماری نهایی در این پژوهش انتخاب شده است.

جدول ۷.۵: نتایج عملکرد روش JKNet با ویژگی‌های دودویی

مجموعه داده	سازوکار JKNet	Precision	Recall	F1	Accuracy	NCP	NCB
Collins	Max pooling	۰/۸۴۹	۰/۵۱۱	۰/۶۳۸	۰/۲۷۱	۱۶۳	۲۸۳
	Concat	۰/۷۹۵	**۰/۶۷۱**	**۰/۷۲۸**	**۰/۲۹۴**	**۲۶۷**	**۳۷۲**
	LSTMAttention	**۰/۸۹۸**	۰/۵۰۹	۰/۶۵	۰/۲۶۸	۱۹۳	۲۸۲
Krogan Core	Max pooling	۰/۵۳۴	۰/۵۷۲	۰/۵۵۲	۰/۲۷	۲۱۱	۳۴۳
	Concat	**۰/۵۴۲**	۰/۵۷۲	۰/۵۵۷	**۰/۲۶۹**	۲۱۷	۳۴۳
	LSTMAttention	۰/۵۲۶	**۰/۵۹۵**	**۰/۵۵۸**	۰/۲۶۸	**۲۴۵**	**۳۵۷**
DIP	Max pooling	۰/۵۱۷	۰/۵۴۱	۰/۵۲۹	**۰/۲۶۵**	۱۹۴	۴۱۹
	Concat	**۰/۵۳**	۰/۵۴۵	**۰/۵۳۷**	۰/۲۵۴	۲۰۴	۴۲۲
	LSTMAttention	۰/۴۹۸	**۰/۵۷۹**	۰/۵۳۵	۰/۲۵۵	**۲۱۶**	**۴۴۸**

۶.۵ مقایسه عملکرد شبکه GAT استاندارد در مقایسه با دو نسخه بهبود یافته آن

در این قسمت به بررسی عملکرد نخسه‌های متفاوت شبکه‌های عصبی گرافی توجه محور می‌پردازیم. جدول ۸.۵ به مقایسه عملکرد شبکه GAT استاندارد با دو نسخه توسعه‌یافته آن، شامل GATv2 و SuperGAT، اختصاص دارد و تفاوت‌های حاصل در معیارهای ارزیابی مختلف را نشان می‌دهد.

جدول ۸.۵: بررسی عملکرد شبکه‌های GATv2 و SuperGAT با ویژگی‌های دودویی

مجموعه داده	شبکه عصبی	Precision	Recall	F1	Accuracy	NCP	NCB
Collins	GATv2	۰/۸۶۵	۰/۵۲۷	۰/۶۵۵	**۰/۲۹۳**	۱۳۵	۲۹۲
	SuperGAT	**۰/۹۱۱**	۰/۵۵۶	۰/۶۹۰	۰/۲۸۳	۱۷۴	۳۰۸
	GAT	۰/۸۷۹	**۰/۶۳۰**	**۰/۷۳۴**	۰/۲۹۲	**۲۴۰**	**۳۴۹**
Krogan Core	GATv2	**۰/۶۶۹**	۰/۵۴۸	۰/۶۰۳	۰/۲۶۴	۱۷۲	۳۲۹
	SuperGAT	۰/۶۶۶	۰/۵۵۳	۰/۶۰۴	**۰/۲۶۸**	۲۱۱	۳۳۲
	GAT	۰/۶۵۵	**۰/۶۰۵**	**۰/۶۲۹**	۰/۲۶۱	**۲۶۶**	**۳۶۳**
DIP	GATv2	**۰/۶۴۲**	۰/۳۹۳	۰/۴۸۷	۰/۲۳۷	۱۳۳	۳۰۴
	SuperGAT	۰/۵۶۵	۰/۳۹۹	۰/۴۶۸	۰/۲۳۴	۱۳۸	۳۰۹
	GAT	۰/۵۲۳	**۰/۵۰۶**	**۰/۵۱۵**	**۰/۲۴۲**	**۲۱۲**	**۳۹۲**

بر اساس نتایج ارائه‌شده در جدول ۸.۵، شبکه GAT استاندارد در مقایسه با نسخه‌های توسعه‌یافته آن، شامل GATv2 و SuperGAT، در اغلب مجموعه‌داده‌ها عملکرد برتری در معیارهای بازیابی و F1 از خود نشان داده است. از آنجا که معیار F1 به‌عنوان شاخصی متوازن میان دقت و بازیابی در ارزیابی کیفیت شناسایی پیمانه‌های عملکردی اهمیت ویژه‌ای دارد، برتری GAT در این معیار بیانگر توانایی بالاتر آن در استخراج بازنمایی‌های مؤثر برای خوشه‌بندی پروتئین‌ها می‌باشد. افزون بر این، در معیار صحت نیز عملکرد GAT قابل مقایسه و در برخی موارد هم‌تراز با سایر نسخه‌ها گزارش شده است که نشان‌دهنده پایداری این معماری در تشخیص نمونه‌های منفی است. با توجه به این نتایج و نیز سادگی

معماری و هزینه محاسباتی کمتر نسبت به نسخه‌های پیچیده‌تر، می‌توان نتیجه گرفت که شبکه GAT استاندارد انتخاب مناسب‌تری برای چارچوب پیشنهادی این پژوهش محسوب می‌شود.

۷.۵ نتایج تعیین آستانه تجمیعی و تاثیر انتخاب ویژگی

در این بخش، به بررسی بهبودهای حاصل از روش پیشنهادی انتخاب آستانه تجمیعی و تاثیر انتخاب ویژگی‌ها در این پژوهش پرداخته می‌شود. همان‌گونه که در فصل مربوط به روش پیشنهادی توضیح داده شد، با توجه به ساختار هم‌پوشانی و رابطه زیرمجموعه‌ای میان پیمانه‌های عملکردی پروتئینی، روشی مبتنی بر تعیین آستانه ترکیبی پیشنهاد شده است. هدف از این روش، ارتقای دقت شناسایی پیمانه‌ها با بهره‌گیری از ساختار واقعی آن‌ها در شبکه‌های زیستی است.

جدول ۹.۵: عملکرد تعیین آستانه تجمیعی و نوع ویژگی‌ها - نتایج مربوط به سایر آستانه‌ها در پیوست موجود است.

مجموعه‌داده‌ـ ویژگی	آستانه ثابت ۰/۳				آستانه تجمیعی			
	Precision	Recall	F-score	Acc	Precision	Recall	F-score	Acc
Collins-binary	**۰/۸۸۹**	۰/۵۶۳	۰/۶۸۹	۰/۲۸۶	۰/۸۳۵	**۰/۶۲۱**	**۰/۷۱۲**	**۰/۳۰۳**
Collins-embedding	**۰/۹۰۳**	۰/۳۳۹	۰/۴۹۳	۰/۲۴۹	۰/۸۸۸	**۰/۴۹۶**	**۰/۶۳۷**	**۰/۲۹۵**
Collins-binary + embedding	**۰/۸۸۲**	۰/۵۹۴	۰/۷۱	۰/۲۹۴	۰/۸۴۳	**۰/۶۷۳**	**۰/۷۴۹**	**۰/۳۱۷**
Krogan Core-binary	**۰/۶۳۲**	۰/۵۹	۰/۶۱	۰/۲۶۳	۰/۶۰۸	**۰/۶۴۷**	**۰/۶۲۷**	**۰/۲۷۲**
Krogan Core-embedding	**۰/۶۵۸**	۰/۵۳۵	۰/۵۹	۰/۲۶۴	۰/۶۵۲	**۰/۶۰۷**	**۰/۶۲۹**	**۰/۲۷۹**
Krogan Core- binary + embedding	**۰/۶۳۳**	۰/۶۳۵	۰/۶۳۴	۰/۲۷۴	۰/۶۱۴	**۰/۶۹۷**	**۰/۶۵۳**	**۰/۲۸۴**
Krogan Extended-binary	۰/۶۵۲	۰/۴۷۱	۰/۵۴۶	۰/۲۴۱	**۰/۶۷۱**	**۰/۵۴۸**	**۰/۶۰۳**	**۰/۲۵۶**
Krogan Extended-embedding	**۰/۷۷۹**	۰/۳۸۵	۰/۵۱۵	۰/۲۳۲	۰/۷۴۴	**۰/۴۵۲**	**۰/۵۶۳**	**۰/۲۵۲**
Krogan Extended-binary + embedding	۰/۶۹۱	۰/۵۰۷	۰/۵۸۵	۰/۲۵۱	**۰/۶۹۱**	**۰/۵۷۵**	**۰/۶۲۸**	**۰/۲۶۴**
Biogrid- binary	۰/۶۷۵	۰/۴۵۲	۰/۵۴۱	۰/۲۷۶	**۰/۶۸۱**	**۰/۵۱۳**	**۰/۵۸۵**	**۰/۳۰۳**
Biogrid- embedding	**۰/۶۴۶**	۰/۳۶۲	۰/۴۶۴	۰/۲۶۵	۰/۶۳۶	**۰/۴۳۵**	**۰/۵۱۷**	**۰/۲۹۳**
Biogrid- binary + embedding	**۰/۶۶۲**	۰/۴۹۴	۰/۵۶۵	۰/۲۸۳	۰/۶۵۷	**۰/۵۵۶**	**۰/۶۰۲**	**۰/۳۱**
DIP - binary	**۰/۶۱۴**	۰/۵۲۲	۰/۵۶۴	۰/۲۴	۰/۵۹۸	**۰/۵۸۸**	**۰/۵۹۳**	**۰/۲۵۶**
DIP - embedding	**۰/۶۷۴**	۰/۳۸	۰/۴۸۶	۰/۲۲	۰/۶۴۳	**۰/۴۵۶**	**۰/۵۳۴**	**۰/۲۴۷**
DIP - binary + embedding	**۰/۶۲۱**	۰/۵۵۸	۰/۵۸۸	۰/۲۴۴	۰/۶۰۱	**۰/۶۳۸**	**۰/۶۱۹**	**۰/۲۶۵**

این آزمایش بر روی تمامی مجموعه‌داده‌ها و برای هر دو نوع ویژگی ورودی، یعنی ویژگی‌های دودویی و ویژگی‌های تعبیه‌شده و ترکیب آن‌ها، انجام شده است. نتایج مربوطه در جدول ۹.۵ گزارش شده‌اند. همان‌طور که در جدول مشاهده می‌شود، استفاده از آستانه ترکیبی در اغلب مجموعه‌داده‌ها (به‌جز Krogan Extended-binary و Biogrid-binary) منجر به کاهش معیار دقت شده است. با این حال، این روش موجب افزایش معنادار سایر معیارها در تمامی مجموعه‌داده‌ها شده است که این امر مؤید کارآمدی و اثربخشی روش پیشنهادی است.

در گام بعد، مجموعه‌های پروتئینی استخراج‌شده توسط ویژگی‌های دودویی و ویژگی‌های تعبیه‌شده، برای هر مجموعه‌داده، با استفاده از روش پیشنهادی با یکدیگر ترکیب شده‌اند و تنها مجموعه‌های یکتا حفظ شده‌اند. این فرآیند نیز بهبود قابل توجهی در عملکرد نهایی ایجاد کرده است.

۸.۵ مقایسه با پژوهش‌های پیشین

در این بخش، عملکرد روش پیشنهادی با مجموعه‌ای از ۱۲ پژوهش شامل روش‌های کلاسیک و همچنین روش‌های مبتنی بر شبکه‌های عصبی گرافی بر روی مجموعه‌داده‌های مختلف در جدول ۱۰.۵ مقایسه شده است. در میان این پژوهش‌ها، روش AdaPPI نیز قرار دارد که به‌عنوان یکی از پیشرفته‌ترین و معتبرترین رویکردهای موجود در حوزه شناسایی پیمانه‌های عملکردی شناخته می‌شود. ارزیابی‌های انجام‌شده بر اساس معیارهای دقت، بازیابی، صحت و F1 صورت گرفته است که از شاخص‌های اصلی در سنجش کیفیت روش‌های شناسایی پیمانه‌های عملکردی به‌شمار می‌روند. در این میان، معیار F-score اهمیت ویژه‌ای دارد، زیرا بازتاب‌دهنده تعادلی مؤثر میان دو معیار دقت و بازیابی بوده و نشان‌دهنده توانایی یک روش در شناسایی دقیق و کامل پیمانه‌های زیستی است. ابتدا به بررسی نتایج مربوط به هر مجموعه‌داده پرداخته و سپس جمع‌بندی کلی نتایج ارائه می‌شود.

در نتایج حاصل از مجموعه‌داده Collins مشاهده می‌شود که روش AdaPPI بالاترین مقدار دقت را

جدول ۱۰.۵: مقایسه عملکرد روش پیشنهادی با پژوهش‌های پیشین در مجموعه‌داده‌های متفاوت – نتایج گزارش شده در پژوهش AdaPPI

روش‌ها	Collins				Krogan Core				Krogan Extended			
	Precision	Recall	F-score	Acc	Precision	Recall	F-score	Acc	Precision	Recall	F-score	Acc
MCODE [۴۹]	۰/۸۴۷	۰/۴۰۰	۰/۵۴۰	۰/۲۵۴	۰/۷۳۲	۰/۱۹۸	۰/۳۱۱	۰/۱۷۶	۰/۶۱۲	۰/۱۱۲	۰/۱۸۹	۰/۱۵۲
MCL [۷۰]	۰/۷۳۲	۰/۵۰۶	۰/۵۹۸	۰/۲۸۶	۰/۳۳۵	۰/۴۱۴	۰/۳۷۱	۰/۲۶۲	۰/۲۹۹	۰/۳۳۳	۰/۳۱۱	۰/۲۳۳
ClusterOne [۴۸]	۰/۷۳۳	۰/۵۱۱	۰/۶۰۲	۰/۲۹۰	۰/۳۶۴	۰/۴۶۴	۰/۴۰۸	۰/۲۷۳	۰/۴۶۷	۰/۳۰۲	۰/۳۶۶	۰/۲۲۲
CMC [۷۱]	۰/۶۸۰	۰/۳۹۰	۰/۴۹۶	۰/۲۵۵	۰/۶۷۲	۰/۳۰۴	۰/۴۱۹	۰/۲۰۶	۰/۴۷۲	۰/۴۴۰	۰/۴۵۵	۰/۲۱۰
PC2P [۷۲]	۰/۷۳۱	۰/۶۶۲	۰/۶۹۵	۰/۳۰۳	۰/۴۰۳	۰/۴۸۸	۰/۴۴۱	۰/۲۵۱	۰/۳۴۵	۰/۳۸۰	۰/۳۶۲	۰/۲۳۵
COACH [۵۲]	۰/۷۴۹	۰/۵۲۲	۰/۶۱۵	۰/۲۸۰	۰/۵۹۲	۰/۴۶۰	۰/۵۱۸	۰/۲۱۷	۰/۴۶۱	۰/۴۶۵	۰/۴۶۳	۰/۲۱۷
TADW-SC [۵۵]	۰/۵۹۵	**۰/۷۹۳**	۰/۶۷۹	۰/۳۱۶	۰/۴۲۶	۰/۴۹۲	۰/۴۵۷	**۰/۲۹۷**	۰/۳۰۰	۰/۴۴۱	۰/۳۵۷	**۰/۲۷۲**
GANE [۵۷]	۰/۸۱۹	۰/۴۹۱	۰/۶۱۵	۰/۲۹۳	۰/۷۷۴	۰/۴۳۶	۰/۵۵۸	۰/۲۲۹	۰/۶۸۴	۰/۴۴۲	۰/۵۳۷	۰/۲۳۴
DPCMNE [۷۳]	۰/۸۲۱	۰/۵۲۳	۰/۶۳۹	۰/۲۷۰	۰/۷۵۴	۰/۴۵۵	۰/۵۶۷	۰/۲۲۰	۰/۶۲۱	۰/۴۶۳	۰/۵۳۱	۰/۲۲۳
R-GMM-VGAE [۷۴]	۰/۸۹۰	۰/۴۹۴	۰/۶۳۶	۰/۲۵۶	۰/۷۷۰	۰/۴۸۸	۰/۵۹۷	۰/۲۳۶	۰/۵۷۴	۰/۳۶۱	۰/۴۴۳	۰/۲۳۹
Protein-AGC [۷۵]	۰/۸۹۹	۰/۶۰۸	۰/۷۲۵	۰/۲۸۷	۰/۶۸۰	۰/۴۸۵	۰/۵۶۶	۰/۲۳۳	۰/۵۵۹	۰/۳۵۶	۰/۴۳۵	۰/۲۰۸
AdaPPI [۵]	**۰/۹۶۷**	۰/۵۸۶	۰/۷۳۰	۰/۲۸۴	**۰/۸۳۴**	۰/۵۳۳	۰/۶۵۰	۰/۲۳۹	**۰/۷۴۳**	۰/۴۹۳	۰/۵۹۲	۰/۲۳۸
Our Method	۰/۸۴۳ ± ۰/۰۱	۰/۶۷۳ ± ۰/۰۰۵	**۰/۷۴۹ ± ۰/۰۰۸**	**۰/۳۱۷ ± ۰/۰۱۲**	۰/۶۱۴ ± ۰/۰۱۳	**۰/۶۹۷ ± ۰/۰۲۱**	**۰/۶۵۳ ± ۰/۰۱۲**	۰/۲۸۴ ± ۰/۰۱۱	۰/۶۹۱ ± ۰/۰۱	**۰/۵۷۵ ± ۰/۰۱۴**	**۰/۶۲۸ ± ۰/۰۱**	۰/۲۶۴ ± ۰/۰۳

روش‌ها	DIP				Biogrid			
	Precision	Recall	F-score	Acc	Precision	Recall	F-score	Acc
MCODE	۰/۵۴۲	۰/۱۱۸	۰/۱۹۴	۰/۱۴۹	۰/۲۷۶	۰/۰۴۳	۰/۰۷۵	۰/۱۸۱
MCL	۰/۱۵۳	۰/۱۷۲	۰/۱۶۲	۰/۱۹۰	۰/۲۲۸	۰/۲۱۹	۰/۲۲۳	۰/۲۴۹
ClusterOne	۰/۳۹۰	۰/۳۴۳	۰/۳۶۵	۰/۲۲۷	۰/۳۹۳	۰/۴۹۷	۰/۴۳۹	**۰/۳۱۶**
CMC	۰/۶۰۳	۰/۳۹۴	۰/۴۷۷	۰/۲۱۹	۰/۱۵۷	۰/۵۵۳	۰/۲۴۵	۰/۲۶۵
PC2P	–	–	–	۰/۲۴۲	–	–	–	–
COACH	۰/۲۶۰	۰/۳۵۱	۰/۲۹۹	۰/۲۴۳	۰/۳۱۱	۰/۶۵۷	۰/۴۲۲	۰/۲۷۶
TADW-SC	۰/۱۷۰	۰/۰۸۴	۰/۱۱۳	۰/۲۴۵	۰/۵۵۰	۰/۲۹۲	۰/۳۸۲	۰/۲۹۲
GANE	۰/۶۲۳	۰/۵۵۰	۰/۵۸۴	۰/۲۵۴	۰/۵۴۵	**۰/۶۶۴**	۰/۵۹۹	۰/۳۱۰
DPCMNE	۰/۶۰۸	۰/۵۷۵	۰/۵۹۱	۰/۲۴۵	۰/۴۴۷	۰/۶۵۳	۰/۵۳۱	۰/۳۰۴
R-GMM-VGAE	۰/۵۷۴	۰/۳۶۱	۰/۴۴۳	۰/۲۳۹	۰/۴۱۵	۰/۳۳۸	۰/۳۷۳	۰/۲۷۵
Protein-AGC	۰/۳۸۲	۰/۲۹۷	۰/۳۳۴	۰/۲۲۷	۰/۳۳۰	۰/۲۶۹	۰/۲۴۸	۰/۲۴۷
AdaPPI	**۰/۶۷۵**	۰/۵۱۴	۰/۵۸۳	۰/۲۵۹	۰/۶۰۰	۰/۵۳۵	۰/۵۶۶	۰/۳۰۳
Our Method	۰/۶۰۱ ± ۰/۰۳۵	**۰/۶۳۸ ± ۰/۰۱۲**	۰/۶۱۹ ± ۰/۰۱۵	۰/۲۶۵ ± ۰/۰۰۵	**۰/۶۵۷ ± ۰/۰۱۲**	۰/۵۵۶ ± ۰/۰۳	**۰/۶۰۲ ± ۰/۰۱۷**	۰/۳۱ ± ۰/۰۱

در میان پژوهش‌های مقایسه‌شده به دست آورده است و روش پیشنهادی نیز در این معیار عملکردی قابل رقابت و نزدیک به AdaPPI دارد. با این حال، اگرچه AdaPPI در معیار دقت عملکرد مطلوبی نشان می‌دهد، اما مقدار بازیابی آن کمتر از روش پیشنهادی است و این امر در نهایت موجب کاهش F-score برای این روش می‌شود. در مقابل، روش پیشنهادی با حفظ سطح بالای دقت و ارائه مقادیر بالاتر بازیابی توانسته است بهترین F-score را در این مجموعه‌داده به دست آورد، که نشان‌دهنده توانایی آن در شناسایی دقیق‌تر و کامل‌تر پیمانه‌های عملکردی است. علاوه بر این، در معیار صحت نیز روش پیشنهادی عملکرد برتری نسبت به سایر روش‌ها داشته و بالاترین مقدار را در میان روش‌های مقایسه‌شده ارائه کرده است.

در مجموعه‌داده Krogan Core که به‌عنوان نسخه‌ای فشرده‌تر از شبکه Krogan شناخته می‌شود، روش

پیشنهادی توانسته است بالاترین مقادیر بازیابی و امتیاز F1 را در میان تمامی روش‌های مقایسه‌شده کسب کند. به‌ویژه در معیار بازیابی، اختلاف معناداری میان روش پیشنهادی و روش AdaPPI مشاهده می‌شود که نشان‌دهنده توانایی بیشتر روش پیشنهادی در پوشش دادن مجموعه‌های مرجع و شناسایی پیمانه‌های عملکردی واقعی است. اگرچه روش پیشنهادی در معیار دقت عملکرد ضعیف‌تری نسبت به برخی روش‌ها دارد، اما با توجه به برتری آن در بازیابی، در معیار ترکیبی F-score توانسته است با اختلافی هرچند کم، از روش AdaPPI نیز پیشی بگیرد. این موضوع نشان می‌دهد که در حالی که روش‌هایی مانند AdaPPI و Protein-AGC عمدتاً پیمانه‌های محافظه‌کارانه‌تر و با اطمینان بالاتر را شناسایی می‌کنند، روش پیشنهادی موفق شده است تعداد بیشتری از مجموعه‌های پروتئینی واقعی و ثبت‌شده در منابع معتبر را بازیابی کند و تصویری کامل‌تر از ساختارهای زیستی موجود در شبکه ارائه دهد.

در مجموعه‌داده Krogan Extended، نتایج حاصل از ارزیابی روش‌ها شباهت بسیاری به نتایج به‌دست آمده از مجموعه‌داده Krogan Core از خود نشان می‌دهد و رفتارهای مشاهده‌شده در هر دو مجموعه‌داده تکرار شده‌اند. این همسویی در نتایج را می‌توان به شباهت ساختاری شبکه‌ها و ماهیت ارتباطات در این دو مجموعه‌داده نسبت داد. همانند مجموعه‌داده Krogan Core، در مجموعه‌داده Krogan Extended نیز روش پیشنهادی بهترین عملکرد را در معیار F1 به دست آورده است، که نشان‌دهنده توانایی مستمر آن در ایجاد تعادل بهینه میان دقت و بازیابی در شناسایی پیمانه‌های عملکردی است. این یافته تأکید می‌کند که روش پیشنهادی در مواجهه با ساختارهای مشابه، قادر به ارائه عملکرد پایدار و برتر نسبت به سایر روش‌های مقایسه‌شده می‌باشد.

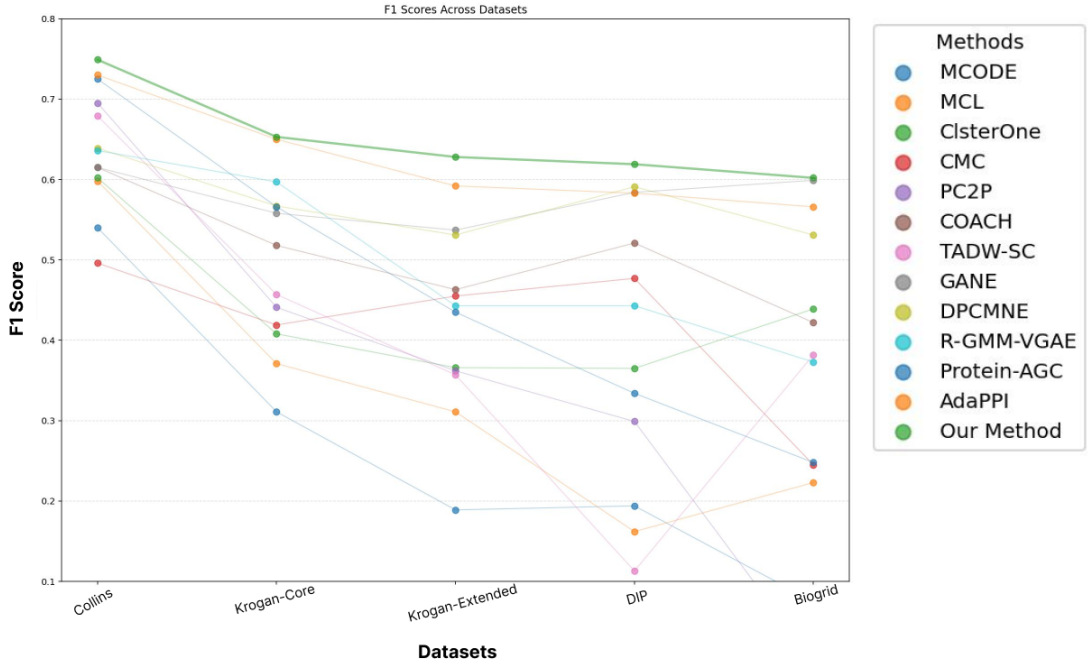
مجموعه‌داده DIP به دلیل وجود نویز بالا و مقیاس بزرگ شبکه، یکی از چالش‌برانگیزترین مجموعه‌داده‌ها در میان داده‌های مورد استفاده در این پژوهش محسوب می‌شود. روش‌های کلاسیک همچون MCODE، MCL و TADW-SC در مواجهه با این مجموعه‌داده عملکرد نسبتاً ضعیفی از خود نشان می‌دهند. در مقابل، روش‌های مبتنی بر شبکه‌های عصبی گراف، از جمله R-GMM-VGAE و AdaPPI، عملکردی

بهتر و پایدارتر ارائه کرده‌اند. روش پیشنهادی در معیار دقت نسبت به بهترین روش موجود، یعنی AdaPPI، عملکرد ضعیف‌تری دارد. اما در سایر معیارها، و به‌ویژه در معیار مهم F1، بهترین نتایج را کسب کرده است. این موضوع نشان می‌دهد که روش پیشنهادی توانسته است تعادل بهینه‌ای میان دقت و بازیابی برقرار کند و در نتیجه، در شناسایی پیمانه‌های عملکردی در مجموعه‌داده DIP برتری قابل توجهی نسبت به روش‌های مقایسه‌شده داشته باشد.

مجموعه‌داده Biogrid نیز همانند مجموعه‌داده DIP شامل شبکه‌ای بزرگ و دارای نویز قابل توجه است. نکته جالب در نتایج این مجموعه‌داده آن است که روش پیشنهادی در معیار دقت بهترین عملکرد را ارائه داده است، اما در معیار بازیابی در رتبه چهارم قرار گرفته است. این موضوع از آن جهت اهمیت دارد که در سایر مجموعه‌داده‌ها روندی معکوس مشاهده شد، یعنی روش پیشنهادی معمولاً در معیار بازیابی برتری محسوسی نسبت به دیگر روش‌ها داشته است.

با وجود این تفاوت، روش پیشنهادی در معیار F1 بهترین عملکرد را کسب کرده است که بیانگر توانایی آن در برقراری تعادل مناسب میان دقت و بازیابی و در نتیجه، کارایی بیشتر در شناسایی پیمانه‌های عملکردی است. علاوه بر این، در معیار صحت نیز روش پیشنهادی پس از روش ClusterOne و با اختلافی اندک در رتبه دوم قرار گرفته است.

به‌طور کلی، نتایج حاصل از تمامی مجموعه‌داده‌ها نشان می‌دهد که روش پیشنهادی به‌صورت پایدار و معنادار از سایر روش‌ها، از جمله AdaPPI، عملکرد بهتری دارد. به صورتی که در تمامی مجموعه داده‌ها در سه معیار بازیابی، F1 و صحت برتری معناداری نسبت به روش AdaPPI دارد. برتری روش پیشنهادی به‌ویژه در معیار F1 بیانگر ایجاد تعادل مناسب میان دو معیار دقت و بازیابی است، در حالی که بسیاری از روش‌های موجود یا دقت بالا و بازیابی پایین دارند و یا بالعکس. این نتایج نشان می‌دهد که روش پیشنهادی نه تنها قادر به شناسایی پیمانه‌های عملکردی دقیق‌تر است، بلکه پوشش کامل‌تری از ساختارهای زیستی واقعی را نیز فراهم می‌کند، که این ویژگی آن را به گزینه‌ای مناسب و قدرتمند برای تحلیل شبکه‌های برهم‌کنش پروتئینی و شناسایی پیمانه‌های عملکردی تبدیل می‌نماید.



شکل ۱.۵ : نمودار مقایسه روش پیشنهادی با پژوهش‌های پیشین

شکل ۸.۵ مقایسه امتیاز F روش پیشنهادی با پژوهش‌های پیشین را در مجموعه‌داده‌های مختلف نشان می‌دهد. همان‌گونه که مشاهده می‌شود، روش پیشنهادی در تمامی مجموعه‌داده‌ها بهترین عملکرد را از خود به نمایش گذاشته است. همچنین، نزدیک‌ترین روش به روش پیشنهادی، پژوهش AdaPPI است؛ با این حال، این روش نیز در برخی از مجموعه‌داده‌ها، از جمله DIP و BioGRID، عملکرد ضعیف‌تری نسبت به برخی از پژوهش‌های دیگر داشته است.

۱.۸.۵ بررسی پیمانه‌های پیش‌بینی شده

در این قسمت به بررسی پیمانه‌های پیش‌بینی شده توسط مدل و صحت سنجی از آن‌ها می‌پردازیم. در ابتدا به صورت آماری پیمانه‌های پیدا شده توسط روش پیشنهادی و پیمانه‌های مرجع را از نظر ویژگی‌های آماری اندازه پیمانه‌ها بررسی می‌کنیم که در جدول ۱۱.۵ مشاهده می‌شود.

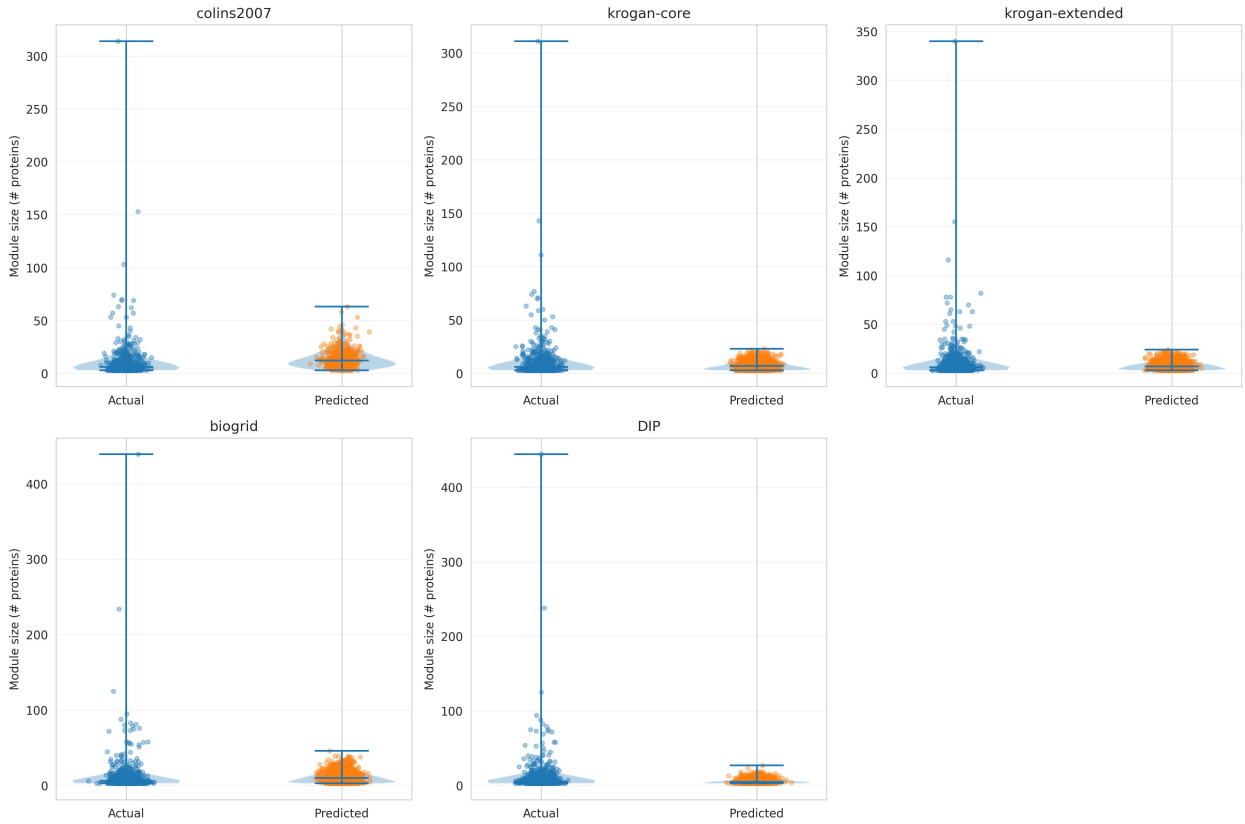
نتایج جدول ۱۱.۵ نشان می‌دهد که از نظر اندازه پیمانه‌ها، پیمانه‌های پیش‌بینی‌شده در مقایسه با

جدول ۱۱.۵: بررسی آماری پیمانه‌های مرجع و پیمانه‌های پیش‌بینی شده از نظر اندازه و هم‌پوشانی

مجموعه‌داده	نوع	تعداد پیمانه‌ها	میانه	انحراف معیار	حداقل	حداکثر	تعداد پروتئین‌های یکتا	تعداد پروتئین‌های هم‌پوشان	درصد هم‌پوشانی
Collins	مرجع	۵۵۴	۶	۹۳/۱۷	۳	۳۱۴	۱۲۵۶	۱۰۴۶	۲۸/۸۳
Collins	پیش‌بینی‌شده	۴۵۳	۱۲	۸۹/۸	۳	۶۳	۱۱۲۳	۹۴۸	۴۲/۸۴
Krogan Core	مرجع	۶۰۰	۶	۳۵/۱۷	۳	۳۱۱	۱۳۹۴	۱۱۶۲	۳۶/۸۳
Krogan Core	پیش‌بینی‌شده	۱۵۲۵	۷	۷۶/۳	۳	۲۳	۱۸۲۲	۱۴۶۷	۵۲/۸۰
Krogan Extended	مرجع	۶۶۳	۶	۰۷/۱۸	۳	۳۴۰	۱۶۲۶	۱۳۳۸	۲۹/۸۲
Krogan Extended	پیش‌بینی‌شده	۱۳۵۷	۷	۱۵/۴	۳	۲۴	۱۶۶۱	۱۲۵۴	۵۰/۷۵
Biogrid	مرجع	۷۸۸	۶	۳۳/۲۱	۳	۴۳۹	۲۱۴۴	۱۶۹۲	۹۲/۷۸
Biogrid	پیش‌بینی‌شده	۱۳۴۸	۱۰	۳۰/۷	۳	۴۶	۲۰۴۲	۱۶۲۰	۳۳/۷۹
DIP	مرجع	۷۷۴	۵	۴۰/۲۱	۳	۴۴۴	۱۹۷۴	۱۶۴۱	۱۳/۸۳
DIP	پیش‌بینی‌شده	۱۳۸۵	۵	۰۷/۳	۳	۲۷	۱۷۱۰	۱۲۸۶	۲۰/۷۵

پیمانه‌های مرجع عموماً پراکندگی کمتری دارند. برای نمونه، انحراف معیار اندازه پیمانه‌ها در پیمانه‌های پیش‌بینی‌شده در تمامی مجموعه‌داده‌ها کمتر از مقدار متناظر در مجموعه مرجع است. همچنین، حداکثر اندازه پیمانه‌های پیش‌بینی‌شده نیز به‌طور محسوسی کمتر است. با این حال، این تفاوت را باید با توجه به توزیع اندازه پیمانه‌ها تفسیر کرد. تعداد پیمانه‌های بسیار بزرگ در مجموعه‌های مرجع معمولاً بسیار محدود است و بخش عمده پیمانه‌ها در محدوده اندازه‌های کوچک و متوسط قرار دارند. ازاین‌رو، مقادیر حداکثر و انحراف معیار می‌توانند به‌شدت تحت تأثیر تعداد اندک پیمانه‌های بسیار بزرگ قرار گیرند و مقایسه توزیع کامل اندازه پیمانه‌ها، که در شکل ۱.۸.۵ ارائه شده است، ارزیابی دقیق‌تری از این تفاوت فراهم می‌کند.

از نظر میزان هم‌پوشانی میان پیمانه‌ها نیز درصد پروتئین‌هایی که در بیش از یک پیمانه قرار گرفته‌اند، در مجموعه‌های مرجع بین ۹۲/۷۸ تا ۳۶/۸۳ درصد و در مجموعه‌های پیش‌بینی‌شده بین ۲۰/۷۵ تا ۴۲/۸۴ درصد است. این مقادیر نشان می‌دهند که بخش قابل توجهی از پروتئین‌های شناسایی‌شده در چندین پیمانه حضور دارند، که با ماهیت هم‌پوشان ساختارهای پروتئینی سازگار است. در برخی مجموعه‌داده‌ها میزان هم‌پوشانی در پیمانه‌های پیش‌بینی‌شده کمتر از مجموعه مرجع است، در حالی که در برخی دیگر مقدار آن مشابه یا حتی اندکی بیشتر است. بنابراین، روش پیشنهادی علاوه بر شناسایی پیمانه‌هایی با اندازه‌های متفاوت، توانسته است بخش قابل توجهی از ساختار هم‌پوشان میان پیمانه‌ها



شکل ۲.۵: توزیع اندازه پیمانه‌های مرجع و پیمانه‌های پیش‌بینی‌شده

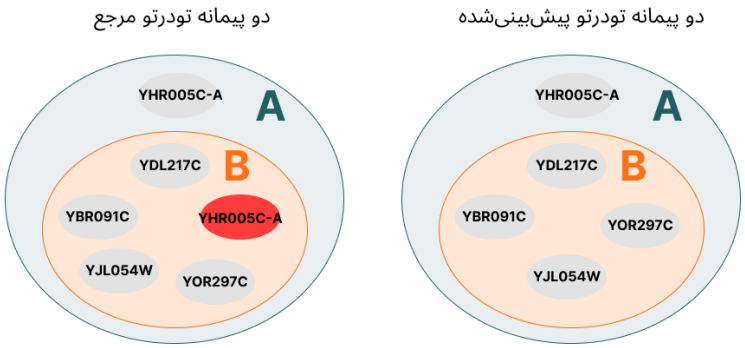
را نیز حفظ کند.

به‌منظور ارزیابی عملکرد آستانه تجمیعی و بررسی تأثیر آن بر بازیابی جفت‌های پیمانه‌ای تودرتو، عملکرد روش پیشنهادی با استفاده از آستانه ثابت ۰/۳ و آستانه تجمیعی مقایسه شده است. همان‌طور که نتایج جدول ۱۲.۵ نشان می‌دهد، آستانه تجمیعی در تمامی مجموعه‌داده‌ها عملکرد بهتری در بازیابی جفت‌های پیمانه‌ای تودرتو نسبت به آستانه ثابت ۰/۳ داشته است. شایان ذکر است که مقدار ۰/۳ در میان مقادیر مختلف آستانه ثابت، به دلیل عملکرد نسبی بهتر آن، به‌عنوان آستانه ثابت در این مقایسه انتخاب شده است. نتایج نشان می‌دهند که استفاده از آستانه تجمیعی می‌تواند توانایی روش پیشنهادی در شناسایی ساختارهای پیمانه‌ای تودرتو را بهبود دهد. یکی از نمونه‌های پیمانه‌های تودرتو پیش‌بینی شده در مجموعه‌داده Biogrid که در شکل ۱.۸.۵ به تصویر کشیده شده است. در این مثال اگرچه

پروتئین YHR005C-A توسط روش‌پیشنهادی در هیچ یک از این دو پیمانه پیش‌بینی نشده است، اما به دلیل شباهت همسایگی بیشتر از ۰/۲۵ به برابر در نظر گرفته می‌شوند.

جدول ۱۲.۵: مقایسه درصد بازیابی جفت‌های پیمانه‌های تودرتو با استفاده از دو روش تعیین آستانه

مجموعه‌داده	تعداد جفت‌های تودرتو	درصد بازیابی	
		آستانه تجمیعی	آستانه ثابت ۰/۳
Collins	۱۰۱۴	۲۳/۸۷	۱۱/۰۵
Krogan Core	۹۹۵	۱۷/۰۹	۹/۳۵
Krogan Extended	۱۰۱۷	۲۲/۷۱	۱۱/۰۱
Biogrid	۱۱۲۱	۲۵/۷۸	۶/۹۶
DIP	۱۱۵۸	۱۹/۶۰	۶/۶۵



شکل ۳.۵: مقایسه پیمانه‌های تودرتو پیش‌بینی شده و مرجع در مجموعه‌داده Biogrid

در مجموع، نتایج این بخش نشان می‌دهند که روش پیشنهادی ضمن شناسایی پیمانه‌هایی با اندازه و توزیع قابل‌قبول، توانسته است بخش قابل توجهی از ساختار هم‌پوشان موجود در مجموعه‌های مرجع را نیز حفظ کند. همچنین، مقایسه آستانه‌های مختلف نشان داد که استفاده از آستانه تجمیعی در مقایسه با آستانه ثابت، توانایی روش را در بازیابی روابط تودرتوی میان پیمانه‌ها بهبود می‌دهد. بررسی نمونه‌های کیفی نیز نشان می‌دهد که روش پیشنهادی قادر است در مواردی که پیمانه‌های واقعی دارای ساختارهای تودرتو هستند، این رابطه را در پیمانه‌های پیش‌بینی‌شده حفظ کند. در نتیجه، ارزیابی‌های

آماری و کیفی انجام‌شده، توانایی روش پیشنهادی در بازسازی ساختارهای پیمانه‌ای پیچیده و هم‌پوشان شبکه برهم‌کنش پروتئین‌ها را تأیید می‌کنند.

فصل ۶

نتیجه‌گیری و پیشنهادها

۱.۶ مقدمه

در این فصل به جمع‌بندی پژوهش حاضر می‌پردازیم، همچنین پیشنهاداتی برای پژوهشگران آینده در این حوزه ارائه می‌دهیم.

۲.۶ جمع‌بندی و نتیجه‌گیری

در این پژوهش، مدل‌های یادگیری عمیق و به‌ویژه شبکه‌های عصبی گرافی برای شناسایی پیمانه‌های عملکردی در شبکه‌های تعامل پروتئین_پروتئین پیشنهاد شد. بنابر بررسی‌های انجام‌شده، تا زمان نگارش این پایان‌نامه روشی یکپارچه مبتنی بر شبکه‌های عصبی گرافی برای این مسئله ارائه نشده بود. در این تحقیق، اطلاعات زیستی پایگاه هستی‌شناسی ژن به‌صورت مؤثر و ترکیبی از دو قالب دودویی و بردارهای تعبیه به کار گرفته شد. افزون بر این موضوع، تابع هزینه پیشنهادی در این تحقیق که نسخه بهبود یافته NOCD برای شناسایی پیمانه‌های عملکردی است، نیز تاثیر به سزایی در عملکرد این روش

داشته است.

چندین مدل محاسباتی شامل شبکه عصبی گرافی پیچشی، شبکه عصبی گرافی توجه‌محور، دو نسخه بهبودیافته‌ی مدل توجه‌محور یک مدل مجهز به سازوکار پرش دانش طراحی و بررسی شدند که در میان آن‌ها، مدل توجه‌محور بهترین عملکرد را نشان داد.

برای ارزیابی، نتایج مدل پیشنهادی بر روی مجموعه‌داده‌های معیار با چندین روش پیشین و نیز بهترین روش موجود در این حوزه مقایسه شد و برتری روش ارائه‌شده در تمامی معیارهای اصلی به اثبات رسید.

۳.۶ پیشنهادها

همان‌طور که اشاره شد در پژوهش حاضر به شناسایی پیمانه‌های عملکردی به کمک شبکه‌های عصبی گرافی و استفاده از ویژگی‌های زیستی موجود پرداختیم و روشی یکپارچه ارائه دادیم. در ادامه چندین موضوع برای ادامه پژوهش حاضر ارائه می‌شود.

در این پژوهش، برای نمایش هر پروتئین از میانگین‌گیری تعبیه‌های عبارات GO در هر زیرفضا استفاده شده است. این رویکرد اگرچه ساده به نظر می‌رسد، اما از نظر محاسباتی کارا بوده است. اما می‌تواند منجر به از دست رفتن بخشی از اطلاعات زیستی نهفته در تعبیه‌ها شود. بررسی و به‌کارگیری سایر روش‌های ادغام تعبیه‌های عبارات GO در هر زیرفضا، به‌عنوان ویژگی‌های بازنمایی‌کننده پروتئین‌ها، می‌تواند به‌عنوان یک مسیر پژوهشی آینده مدنظر قرار گیرد و به بهبود کیفیت نمایش پروتئین‌ها منجر شود.

همچنین تمرکز اصلی این پژوهش بر شبکه‌های تعامل پروتئین ـ پروتئین در گونه‌ی مخمر نان بوده است، موضوعی که در بسیاری از پژوهش‌های پیشین نیز مشاهده می‌شود. تعمیم و ارزیابی روش پیشنهادی بر روی شبکه‌های تعامل پروتئین ـ پروتئین مربوط به سایر گونه‌ها، می‌تواند چشم‌انداز مناسبی برای بررسی قابلیت تعمیم‌پذیری و پایداری عملکرد روش فراهم آورد.

افزون بر این، هرچند روش پیشنهادی در این پژوهش با هدف شناسایی پیمانه‌های عملکردی در شبکه‌های تعامل پروتئین_پروتئین ارائه شده است، اما انتظار می‌رود در مسائل خوشه‌بندی که مستلزم شناسایی خوشه‌های هم‌پوشان هستند نیز کارایی مناسبی داشته باشد. از این رو، آزمون روش پیشنهادی در سایر مسائل خوشه‌بندی هم‌پوشان می‌تواند به‌عنوان مسیر پژوهشی دیگری در آینده دنبال شود.

پیوست آ

نتایج تکمیلی روش محاسباتی

در این پیوست، نتایج تکمیلی حاصل از ارزیابی روش محاسباتی پیشنهادی ارائه می‌شوند. ابتدا، عملکرد شبکه‌ی GAT با انواع ویژگی‌های ورودی در آستانه‌های مختلف بررسی می‌شود. سپس، به‌منظور بررسی میزان تأثیرگذاری ویژگی‌های GO، این ویژگی‌ها با نمونه‌هایی از ویژگی‌های تصادفی جایگزین شده و نتایج حاصل از این آزمایش‌ها گزارش می‌شوند.

آ.۱ نتایج آستانه‌های متفاوت

در فصل نتایج، عملکرد شبکه‌های عصبی گرافی در آستانه‌ی ۰/۳ مورد مقایسه قرار گرفته است. ازاین‌رو، در این قسمت نتایج حاصل از اجرای شبکه‌ی GAT با انواع مختلف ویژگی‌های ورودی، شامل ویژگی‌های دودویی، ویژگی‌های تعبیه‌شده و ترکیب ویژگی‌های دودویی و تعبیه‌شده، در آستانه‌های مختلف برای پنج مجموعه‌داده‌ی مورد بررسی در این پژوهش گزارش می‌شوند.

جدول آ.۱: نتایج عملکرد شبکه عصبی در آستانه‌های ثابت مختلف با انواع ویژگی‌ها برای مجموعه داده Collins

نوع ویژگی	آستانه	Precision	Recall	F1	Accuracy	NCP	NCB
Binary	۰/۲	۰/۸۱۷	۰/۵۵۸	۰/۶۶۳	۰/۳۰۲	۱۳۸	۳۰۹
Embedding	۰/۲	۰/۸۹۳	۰/۴۷۷	۰/۶۲۱	۰/۲۹۲	۱۰۸	۲۶۴
Binary + Embedding	۰/۲	۰/۸۳۹	۰/۶۳۰	۰/۷۲۰	۰/۳۱۴	۲۳۰	۳۴۹
Binary	۰/۳	۰/۸۸۹	۰/۵۶۳	۰/۶۸۹	۰/۲۸۶	۱۱۲	۳۱۲
Embedding	۰/۳	۰/۹۰۳	۰/۳۳۹	۰/۴۹۳	۰/۲۴۹	۵۶	۱۸۸
Binary + Embedding	۰/۳	۰/۸۸۲	۰/۵۹۴	۰/۷۱۰	۰/۲۹۴	۱۵۰	۳۲۹
Binary	۰/۴	۰/۹۲۵	۰/۴۵۸	۰/۶۱۳	۰/۲۵۲	۷۴	۲۵۴
Embedding	۰/۴	۰/۹۶۶	۰/۲۰۴	۰/۳۳۷	۰/۱۹۲	۲۸	۱۱۳
Binary + Embedding	۰/۴	۰/۹۳۲	۰/۴۶۸	۰/۶۲۳	۰/۲۶۳	۹۶	۲۵۹
Binary	۰/۵	۰/۹۳۸	۰/۴۱۷	۰/۵۷۷	۰/۲۳۵	۶۱	۲۳۱
Embedding	۰/۵	۱/۰۰۰	۰/۰۸۷	۰/۱۵۹	۰/۱۳۰	۱۰	۴۸
Binary + Embedding	۰/۵	۰/۹۴۵	۰/۴۳۷	۰/۵۹۸	۰/۲۴۴	۶۹	۲۴۲
Binary	۰/۶	۰/۹۴۲	۰/۳۳۲	۰/۴۹۱	۰/۲۱۳	۴۹	۱۸۴
Embedding	۰/۶	۱/۰۰۰	۰/۰۳۱	۰/۰۶۰	۰/۰۷۲	۳	۱۷
Binary + Embedding	۰/۶	۰/۹۴۴	۰/۳۳۲	۰/۴۹۱	۰/۲۱۳	۵۱	۱۸۴
Binary	۰/۷	۰/۹۴۹	۰/۲۵۵	۰/۴۰۱	۰/۱۹۰	۳۷	۱۴۱
Embedding	۰/۷	۰/۰۰۰	۰/۰۰۰	۰/۰۰۰	۰/۰۰۰	۰	۰
Binary + Embedding	۰/۷	۰/۹۴۹	۰/۲۵۵	۰/۴۰۱	۰/۱۹۰	۳۷	۱۴۱

جدول آ.۲: نتایج عملکرد شبکه عصبی در آستانه‌های ثابت مختلف با انواع ویژگی‌ها برای مجموعه داده Krogan Core

نوع ویژگی	آستانه	Precision	Recall	F1	Accuracy	NCP	NCB
Binary	۰/۲	۰/۶۱۰	۰/۵۸۸	۰/۵۹۹	۰/۲۷۰	۲۲۱	۳۵۳
Embedding	۰/۲	۰/۶۰۱	۰/۵۲۸	۰/۵۶۲	۰/۲۷۵	۱۶۷	۳۱۷
Binary + Embedding	۰/۲	۰/۵۹۶	۰/۶۴۷	۰/۶۲۰	۰/۲۸۱	۳۷۰	۳۸۸
Binary	۰/۳	۰/۶۳۲	۰/۵۹۰	۰/۶۱۰	۰/۲۶۳	۲۰۸	۳۵۴
Embedding	۰/۳	۰/۶۵۸	۰/۵۳۵	۰/۵۹۰	۰/۲۶۴	۱۵۸	۳۲۱
Binary + Embedding	۰/۳	۰/۶۳۳	۰/۶۳۵	۰/۶۳۴	۰/۲۷۴	۳۴۹	۳۸۱
Binary	۰/۴	۰/۶۵۷	۰/۵۵۸	۰/۶۰۴	۰/۲۵۱	۱۸۲	۳۳۵
Embedding	۰/۴	۰/۶۸۲	۰/۴۸۷	۰/۵۶۸	۰/۲۴۳	۱۱۸	۲۹۲
Binary + Embedding	۰/۴	۰/۶۵۳	۰/۵۹۸	۰/۶۲۵	۰/۲۵۹	۲۸۱	۳۵۹
Binary	۰/۵	۰/۶۷۱	۰/۵۱۲	۰/۵۸۱	۰/۲۴۳	۱۳۹	۳۰۷
Embedding	۰/۵	۰/۷۹۸	۰/۴۲۵	۰/۵۵۵	۰/۲۲۹	۹۱	۲۵۵
Binary + Embedding	۰/۵	۰/۶۹۸	۰/۵۷۰	۰/۶۲۸	۰/۲۵۳	۲۰۸	۳۴۲
Binary	۰/۶	۰/۷۵۳	۰/۴۷۰	۰/۵۷۹	۰/۲۲۷	۱۲۲	۲۸۲
Embedding	۰/۶	۰/۸۰۶	۰/۲۸۸	۰/۴۲۵	۰/۱۹۸	۵۴	۱۷۳
Binary + Embedding	۰/۶	۰/۷۵۰	۰/۴۹۵	۰/۵۹۶	۰/۲۳۴	۱۵۹	۲۹۷
Binary	۰/۷	۰/۷۸۶	۰/۴۲۰	۰/۵۴۷	۰/۲۱۷	۹۹	۲۵۲
Embedding	۰/۷	۰/۸۴۱	۰/۲۰۲	۰/۳۲۵	۰/۱۶۶	۳۷	۱۲۱
Binary + Embedding	۰/۷	۰/۷۸۳	۰/۴۴۲	۰/۵۶۵	۰/۲۲۳	۱۲۳	۲۶۵

جدول آ.۳: نتایج عملکرد شبکه عصبی درآستانه‌های ثابت مختلف با انواع ویژگی‌ها برای مجموعه داده Krogan Extended

نوع ویژگی	آستانه	Precision	Recall	F1	Accuracy	NCP	NCB
Binary	۰/۲	۰/۶۵۷	۰/۴۸۶	۰/۵۵۸	۰/۲۵۳	۲۴۵	۳۲۲
Embedding	۰/۲	۰/۶۹۴	۰/۳۹۵	۰/۵۰۴	۰/۲۴۸	۱۴۵	۲۶۲
Binary + Embedding	۰/۲	۰/۶۶۶	۰/۵۱۶	۰/۵۸۱	۰/۲۶۰	۳۸۲	۳۴۲
Binary	۰/۳	۰/۶۵۲	۰/۴۷۱	۰/۵۴۶	۰/۲۴۱	۲۰۲	۳۱۲
Embedding	۰/۳	۰/۷۷۹	۰/۳۸۵	۰/۵۱۵	۰/۲۳۲	۱۱۳	۲۵۵
Binary + Embedding	۰/۳	۰/۶۹۱	۰/۵۰۷	۰/۵۸۵	۰/۲۵۱	۳۰۸	۳۳۶
Binary	۰/۴	۰/۷۱۹	۰/۴۶۲	۰/۵۶۲	۰/۲۲۸	۱۶۶	۳۰۶
Embedding	۰/۴	۱/۰۰۰	۰/۳۱۷	۰/۴۵۴	۰/۲۱۰	۷۶	۲۱۰
Binary + Embedding	۰/۴	۰/۷۳۸	۰/۴۸۳	۰/۵۸۳	۰/۲۳۸	۲۳۶	۳۲۰
Binary	۰/۵	۰/۸۰۱	۰/۴۱۳	۰/۵۴۵	۰/۲۱۳	۱۳۳	۲۷۴
Embedding	۰/۵	۰/۷۱۲	۰/۲۲۸	۰/۳۴۵	۰/۱۷۹	۴۷	۱۵۱
Binary + Embedding	۰/۵	۰/۷۷۳	۰/۴۲۷	۰/۵۵۰	۰/۲۲۰	۱۷۷	۲۸۳
Binary	۰/۶	۰/۸۷۳	۰/۳۵۹	۰/۵۰۹	۰/۱۹۹	۹۶	۲۳۸
Embedding	۰/۶	۰/۷۸۴	۰/۱۴۶	۰/۲۴۷	۰/۱۳۵	۲۹	۹۷
Binary + Embedding	۰/۶	۰/۸۴۵	۰/۳۷۷	۰/۵۲۱	۰/۲۰۰	۱۲۰	۲۵۰
Binary	۰/۷	۰/۹۰۲	۰/۳۰۹	۰/۴۶۱	۰/۱۷۸	۷۴	۲۰۵
Embedding	۰/۷	۰/۸۳۳	۰/۰۹۴	۰/۱۶۸	۰/۱۰۷	۱۵	۶۲
Binary + Embedding	۰/۷	۰/۸۸۹	۰/۳۳۲	۰/۴۸۳	۰/۱۸۳	۸۸	۲۲۰

جدول آ.۴: نتایج عملکرد شبکه عصبی درآستانه‌های ثابت مختلف با انواع ویژگی‌ها برای مجموعه داده Biogrid

نوع ویژگی	آستانه	Precision	Recall	F1	Accuracy	NCP	NCB
Binary	۰/۲	۰/۵۹۱	۰/۴۳۵	۰/۳۰۴	۰/۵۰۱	۱۹۸	۳۴۳
Embedding	۰/۲	۰/۵۳۸	۰/۳۷۱	۰/۲۹۷	۰/۴۳۹	۱۲۸	۲۹۲
Binary + Embedding	۰/۲	۰/۵۶۷	۰/۴۷۵	۰/۳۱۳	۰/۵۱۷	۳۱۹	۳۷۴
Binary	۰/۳	۰/۶۷۵	۰/۴۵۲	۰/۲۷۶	۰/۵۴۱	۱۶۴	۳۵۶
Embedding	۰/۳	۰/۶۴۶	۰/۳۶۲	۰/۲۶۵	۰/۴۶۴	۱۰۴	۲۸۵
Binary + Embedding	۰/۳	۰/۶۶۲	۰/۴۹۴	۰/۲۸۳	۰/۵۶۵	۲۵۸	۳۸۹
Binary	۰/۴	۰/۷۴۳	۰/۳۹۱	۰/۲۴۷	۰/۵۱۲	۱۱۳	۳۰۸
Embedding	۰/۴	۰/۶۳۹	۰/۳۱۱	۰/۲۳۸	۰/۴۱۸	۷۸	۲۴۵
Binary + Embedding	۰/۴	۰/۶۹۰	۰/۴۳۰	۰/۲۵۹	۰/۵۳۰	۱۸۰	۳۳۹
Binary	۰/۵	۰/۸۴۳	۰/۳۲۹	۰/۲۲۱	۰/۴۷۳	۸۶	۲۵۹
Embedding	۰/۵	۰/۸۴۲	۰/۲۵۶	۰/۲۰۷	۰/۳۹۳	۶۴	۲۰۲
Binary + Embedding	۰/۵	۰/۸۴۱	۰/۳۶۹	۰/۲۳۳	۰/۵۱۳	۱۴۳	۲۹۱
Binary	۰/۶	۰/۸۴۴	۰/۲۷۵	۰/۱۹۵	۰/۴۱۵	۶۵	۲۱۷
Embedding	۰/۶	۰/۸۴۰	۰/۱۶۴	۰/۱۷۳	۰/۲۷۴	۴۲	۱۲۹
Binary + Embedding	۰/۶	۰/۸۳۷	۰/۳۱۳	۰/۲۱۲	۰/۴۵۶	۱۰۳	۲۴۷
Binary	۰/۷	۰/۸۷۵	۰/۱۹۳	۰/۱۶۳	۰/۳۱۶	۴۲	۱۵۲
Embedding	۰/۷	۰/۷۷۴	۰/۱۱۵	۰/۱۴۳	۰/۲۰۱	۲۴	۹۱
Binary + Embedding	۰/۷	۰/۸۳۱	۰/۲۳۲	۰/۱۸۴	۰/۳۶۳	۶۴	۱۸۳

جدول آ.۵: نتایج عملکرد شبکه عصبی درآستانه‌های ثابت مختلف با انواع ویژگی‌ها برای مجموعه داده DIP

نوع ویژگی	آستانه	Precision	Recall	F1	Accuracy	NCP	NCB
Binary	۰/۲	۰/۵۶۵	۰/۵۴۸	۰/۵۵۶	۰/۲۵۶	۲۱۴	۴۲۴
Embedding	۰/۲	۰/۵۷۸	۰/۴۱۵	۰/۴۸۳	۰/۲۴۷	۱۳۴	۳۲۱
Binary + Embedding	۰/۲	۰/۵۵۸	۰/۵۹۴	۰/۵۷۶	۰/۲۶۴	۳۳۱	۴۶۰
Binary	۰/۳	۰/۶۱۴	۰/۵۲۲	۰/۵۶۴	۰/۲۴۰	۱۹۹	۴۰۴
Embedding	۰/۳	۰/۶۷۴	۰/۳۸۰	۰/۴۸۶	۰/۲۲۰	۱۱۶	۲۹۴
Binary + Embedding	۰/۳	۰/۶۲۱	۰/۵۵۸	۰/۵۸۸	۰/۲۴۴	۲۹۳	۴۳۲
Binary	۰/۴	۰/۶۷۳	۰/۴۶۴	۰/۵۴۹	۰/۲۲۱	۱۶۵	۳۵۹
Embedding	۰/۴	۰/۷۴۱	۰/۳۱۳	۰/۴۴۰	۰/۱۹۷	۸۳	۲۴۲
Binary + Embedding	۰/۴	۰/۶۸۲	۰/۴۹۹	۰/۵۷۶	۰/۲۲۶	۲۲۵	۳۸۶
Binary	۰/۵	۰/۷۳۱	۰/۳۸۲	۰/۵۰۲	۰/۲۰۰	۱۲۲	۲۹۶
Embedding	۰/۵	۰/۷۷۶	۰/۲۴۹	۰/۳۷۷	۰/۱۷۹	۶۶	۱۹۳
Binary + Embedding	۰/۵	۰/۷۳۶	۰/۴۰۷	۰/۵۲۴	۰/۲۰۷	۱۷۰	۳۱۵
Binary	۰/۶	۰/۷۲۵	۰/۲۹۷	۰/۴۲۲	۰/۱۸۲	۸۷	۲۳۰
Embedding	۰/۶	۰/۷۶۴	۰/۱۵۸	۰/۲۶۱	۰/۱۵۶	۴۲	۱۲۲
Binary + Embedding	۰/۶	۰/۷۳۰	۰/۳۳۲	۰/۴۵۶	۰/۱۸۹	۱۱۶	۲۵۷
Binary	۰/۷	۰/۷۷۵	۰/۲۳۱	۰/۳۵۶	۰/۱۵۹	۶۹	۱۷۹
Embedding	۰/۷	۰/۸۳۳	۰/۱۱۹	۰/۲۰۸	۰/۱۳۲	۳۰	۹۲
Binary + Embedding	۰/۷	۰/۷۹۳	۰/۲۶۶	۰/۳۹۹	۰/۱۷۱	۹۲	۲۰۶

آ.۲ نتایج ویژگی‌های تصادفی

به‌منظور بررسی میزان تأثیرگذاری ویژگی‌های GO بر عملکرد روش پیشنهادی، آزمایش‌های تکمیلی با جایگزین‌کردن این ویژگی‌ها با ویژگی‌های تصادفی انجام شده است. در این آزمایش‌ها، سه نوع ویژگی جایگزین شامل ماتریس همانی، ماتریس تعبیه‌ی تصادفی و ماتریس دودویی تصادفی به‌عنوان ویژگی‌های ورودی شبکه در نظر گرفته شده‌اند. نتایج این آزمایش‌ها در آستانه‌ی ۰/۳ ارائه شده و امکان ارزیابی نقش و اهمیت ویژگی‌های GO در عملکرد مدل را فراهم می‌کنند.

جدول آ.۶: مقایسه عملکرد مدل با ویژگی‌های تصادفی با سه رویکرد ماتریس همانی، ویژگی‌های تعبیه تصادفی و ویژگی‌های دودویی تصادفی بر روی مجموعه‌داده‌های Collins و BioGRID

مجموعه‌داده	نوع ویژگی پایه	Precision	Recall	F-score	Acc	NCP	NCB
Collins	Identity	۰/۹۷۸	۰/۳۷۹	۰/۵۴۶	۰/۲۴۶	۹۱	۲۱۰
	Random Binary	۰/۸۸۵	۰/۳۱۶	۰/۴۶۶	۰/۲۵۲	۷۷	۱۷۵
	Random Embedding	۰/۸۶۲	۰/۱۵۵	۰/۲۶۳	۰/۲۰۴	۲۵	۸۶
BioGRID	Identity	۰/۷۴۲	۰/۱۵۳	۰/۲۵۴	۰/۱۸۵	۵۲	۱۲۱
	Random Binary	۰/۵۲۹	۰/۱۱۸	۰/۱۹۳	۰/۱۸۰	۳۶	۹۳
	Random Embedding	۰/۶۵۹	۰/۱۹۲	۰/۲۹۷	۰/۲۲۳	۶۰	۱۵۱

کتاب‌نامه

[1] Wikipedia contributors. Gene ontology — Wikipedia, the free encyclopedia, 2024. [Online; accessed 20-December-2024].

[2] Grattarola, Daniele. A practical introduction to GNNs - Part 2: Message passing and gather-scatter. Daniele Grattarola's Blog, March 2021. Accessed: 2024-12-20.

[3] Veličković, Petar, Cucurull, Guillem, Casanova, Arantxa, Romero, Adriana, Lio, Pietro, and Bengio, Yoshua. Graph attention networks. *arXiv preprint arXiv:1710.10903*, 2017.

[4] Xu, Keyulu, Li, Chengtao, Tian, Yonglong, Sonobe, Tomohiro, Kawarabayashi, Ken-ichi, and Jegelka, Stefanie. Representation learning on graphs with jumping knowledge networks. in *International conference on machine learning*, pp. 5453–5462. pmlr, 2018.

[5] Chen, Hongwei, Cai, Yunpeng, Ji, Chaojie, Selvaraj, Gurudeeban, Wei, Dongqing, and Wu, Hongyan. Adappi: identification of novel protein func-

tional modules via adaptive graph convolution networks in a protein–protein interaction network. *Briefings in Bioinformatics*, 24(1):bbac523, 2023.

[6] Ji, Junzhong, Zhang, Aidong, Liu, Chunnian, Quan, Xiaomei, and Liu, Zhijun. Survey: Functional module detection from protein-protein interaction networks. *IEEE Transactions on Knowledge and Data Engineering*, 26(2):261–277, 2012.

[7] V, Manila M. A literature survey on bioinformatics. *IJIREEICE International Journal of Innovative Research in Electrical, Electronics, Instrumentation and Control Engineering*, February 2023.

[8] Berahmand, Kamal, Nasiri, Elahe, Li, Yuefeng, et al. Spectral clustering on protein-protein interaction networks via constructing affinity matrix using attributed graph embedding. *Computers in Biology and Medicine*, 138:104933, 2021.

[9] Li, Xiaoli, Wu, Min, Kwoh, Chee-Keong, and Ng, See-Kiong. Computational approaches for detecting protein complexes from protein interaction networks: a survey. *BMC genomics*, 11:1–19, 2010.

[10] Consortium, Gene Ontology. The gene ontology (go) project in 2006. *Nucleic acids research*, 34(suppl_1):D322–D326, 2006.

[11] Su, Lili, Liu, Guang, Guo, Ying, Zhang, Xuanping, Zhu, Xiaoyan, and Wang, Jiayin. Integration of protein-protein interaction networks and gene expression profiles helps detect pancreatic adenocarcinoma candidate genes. *Frontiers in Genetics*, 13:854661, 2022.

[12] Bothorel, Cécile, Cruz, Juan David, Magnani, Matteo, and Micenkova, Barbora. Clustering attributed graphs: models, measures and methods. *Network Science*, 3(3):408–444, 2015.

[13] Farutin, Victor, Robison, Keith, Lightcap, Eric, Dancik, Vlado, Ruttenberg, Alan, Letovsky, Stanley, and Pradines, Joel. Edge-count probabilities for the identification of local protein communities and their organization. *Proteins: Structure, Function, and Bioinformatics*, 62(3):800–818, 2006.

[14] Zaki, Nazar and Alashwal, Hany. Improving the detection of protein complexes by predicting novel missing interactome links in the protein-protein interaction network. in *2018 40th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pp. 5041–5044. IEEE, 2018.

[15] Macropol, Kathy, Can, Tolga, and Singh, Ambuj K. Rrw: repeated random walks on genome-scale protein networks for local cluster discovery. *BMC bioinformatics*, 10(1):283, 2009.

[16] Alberts, Bruce, Heald, Rebecca, Johnson, Alexander, Morgan, David, Raff, Martin, Roberts, Keith, and Walter, Peter. *Molecular Biology of the Cell*. W. W. Norton & Company, New York, 7th ed. , 2022. International Student Edition.

[17] Dilmaghani, Saharnaz, Brust, Matthias R, Ribeiro, Carlos HC, Kieffer, Emmanuel, Danoy, Grégoire, and Bouvry, Pascal. From communities to protein complexes: a local community detection algorithm on ppi networks. *Plos one*, 17(1):e0260484, 2022.

[18] Hartwell, Leland H, Hopfield, John J, Leibler, Stanislas, and Murray, Andrew W. From molecular to modular cell biology. *Nature*, 402(Suppl 6761):C47–C52, 1999.

[19] Li, Min, Wu, Xuehong, Wang, Jianxin, and Pan, Yi. Towards the identification of protein complexes and functional modules by integrating ppi network and gene expression data. *BMC bioinformatics*, 13(1):109, 2012.

[20] Safari-Alighiarloo, Nahid, Taghizadeh, Mohammad, Rezaei-Tavirani, Mostafa, Goliaei, Bahram, and Peyvandi, Ali Asghar. Protein-protein interaction networks (ppi) and complex diseases. *Gastroenterology and Hepatology from bed to bench*, 7(1):17, 2014.

[21] Mujawar, Shama, Mishra, Rohit, Pawar, Shrikant, Gatherer, Derek, and Lahiri, Chandrajit. Delineating the plausible molecular vaccine candidates and drug targets of multidrug-resistant acinetobacter baumannii. *Frontiers in cellular and infection microbiology*, 9:203, 2019.

[22] Gélard, Maxence, Richard, Guillaume, Pierrot, Thomas, and Cournède, Paul-Henry. Bulkrnabert: Cancer prognosis from bulk rna-seq based language models. *bioRxiv*, pp. 2024–06, 2024.

[23] Ashburner, Michael, Ball, Catherine A, Blake, Judith A, Botstein, David, Butler, Heather, Cherry, J Michael, Davis, Allan P, Dolinski, Kara, Dwight, Selina S, Eppig, Janan T, et al. Gene ontology: tool for the unification of biology. *Nature genetics*, 25(1):25–29, 2000.

[24] Stumpf, Michael PH, Kelly, William P, Thorne, Thomas, and Wiuf, Carsten. Evolution at the system level: the natural history of protein interaction networks. *Trends in Ecology & Evolution*, 22(7):366–373, 2007.

[25] Li, Dong, Li, Jianqi, Ouyang, Shuguang, Wang, Jian, Wu, Songfeng, Wan, Ping, Zhu, Yunping, Xu, Xiaojie, and He, Fuchu. Protein interaction networks of saccharomyces cerevisiae, caenorhabditis elegans and drosophila melanogaster: Large-scale organization and robustness. *Proteomics*, 6(2):456–461, 2006.

[26] Wagner, Günter P, Pavlicev, Mihaela, and Cheverud, James M. The road to modularity. *Nature Reviews Genetics*, 8(12):921–931, 2007.

[27] Bishop, Christopher M and Nasrabadi, Nasser M. *Pattern recognition and machine learning*, vol. 4. Springer, 2006.

[28] Janiesch, Christian, Zschech, Patrick, and Heinrich, Kai. Machine learning and deep learning. *Electronic markets*, 31(3):685–695, 2021.

[29] Dridi, Salim. Supervised learning-a systematic literature review. *preprint, Dec*, 2021.

[30] Wu, Xiangdong, Liu, Xiaoyan, and Zhou, Yimin. Review of unsupervised learning techniques. in *Proceedings of 2021 Chinese Intelligent Systems Conference: Volume II*, pp. 576–590. Springer, 2021.

[۳۱] Esmail. Babalian، *Topics in Discrete Mathematics*. Mobtakeran، Tehran، ۲۰۰۷.

[32] Scarselli, Franco, Gori, Marco, Tsoi, Ah Chung, Hagenbuchner, Markus, and Monfardini, Gabriele. The graph neural network model. *IEEE transactions on neural networks*, 20(1):61–80, 2008.

[33] Rong, Yu, Huang, Wenbing, Xu, Tingyang, and Huang, Junzhou. Dropedge: Towards deep graph convolutional networks on node classification. *arXiv preprint arXiv:1907.10903*, 2019.

[34] Khemani, Bharti, Patil, Shruti, Kotecha, Ketan, and Tanwar, Sudeep. A review of graph neural networks: concepts, architectures, techniques, challenges, datasets, applications, and future directions. *Journal of Big Data*, 11(1):18, 2024.

[35] Kipf, TN. Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv:1609.02907*, 2016.

[36] He, Kaiming, Zhang, Xiangyu, Ren, Shaoqing, and Sun, Jian. Deep residual learning for image recognition. in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 770–778, 2016.

[37] Mikolov, Tomas, Chen, Kai, Corrado, Greg, and Dean, Jeffrey. Efficient estimation of word representations in vector space. *arXiv preprint arXiv:1301.3781*, 2013.

[38] Grover, Aditya and Leskovec, Jure. node2vec: Scalable feature learning for networks. in *Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining*, pp. 855–864, 2016.

[39] Jannesari, Vahid, Keshvari, Maryam, and Berahmand, Kamal. A novel non-negative matrix factorization-based model for attributed graph clustering by incorporating complementary information. *Expert Systems with Applications*, 242:122799, 2024.

[40] Kang, Zhao, Liu, Zhanyu, Pan, Shirui, and Tian, Ling. Fine-grained attributed graph clustering. in *Proceedings of the 2022 SIAM International Conference on Data Mining (SDM)*, pp. 370–378. SIAM, 2022.

[41] Bhowmick, Aritra, Kosan, Mert, Huang, Zexi, Singh, Ambuj, and Medya, Sourav. Dgcluster: A neural framework for attributed graph clustering via modularity maximization. in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, pp. 11069–11077, 2024.

[42] Zhang, Tian, Ramakrishnan, Raghu, and Livny, Miron. Birch: an efficient data clustering method for very large databases. *ACM sigmod record*, 25(2):103–114, 1996.

[43] He, Chaobo, Cheng, Junwei, Chen, Guohua, Guan, Quanlong, Fei, Xiang, and Tang, Yong. Detecting communities with multiple topics in attributed networks via self-supervised adaptive graph convolutional network. *Information Fusion*, 105:102254, 2024.

[44] Wang, Chun, Pan, Shirui, Hu, Ruiqi, Long, Guodong, Jiang, Jing, and Zhang, Chengqi. Attributed graph clustering: A deep attentional embedding approach. *arXiv preprint arXiv:1906.06532*, 2019.

[45] Shchur, Oleksandr and Günnemann, Stephan. Overlapping community detection with graph neural networks. *arXiv preprint arXiv:1909.12201*, 2019.

[46] Srihari, Sriganesh and Leong, Hon Wai. Employing functional interactions for characterisation and detection of sparse complexes from yeast ppi networks. *International journal of bioinformatics research and applications*, 8(3-4):286–304, 2012.

[47] Patra, Sabyasachi and Mohapatra, Anjali. Protein complex prediction in interaction network based on network motif. *Computational Biology and Chemistry*, 89:107399, 2020.

[48] Nepusz, Tamás, Yu, Haiyuan, and Paccanaro, Alberto. Detecting overlapping protein complexes in protein-protein interaction networks. *Nature methods*, 9(5):471–472, 2012.

[49] Bader, Gary D and Hogue, Christopher WV. An automated method for finding molecular complexes in large protein interaction networks. *BMC bioinformatics*, 4:1–27, 2003.

[50] Hu, Allen L and Chan, Keith CC. Utilizing both topological and attribute information for protein complex identification in ppi networks. *IEEE/ACM transactions on computational biology and bioinformatics*, 10(3):780–792, 2013.

[51] Zhang, Wei, Xu, Jia, Li, Yuanyuan, and Zou, Xiufen. Integrating network topology, gene expression data and go annotation information for protein

complex prediction. *Journal of bioinformatics and computational biology*, 17(01):1950001, 2019.

[52] Wu, Min, Li, Xiaoli, Kwoh, Chee-Keong, and Ng, See-Kiong. A core-attachment based method to detect protein complexes in ppi networks. *BMC bioinformatics*, 10:1–16, 2009.

[53] Leung, Henry CM, Xiang, Qian, Yiu, Siu-Ming, and Chin, Francis YL. Predicting protein complexes from ppi data: a core-attachment approach. *Journal of Computational Biology*, 16(2):133–144, 2009.

[54] Chua, Hon Nian, Ning, Kang, Sung, Wing-Kin, Leong, Hon Wai, and Wong, Limsoon. Using indirect protein–protein interactions for protein complex prediction. *Journal of bioinformatics and computational biology*, 6(03):435–466, 2008.

[55] Berahmand, Kamal, Nasiri, Elahe, Li, Yuefeng, et al. Spectral clustering on protein-protein interaction networks via constructing affinity matrix using attributed graph embedding. *Computers in Biology and Medicine*, 138:104933, 2021.

[56] Yang, Cheng, Liu, Zhiyuan, Zhao, Deli, Sun, Maosong, and Chang, Edward Y. Network representation learning with rich text information. in *IJCAI*, vol. 2015, pp. 2111–2117, 2015.

[57] Xu, Bo, Li, Kun, Zheng, Wei, Liu, Xiaoxia, Zhang, Yijia, Zhao, Zhehuan, and He, Zengyou. Protein complexes identification based on go attributed network

embedding. *BMC bioinformatics*, 19:1–10, 2018.

[58] Ma, Xiaoke, Sun, Penggang, and Gong, Maoguo. An integrative framework of heterogeneous genomic data for cancer dynamic modules based on matrix decomposition. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 19(1):305–316, 2020.

[59] Chen, Hongwei, Cai, Yunpeng, Ji, Chaojie, Selvaraj, Gurudeeban, Wei, Dongqing, and Wu, Hongyan. Adappi: identification of novel protein functional modules via adaptive graph convolution networks in a protein–protein interaction network. *Briefings in Bioinformatics*, 24(1):bbac523, 2023.

[60] Bhowmick, Sourav S and Seah, Boon Siew. Clustering and summarizing protein-protein interaction networks: A survey. *IEEE Transactions on Knowledge and Data Engineering*, 28(3):638–658, 2015.

[61] Berahmand, Kamal, Bouyer, Asgarali, and Vasighi, Mahdi. Community detection in complex networks by detecting and expanding core nodes through extended local similarity of nodes. *IEEE Transactions on Computational Social Systems*, 5(4):1021–1033, 2018.

[62] Zhou, Zhixin and Amini, Arash A. Analysis of spectral clustering algorithms for community detection: the general bipartite setting. *Journal of Machine Learning Research*, 20(47):1–47, 2019.

[63] Stark, Chris, Breitkreutz, Bobby-Joe, Reguly, Teresa, Boucher, Lorrie, Breitkreutz, Ashton, and Tyers, Mike. Biogrid: a general repository for interaction

datasets. *Nucleic acids research*, 34(suppl_1):D535–D539, 2006.

[64] Xenarios, Ioannis, Salwinski, Lukasz, Duan, Xiaoqun Joyce, Higney, Patrick, Kim, Sul-Min, and Eisenberg, David. Dip, the database of interacting proteins: a research tool for studying cellular networks of protein interactions. *Nucleic acids research*, 30(1):303–305, 2002.

[65] Collins, Sean R, Kemmeren, Patrick, Zhao, Xue-Chu, Greenblatt, Jack F, Spencer, Forrest, Holstege, Frank CP, Weissman, Jonathan S, and Krogan, Nevan J. Toward a comprehensive atlas of the physical interactome of saccharomyces cerevisiae. *Molecular & Cellular Proteomics*, 6(3):439–450, 2007.

[66] Pu, Shuye, Wong, Jessica, Turner, Brian, Cho, Emerson, and Wodak, Shoshana J. Up-to-date catalogues of yeast protein complexes. *Nucleic acids research*, 37(3):825–831, 2009.

[67] Pagel, Philipp, Kovac, Stefan, Oesterheld, Matthias, Brauner, Barbara, Dunger-Kaltenbach, Irmtraud, Frishman, Goar, Montrone, Corinna, Mark, Pekka, Stümpflen, Volker, Mewes, Hans-Werner, et al. The mips mammalian protein–protein interaction database. *Bioinformatics*, 21(6):832–834, 2005.

[68] Maddi, AMA and Eslahchi, Ch. Discovering overlapped protein complexes from weighted ppi networks by removing inter-module hubs. *Scientific reports*, 7(1):3247, 2017.

[69] Ieremie, Ioan, Ewing, Rob M, and Niranjan, Mahesan. Transformergo: predicting protein–protein interactions by modelling the attention between sets of gene

ontology terms. *Bioinformatics*, 38(8):2269–2277, 2022.

[70] Asur, Sitaram, Ucar, Duygu, and Parthasarathy, Srinivasan. An ensemble framework for clustering protein–protein interaction networks. *Bioinformatics*, 23(13):i29–i40, 2007.

[71] Liu, Guimei, Wong, Limsoon, and Chua, Hon Nian. Complex discovery from weighted ppi networks. *Bioinformatics*, 25(15):1891–1897, 2009.

[72] Omranian, Sara, Angeleska, Angela, and Nikoloski, Zoran. Pc2p: parameter-free network-based prediction of protein complexes. *Bioinformatics*, 37(1):73–81, 2021.

[73] Meng, Xiangmao, Xiang, Ju, Zheng, Ruiqing, Wu, Fang-Xiang, and Li, Min. Dpcmne: detecting protein complexes from protein-protein interaction networks via multi-level network embedding. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 19(3):1592–1602, 2021.

[74] Mrabah, Nairouz, Bouguessa, Mohamed, Touati, Mohamed Fawzi, and Ksantini, Riadh. Rethinking graph auto-encoder models for attributed graph clustering. *IEEE Transactions on Knowledge and Data Engineering*, 35(9):9037–9053, 2022.

[75] Zhang, Xiaotong, Liu, Han, Li, Qimai, and Wu, Xiao-Ming. Attributed graph clustering via adaptive graph convolution. *arXiv preprint arXiv:1906.01210*, 2019.

واژه‌نامه انگلیسی به فارسی

صحت ..... Accuracy

ماتریس همسایگی ..... Adjacency matrix

روش تجمعی ..... Agglomerative method

جمع‌آوری ..... Aggregate

هوش مصنوعی ..... Artificial intelligence

گراف ویژگی‌دار ..... Attributed graph

لایه نرمال‌سازی دسته‌ای ..... Batch normalization layer

زیست انفورماتیک ..... Bioinformatic

فرآیند زیستی ..... Biological process

نمونه‌برداری اول سطح ..... Breadth first sampling (BFS)

مرگ برنامه‌ریزی شده سلولی ..... Cell apoptosis

مؤلفه سلولی ..... Cellular component

انتقال سیگنال‌های سلولی ..... Cellular signal transduction

حساسیت خوشه‌بندی ..... clustering wise sensitivity (Sn)

ارزش پیش‌بینی مثبت خوشه‌بندی ..... Clustering wise positive predictive value (PPV)

الحاق ..... Concat

نمونه‌برداری اول عمق ..... Depth first sampling (DFS)

گراف جهت‌دار سلسله‌مراتبی ..... Directed hierarchical graph

روش تقسیمی ..... Divisive method

دی‌ان‌ای ..... DNA

دراپ‌اوت ..... Dropout

کدگشای دوگانه ..... Dual decoder

مقادیر ویژه ..... Eigenvalues

روش‌های مبتنی بر بازنمایی ..... Embedding based methods

کدگذار ..... Encoder

یکپارچه ..... End-to-end

امتیاز F ..... F-score

تاخوردگی ..... Folding

ماژول‌های عملکردی ..... Functional module

فایل حاشیه‌نویسی ژن ..... Gene annotation file (GAF)

بیان ژن ..... Gene expression

کنترل بیان ژن ..... Gene expression control

تکثیر ماده ژنتیکی ..... Gene substance copy

هستی‌شناسی ژن ..... Go Ontology

شبکه پیچشی گرافی ..... Graph convolutional networks (GCN)

شبکه عصبی گرافی ..... Graph neural network (GNN)

میانگین همساز ..... Harmonic mean

خوشه‌بندی سلسله‌مراتبی ..... Hierarchical clustering

توان عملیاتی بالا ..... High throughput

هاب ..... Hub

شبکه عصبی گرافی با انتقال دانش بین لایه‌ها ... Jumping knowledge graph neural network

عبارت منظم‌سازی L2 ..... L2 regularization term

برچسب ..... Label

نرخ یادگیری ..... Learning rate

تابع هزینه ..... Loss function

فیلتر پایین گذر ..... Low pass filter

یادگیری ماشین ..... Machine learning

طیف‌سنجی جرمی ..... Mass spectrometry

فاکتورگیری ماتریسی ..... Matrix factorization

بیشینه‌گیری ..... Max pooling

کلیک‌های بیشینه ..... Maximal clique

انتقال پیام ..... Message passing

عملکرد مولکولی ..... Molecular function

موتیف ..... Motif

ریبونوکلئیک اسید ..... mRNA:massenger ribonucleic acid

توجه چندسر ..... Multi head attention

پردازش زبان طبیعی ..... Natural language processing (NLP)

شباهت همسایگی ..... Neighborhood affinity

تجزیه نامنفی ماتریس ..... Non negative matrix factorization

روش‌های بدون بازنمایی ..... Non embedding methods

ماتریس لاپلاسی نرمال شده ..... Normalized laplacian matrix

هموارسازی بیش از حد ..... Over smoothing

افرازبندی ..... Partitioning

مسیر زیستی ..... Pathway

دوره پساژنی ..... Postgenomic era

دقت ..... Precision

مدل مولد احتمالی برنولی پواسون .... Probabilistic Bernoulli–Poisson Generative Model

تعاملات پروتئین‌ـ پروتئین ..... Protein-protein intractions

پروتئومیک ..... Proteomics

ولگشت تصادفی ..... Random walk

بازیابی ..... Recall

شبکه بازگشتی ..... Recurrent neural network (RNN)

مجموعه پروتئین‌های مرجع ..... Reference protein complex

یادگیری تقویتی ..... Reinforcement learning

اتصال باقیمانده ..... Residual connection

اتصالات باقیمانده ..... Residual connections

آرانای ..... RNA

مخمر نان ..... Saccharomyces cerevisiae

توزیع بدون مقیاس ..... Scale free distribution

مقیاس‌پذیر ..... Scalable

هسته ..... Seed

ویژگی خودبیانگری ..... Self expression

یال‌های خودی ..... Self connections

توجه خود‌ـ توجهی ..... Self-attention

نام معنایی ..... Semantic name

نیمه نظارتی ..... Semi supervised

تجزیه مقدار تکین ..... Singular value factorization

ویژگی جهان کوچک ..... Small world property

تنک ..... Sparse

خوشه‌بندی طیفی ..... Spectral clustering

خوشه‌بندی زیرفضا ..... Subspace clustering

یادگیری نظارت شده ..... Supervised learning

مجموعه آزمایشی ..... Test dataset

متن‌کاوی ..... Text mining

آستانه ..... Threshold

مجموعه آموزشی ..... Train dataset

شبکه عصبی گرافی توجه‌محور ..... Graph attention network (GAT)

سیستم‌های دوگانه هیبریدی ..... Two hybrid systems

هموارسازی ناکافی ..... Under smoothing

یادگیری بدون نظارت ..... Unsupervised learning

به‌روزرسانی ..... Update

محوشدگی گرادیان ..... Vanishing gradients

Abstract

Bioinformatics is an interdisciplinary field that utilizes biology, computer science, mathematics, and statistics to store and analyze biological data. With the completion of the Human Genome Project and the advent of the post-genomic era, proteomics research has become one of the most important areas of life sciences. Proteomics involves studying the characteristics of proteins to describe their structure, function, and role in regulating biological systems. Proteins often do not act alone but interact with each other, forming larger molecular complexes to perform biological functions. These interactions are represented using a network structure called the protein-protein interaction (PPI) network. A protein complex in PPI networks is a molecular structure composed of proteins that are functionally and structurally compatible. By analyzing PPI networks, we can identify these groups of proteins.

One of the key challenges in bioinformatics is the discovery of protein modules in protein-protein interaction networks. Identifying these modules is equivalent to the problem of community detection in graphs. In many bioinformatics applications, protein module discovery is performed using community detection algorithms in graphs. In this study, we aim to design a specialized method for community detection in protein interaction networks that, in addition to considering the graph structure for module identification, also takes into account the biological characteristics of proteins.

For example, integrating biological information about proteins stored in databases such as GO and KEGG with gene expression data and combining this information with

the PPI network can enhance the accuracy and efficiency of protein module identification. Therefore, in this research, we aim to introduce a clustering algorithm for PPI networks based on graph neural networks while incorporating node-specific features.

Keywords: *Graph Neural Networks, Protein-Protein Interactions, Functional Module Identification, Clustering Attributed Graphs*



Institute for Advanced Studies in Basic Sciences
Gava Zang, Zanjan, Iran

Computer Science and Information Technology

Computer Engineering – Artificial Intelligence and Robotics

Discovery of Functional Modules in Protein-Protein Interaction Networks using the Graph Neural Networks Approach

Master's Thesis

Samaneh Tejerloo

Supervisor: Dr. Zahra Narimani

July 28, 2026